

Progetto Finanza Quantitativa: *MPG-GAS*

Giuseppe Fontana ID: 0348614 Lorenzo Miccoli ID: 0348230
Marco Soriano ID: 0351483 Valerio Sturba ID: 0349754

a.a. 2024/2025

Contents

1	Introduzione	5
2	Analisi descrittiva	6
2.1	Descrizione dei dati	6
2.2	Analisi stazionarietà	11
2.3	Analisi di autocorrelazione	11
2.4	Stima della densità spettrale	12
3	Modelli univariati	13
3.1	Introduzione sulla scelta del modello	13
3.2	Fenomeno del Leverage	17
4	Esperimento di previsione rolling dei prezzi	25
4.1	Rolling Forecast	25
4.2	Metriche di errore	26
5	Conclusioni	29
A	Appendice: Codice Matlab	30

List of Figures

1	Serie temporale dei prezzi.	6
2	Serie temporale dei prezzi logaritmici (p_t).	7
3	Serie temporale dei rendimenti logaritmici (y_t).	8
4	Distribuzione dei rendimenti vs distribuzione Gaussiana.	10
5	ACF Rendimenti.	11
6	PACF Rendimenti.	11
7	Densità spettrale.	12
8	ACF Residui standardizzati.	15
9	ACF Residui standardizzati al quadrato.	15
10	Q-Q Plot dei residui standardizzati.	16
11	Cross-Correlazioni	18
12	Volatility smile.	19
13	Analisi miglior modello	24
14	Previsioni rolling dei prezzi vs Prezzi osservati.	25
15	Errori di previsione.	28

List of Tables

1	Statistiche descrittive per i prezzi logaritmici (p_t).	7
2	Statistiche descrittive per i rendimenti logaritmici (y_t).	9
3	test ADF logp.	11
4	ARCH Test residui standardizzati	16
5	LB test Res.Stand. ²	16
6	MSFE	26
7	MPE	27
8	MAPE	27

1 Introduzione

Il mercato del gas naturale riveste un ruolo cruciale nel panorama energetico europeo, con l'Italia che gioca un ruolo centrale attraverso il Punto di Scambio Virtuale (PSV), la principale piattaforma di negoziazione del gas nel paese. In questo contesto, la serie temporale MPG-GAS, disponibile per il periodo 1 ottobre 2018 - 31 ottobre 2024, rappresenta il prezzo medio ponderato del gas naturale, calcolato sulla base dei contratti conclusi in Italia, dove i pesi sono determinati dalle quantità scambiate. Tale metodologia assicura che i prezzi riflettano l'importanza relativa delle transazioni.

I dati giornalieri, espressi in Euro per Megawattora (€/MWh), sono forniti dal Gestore dei Mercati Energetici (GME) e si riferiscono esclusivamente alle transazioni sui mercati regolamentati. L'andamento dei prezzi del gas naturale è influenzato da numerosi fattori, tra cui la domanda interna, l'andamento dei prezzi internazionali, le condizioni meteorologiche e gli eventi geopolitici. Questi elementi contribuiscono a determinare la stagionalità e la volatilità dei prezzi osservati.

L'analisi di questa serie temporale richiede un approccio modellistico che tenga conto della dinamica complessa dei prezzi e delle loro variazioni giornaliere. In particolare, è necessario valutare la presenza di stagionalità settimanale e modellare l'eteroschedasticità condizionata, aspetti frequentemente riscontrati nei mercati energetici. Lo studio si concentra quindi sulla costruzione di modelli econometrici adeguati che consentano di catturare tali caratteristiche, con l'obiettivo di migliorare la capacità previsionale rispetto a modelli di riferimento semplici.

In questo contesto, il lavoro propone di analizzare i prezzi logaritmici del gas, stimare modelli ARIMA arricchiti con componenti GARCH, GJR o EGARCH per catturare la volatilità condizionata, e valutare la performance previsionale attraverso un esperimento di previsione rolling. I risultati saranno confrontati con un modello random walk stagionale e un modello autoregressivo semplice, utilizzando metriche di valutazione standard come MSFE, MPE e MAPE. L'analisi consentirà di verificare la validità dei modelli proposti e di comprendere meglio le dinamiche sottostanti il mercato del gas naturale in Italia.

2 Analisi descrittiva

In questa prima sezione verrà effettuata un'analisi esplorativa della serie temporale. Attraverso rappresentazioni grafiche, analizziamo il comportamento del prezzo logaritmico e dei rendimenti logaritmici, espressi rispettivamente come $p_t = \ln P_t$ e $y_t = \Delta p_t$, e delle loro statistiche descrittive quali media, varianza, asimmetria e curtosi per fornire una visione quantitativa della distribuzione.

Successivamente condurremo uno studio della stazionarietà della serie, effettuata mediante le funzioni di autocorrelazione semplice (ACF) e parziale (PACF), che forniscono indicazioni utili sulla dipendenza temporale dei dati.

Infine, stimiamo la densità spettrale della serie dei rendimenti logaritmici utilizzando una finestra di Bartlett con ampiezza $m = 15$, per esaminare il contributo di un ciclo trigonometrico definito alla frequenza omega alla variabilità della serie.

Questa fase preliminare getta le basi per modellare la volatilità e prevedere il comportamento futuro della serie temporale. Le osservazioni ottenute guideranno la scelta dei modelli econometrici più adatti, evidenziando le caratteristiche della serie che richiedono una modellazione avanzata, come code pesanti, asimmetrie o clustering della volatilità.

2.1 Descrizione dei dati




Figure 1: Serie temporale dei prezzi.

La Figura 1 evidenzia un comportamento dinamico che può essere suddiviso in due fasi principali: periodi di relativa stabilità e periodi di elevata volatilità.

Nel periodo iniziale, dal 2019 fino al 2020, i prezzi mostrano un andamento relativamente stabile, con variazioni contenute che riflettono una fase di equilibrio del mer-

cato. Tuttavia, a partire dal 2021, si osserva una forte volatilità, caratterizzata da numerosi punti di massimo ed uno di minimo tra il 2021 e il 2023. Questi movimenti estremi includono picchi significativi, seguiti da rapide correzioni al ribasso, che evidenziano l'incertezza del mercato. Questo comportamento è probabilmente legato a eventi geopolitici (come la crisi energetica europea) e dinamiche di mercato straordinarie che hanno sconvolto l'offerta e la domanda di gas naturale.

Successivamente, verso la fine del 2023 e l'inizio del 2024, si nota un ritorno a una fase di relativa stabilità, con oscillazioni più moderate rispetto al periodo di elevata volatilità. Questo suggerisce che il mercato potrebbe essere entrato in una fase di riequilibrio, anche se a prezzi medi più elevati rispetto al periodo pre-2021.




Figure 2: Serie temporale dei prezzi logaritmici (p_t).

Proseguendo, in Figura 2 è rappresentata la serie storica dei log-prezzi. La trasformazione logaritmica consente di analizzare meglio le variazioni relative e di attenuare l'impatto delle oscillazioni estreme, rendendo più chiara la dinamica della serie. Attraverso tale grafico è possibile osservare con maggiore facilità l'andamento di discesa del prezzo nel periodo 2019-2020, che anticipa il triennio di forte oscillazione già ampiamente presente nella serie originale.

In Tabella 1 riportiamo le principali statistiche descrittive della serie.

Statistica	Valore
Media	3.4265
Varianza	0.8522
Asimmetria	0.2874
Curtosi	2.5808

Table 1: Statistiche descrittive per i prezzi logaritmici (p_t).

La serie logaritmica dei prezzi p_t presenta una media di 3.4265, che corrisponde a

un livello medio di prezzo nella scala originale di circa 30.78 €/MWh. Questo valore riflette la persistenza di livelli di prezzo relativamente alti, soprattutto nel periodo post-2020, in linea con quanto osservato nel grafico. La varianza pari a 0.8522 evidenzia una significativa dispersione intorno alla media, attribuibile principalmente all'elevata volatilità registrata tra il 2021 e il 2023, quando i prezzi hanno subito forti oscillazioni in risposta a shock di mercato. L'aspetto più interessante riguarda l'asimmetria della distribuzione 0.2874, che suggerisce una leggera prevalenza di variazioni positive nei log-prezzi. Questo risultato è coerente con i numerosi rialzi marcati osservati nel periodo di alta volatilità, che hanno contribuito a spostare la distribuzione verso valori superiori. La curtosi pari a 2.5808, inferiore al valore tipico di una distribuzione normale (3), indica che la serie logaritmica è platycurtica, suggerendo una minore frequenza di eventi estremi o outlier. Questo risultato riflette il comportamento della serie logaritmica, che, pur mostrando volatilità elevata, non è dominata da variazioni estreme ricorrenti.




Figure 3: Serie temporale dei rendimenti logaritmici (y_t).

In Figura 3 osserviamo invece l'andamento dei rendimenti y_t , la quale consente di studiare le variazioni giornaliere della serie dei log-prezzi, eliminando l'effetto dei trend di lungo periodo e mettendo in evidenza la volatilità intrinseca del mercato. Osservando il grafico, si nota come i rendimenti oscillino attorno allo zero per gran parte del periodo considerato, confermando la loro natura stazionaria. Tuttavia, emergono fasi di forte volatilità che, come già ampiamente osservato attraverso i grafici precedenti, sono presenti principalmente durante il periodo del 2023 ed anche, in modo ridotto, a fine 2019.

Statistica	Valore
Media	0.00016
Varianza	0.0652
Asimmetria	0.4032
Curtosi	16.011

Table 2: Statistiche descrittive per i rendimenti logaritmici (y_t).

La Tabella 2 conferma quanto già analizzato, attraverso i valori delle principali statistiche descrittive della serie dei rendimenti. In particolare notiamo una media di 0.00016, che riflette una variazione giornaliera media prossima allo zero. Questo risultato è coerente con le proprietà teoriche delle serie di rendimenti finanziari, che tendono ad oscillare intorno a zero in condizioni di mercato stazionario. Tuttavia, valori così prossimi allo zero indicano anche che il mercato del gas naturale, pur mostrando periodi di elevata volatilità, non presenta tendenze direzionali dominanti nel periodo analizzato. La varianza pari a 0.0652 evidenzia una significativa dispersione attorno alla media, segno di elevata volatilità nella serie. Questo risultato è in linea con le osservazioni grafiche, che mostrano forti oscillazioni nei rendimenti, in particolare durante il 2023 e in misura minore alla fine del 2019. Tale volatilità riflette la sensibilità del mercato del gas naturale a eventi esogeni, come shock geopolitici e variazioni nella domanda e offerta. L'aspetto più interessante è rappresentato dall'elevata curtosi (16.011), che indica una marcata leptocurtosi della distribuzione dei rendimenti logaritmici. Questo valore evidenzia la presenza di code pesanti, ovvero una frequenza più alta di eventi estremi rispetto a una distribuzione normale. La leptocurtosi è una caratteristica comune delle serie finanziarie, in particolare in mercati soggetti a elevata volatilità, e suggerisce che la serie dei rendimenti logaritmici è influenzata da eventi occasionali di grande impatto, come picchi improvvisi o crolli significativi. Infine, l'asimmetria (0.4032) rivela una leggera tendenza della distribuzione a presentare code più pronunciate sul lato positivo. Questo risultato è coerente con l'osservazione di rialzi improvvisi durante i periodi di volatilità, in particolare nel 2023, e indica che, sebbene il mercato sia generalmente stazionario, le variazioni positive potrebbero essere leggermente più frequenti o intense rispetto a quelle negative.




Figure 4: Distribuzione dei rendimenti vs distribuzione Gaussiana.

La Figura 3.2 confronta la distribuzione empirica dei rendimenti logaritmici con una distribuzione normale (Gaussiana). Dal confronto emergono diverse caratteristiche distintive, che sono cruciali per comprendere le proprietà dei rendimenti e le loro implicazioni econometriche. La distribuzione empirica dei rendimenti presenta un picco centrale più alto rispetto alla distribuzione normale, suggerendo che la maggior parte dei rendimenti si concentra intorno alla media, evidenziando una bassa variabilità nei rendimenti medi. Tuttavia, questa concentrazione è accompagnata da code più lunghe e pesanti, indicative di una maggiore frequenza di eventi estremi, sia positivi che negativi, rispetto a quanto previsto dalla normale. Questo comportamento è coerente con la leptocurtosi osservata nelle statistiche descrittive, che riflette la prevalenza di grandi variazioni nei rendimenti. Un ulteriore aspetto rilevante è l'asimmetria positiva, visibile nel grafico attraverso una coda destra leggermente più pronunciata. Ciò implica che eventi estremi positivi sono più probabili di quelli estremi negativi, in contrasto con l'idea di una distribuzione perfettamente simmetrica. Questo risultato è particolarmente interessante per l'analisi del rischio, poiché suggerisce che il mercato può sperimentare picchi rialzisti in modo più frequente rispetto ai crolli. Inoltre, la presenza di code pesanti e di asimmetria sottolinea la necessità di modelli econometrici capaci di catturare queste peculiarità. Modelli basati esclusivamente sull'assunzione di normalità potrebbero sottostimare il rischio associato ai movimenti estremi del mercato. Di conseguenza, l'uso di distribuzioni alternative, come quella t-student, potrebbe essere più appropriato per modellare i rendimenti e la loro volatilità. In sintesi, il grafico evidenzia come i rendimenti logaritmici del gas naturale

deviano dalla normalità, mostrando concentrazione centrale, code pesanti e una leggera asimmetria. Queste proprietà saranno fondamentali da considerare nell'analisi successiva, in particolare nella modellazione della volatilità e nella previsione del rischio.

2.2 Analisi stazionarietà

h	pValue	stat	criticalValues
false	0.53742	-0.31269	-1.9416

Table 3: test ADF logp.

Il test ADF (Augmented Dickey-Fuller) è un test statistico utilizzato per verificare la stazionarietà di una serie temporale. La stazionarietà è una proprietà fondamentale in molte analisi delle serie temporali, in cui si richiede che la media, la varianza e la covarianza della serie siano costanti nel tempo. Il test ADF verifica se una serie temporale, nel nostro caso i prezzi logaritmici, ha una radice unitaria, che è una condizione associata alla non stazionarietà. In Tabella 3 l'elevato valore del p-value (0.53742) porta ad accettare l'ipotesi nulla del test, concludendo quindi che la serie dei log-prezzi del gas naturale è non stazionaria, come spesso accade per le serie finanziarie.

2.3 Analisi di autocorrelazione

L'analisi delle funzioni di autocorrelazione (ACF) e autocorrelazione parziale (PACF) dei rendimenti logaritmici y_t rappresenta un passaggio fondamentale per comprendere la dipendenza temporale e le dinamiche interne della serie. L'ACF misura il grado di correlazione tra i valori passati della serie fino a un determinato lag, mentre la PACF elimina l'effetto delle correlazioni intermedie, fornendo informazioni più precise sulla relazione diretta tra un valore e il suo lag.




Figure 5: ACF Rendimenti.




Figure 6: PACF Rendimenti.

Dall'analisi grafica della funzione di autocorrelazione globale e parziale della serie dei rendimenti giornalieri logaritmici (Figure 5 e 6), possiamo osservare la caratteristica prin-

cipale di questa serie finanziaria ovvero una stagionalità settimanale. Questo risultato è in linea con quanto osservato per altre serie energetiche dove i rendimenti sono fortemente legati all'andamento della domanda e dell'offerta. In particolare, per il gas naturale, la stagionalità settimanale potrebbe derivare dall'andamento ciclico della domanda di gas naturale, più elevata nei giorni feriali e meno durante il fine settimana (dove la maggior parte degli impianti industriali chiude e la domanda si limita maggiormente alla quota di consumo domestico).

2.4 Stima della densità spettrale

L'analisi della densità spettrale è utile nel caso in questione per analizzare la stagionalità della serie in quanto, essa misura il contributo di una componente ciclica (definita alla frequenza ω) alla variabilità della serie. Per stimarla utilizziamo lo stimatore di Bartlett di ampiezza $m=15$ (prendiamo quindi in considerazione solamente le prime 15 autocovarianze, per ottenere consistenza dello stimatore, pesate con pesi Kernell pari a $1-\tau/m$ per bilanciare la distorsione introdotta non considerando tutte le autocovarianze della serie).




Figure 7: Densità spettrale.

In figura 7 osserviamo la presenza di due picchi principali in corrispondenza delle frequenze (ω) 0,9 e 1,8 che corrispondono rispettivamente a un periodo di 7 e 3,5. Il ciclo di periodo 7, conferma quanto già detto in precedenza sulla stagionalità legata al giorno della settimana della serie dei rendimenti giornalieri logaritmici; mentre il ciclo di periodo 3,5 potrebbe essere interpretato come un'armonizzazione del ciclo settimanale a rappresentazione di variazioni intra-settimanali, come il passaggio da una domanda guidata dall'industria (inizio settimana) a una domanda più residenziale (fine settimana).

3 Modelli univariati

3.1 Introduzione sulla scelta del modello

In questa sezione, andremo a valutare diversi modelli ARIMA con disturbi modellati tramite diversi modelli di eteroschedasticità condizionata per la serie dei prezzi logaritmici p_t . Per la modellazione della media condizionata della serie, data la stagionalità settimanale che si evince dall'ACF dei rendimenti e dalla densità spettrale stimata mediante lo stimatore di Bartlett nel paragrafo precedente, utilizziamo un modello ARIMA stagionale (SARIMA). Quest'ultimo è un'estensione del modello ARIMA per analizzare e prevedere serie temporali che presentano caratteristiche stagionali. Il modello di seguito presentato è stato scelto a seguito del confronto tra diversi modelli SARIMA-GARCH sulla base dei criteri di informazione AIC e BIC (L'AIC fornisce una misura della qualità relativa di un modello statistico rispetto ad altri, penalizzando la complessità del modello per evitare il sovra-adattamento. Il BIC è più conservativo rispetto all'AIC nel penalizzare la complessità del modello. Il BIC tende a preferire modelli più semplici rispetto all'AIC, poiché introduce una penalizzazione maggiore per il numero di parametri). Il modello cattura la media condizionata della serie attraverso una differenziazione stagionale e un parametro di Media Mobile stagionale. La specificazione del modello è la seguente:

$$\text{SARIMA}(p,d,q)(P,D,Q,)(7)$$

- **p**: Ordine autoregressivo (AR). Indica il numero di osservazioni passate da includere per prevedere il valore attuale.
- **d**: Differenziazione (I). Rappresenta il numero di volte che i dati devono essere differenziati per renderli stazionari.
- **q**: Ordine della media mobile (MA). Indica il numero di errori passati da considerare per prevedere il valore attuale.
- **P**: Ordine stagionale autoregressivo (AR stagionale). Determina il numero di osservazioni stagionali passate da includere.
- **D**: Differenziazione stagionale (I stagionale). Indica quante volte bisogna differenziare i dati per eliminare la stagionalità.
- **Q**: Ordine stagionale della media mobile (MA stagionale). Indica il numero di errori stagionali passati da considerare.
- **m**: Periodo stagionale. Rappresenta il numero di osservazioni in un ciclo stagionale (ad esempio, 7 per dati giornalieri con stagionalità settimanale).

$$\Phi_P(L^s)\phi_p(L)(1-L)^d(1-L^s)^D y_t = \Theta_Q(L^s)\theta_q(L)\varepsilon_t$$

In particolare, il modello scelto è un SARIMA (1,0,2)(0,1,7)[7] dove avremo la parte non stagionale che coglie l'andamento della serie nel breve periodo e la parte stagionale

che coglie la ciclicità settimanale dei dati osservati (inoltre osserviamo come utilizziamo solo la differenziazione stagionale (D) e non quella non stagionale (d) per evitare una eccessiva differenziazione che porterebbe a stime instabili). Di seguito viene riportata la specificazione che modella la media condizionata:

$$(1 - \phi_1 L)(1 - L^7)y_t = (1 + \theta_1 L + \theta_2 L^2)(1 + \Theta_7 L^7)\xi_t$$

Per modellare la volatilità condizionata utilizziamo disturbi alternativamente GARCH, GJR-GARCH e EGARCH.

Il primo modello di eteroschedasticità condizionata considerato è il GARCH(1,1) specificato come segue (per la specificazione dei modelli, da ora in avanti si fa riferimento al modello SARIMA come prima specificato, con $\mu_{t|t-1}$):

$$y_t | Y_{t-1} \sim \mathcal{N}(\mu_{t|t-1}, h_t), \quad h_t = \text{Var}(y_t | Y_{t-1}) = \alpha_0 + \alpha_1 \xi_{t-1}^2 + \beta_1 h_{t-1}.$$

Equivalentemente:

$$y_t = \mu_{t|t-1} + \sqrt{h_t} \epsilon_t, \quad \epsilon_t \sim \text{i.i.d. } \mathcal{N}(0, 1),$$

$$h_t = \alpha_0 + \alpha_1 \xi_{t-1}^2 + \beta_1 h_{t-1},$$

con:

$$\alpha_0 > 0, \quad 0 \leq \alpha_1, \beta_1 < 1, \quad \alpha_1 + \beta_1 < 1.$$

Il primo modello stimato è quindi un SARIMA(1,0,2)(0,1,7)(7) con disturbi GARCH(1,1)

Di seguito sono riportate le stime:

ARIMA(1,0,2) Model Seasonally Integrated with Seasonal MA(7) (Gaussian Distribution)

Effective Sample Size 2223
Number of Estimated Parameters 7
Log-Likelihood 3732.93
AIC -7451.86
BIC -7411.91

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	0	0	NaN	NaN
AR{1}	0.98762	0.0030726	321.42	0
MA{1}	0.054383	0.022746	2.3908	0.01681
MA{2}	-0.10886	0.023594	-4.6139	3.9515×10^{-6}
SMA{7}	-0.88451	0.0078877	-112.14	0

GARCH(1,1) Conditional Variance Model (Gaussian Distribution)

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	4.1499×10^{-5}	8.4672×10^{-6}	4.9011	9.528×10^{-7}
GARCH{1}	0.84744	0.0088114	96.176	0
ARCH{1}	0.15256	0.0095164	16.031	7.7753×10^{-58}

Dalla stima si può notare come tutti i parametri siano statisticamente significativi (almeno con un livello di confidenza del 5%), questo indica una buona specificazione del

modello. In particolare, il parametro costante del modello di varianza condizionata (ω) è ≈ 0 , mentre la somma dei parametri ARCH (α_1) e GARCH (β_1) è ≈ 1 , tipico delle serie finanziarie.




Figure 8: ACF Residui standardizzati.




Figure 9: ACF Residui standardizzati al quadrato.

L'ACF dei residui standardizzati (Figura 8) mostra se il modello SARIMA ha catturato la media condizionata, mentre l'ACF dei residui standardizzati al quadrato (Figura 9) mostra se il modello GARCH ha colto il volatility clustering. Da entrambi i grafici osserviamo come non ci sia una significativa autocorrelazione, suggerendo che il modello ha rappresentato bene sia la media condizionata media condizionata e il volatility clustering.

Parameter	pValue	dEngle	dcrit
Value	0.17979	1.7994	3.8415

Table 4: ARCH Test residui standardizzati

L'ARCH test effettuato sui residui standardizzati del modello, come mostrato in Tabella 4, mostra l'assenza di eteroschedasticità condizionata nei residui standardizzati del modello (come mostrato dall'elevato p-value). Non ci sono evidenze di effetti GARCH residui e quindi il modello cattura bene il volatility clustering.

Parameter	pValue	QStatistic	CriticalValue
Value	0.27551	23.275	31.41

Table 5: LB test Res.Stand.²

Il test di Ljung-Box è stato effettuato sui residui standardizzati al quadrato del modello. Come mostrato nella Tabella 5, il p-value del test è pari a "0.27551", significativamente più alto rispetto ai livelli di significatività comuni (ad esempio, 0,05 o 0,01). Questo indica che non si può rifiutare l'ipotesi nulla, suggerendo l'assenza di autocorrelazione significativa nei residui standardizzati fino al lag considerato. Anche il basso valore del Q-statistic rispetto al valore critico supporta questa conclusione. Pertanto, il modello sembra aver catturato adeguatamente la dipendenza seriale nella volatilità dei dati.




Figure 10: Q-Q Plot dei residui standardizzati.

Come mostrato in Figura 10, il grafico Q-Q plot dei residui standardizzati rivela

alcune deviazioni dalla normalità, in particolare nelle code. Ciò suggerisce che, sebbene il modello catturi le dinamiche della serie, i residui potrebbero presentare code più pesanti rispetto alla distribuzione normale. Pertanto, potrebbe essere utile assumere una distribuzione alternativa che possa fornire un miglior adattamento (ad esempio, la distribuzione t di Student). Dato quest'ultimo risultato ristimiamo il modello SARIMA-GARCH(1,1) con distribuzione t-student; le stime sono le seguenti:

ARIMA(1,0,2) Model Seasonally Integrated with Seasonal MA(7) (t Distribution)

Effective Sample Size: 2223
Number of Estimated Parameters: 8
Log-Likelihood: 3847.06
AIC: -7678.12
BIC: -7632.47

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	0	0	NaN	NaN
AR{1}	0.99526	0.003194	311.6	0
MA{1}	0.043613	0.020742	2.1027	0.035493
MA{2}	-0.10037	0.02166	-4.6339	3.589×10^{-6}
SMA{7}	-0.87725	0.0082192	-106.73	0
DoF	3.8054	0.38748	9.8209	9.1562×10^{-23}

GARCH(1,1) Conditional Variance Model (t Distribution)

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	5.9517×10^{-5}	1.5952×10^{-5}	3.7309	0.00019081
GARCH{1}	0.86222	0.015907	54.204	0
ARCH{1}	0.13546	0.020352	6.6556	2.8223×10^{-11}
DoF	3.8054	0.38748	9.8209	9.1562×10^{-23}

Oltre ad osservare un incremento dei criteri di informazione che porterebbero a scegliere questo come miglior modello rispetto al precedente osserviamo che il parametro DoF (gradi di libertà) è significativo e pari a “3.8054”, suggerendo che la distribuzione t è più appropriata per catturare le code pesanti della distribuzione.

3.2 Fenomeno del Leverage

In questa sezione esploriamo se esistano prove grafiche o descrittive del fenomeno del leverage nella nostra serie temporale. Adattiamo i modelli di eteroschedasticità condizionata GJR-GARCH(1,1) ed EGARCH(1,1), utilizzando distribuzioni sia gaussiane che t di Student, e confrontiamo le deviazioni standard condizionate stimate con quelle ottenute dal modello GARCH(1,1) introdotto nella Sezione 2.

Il GJR-GARCH(1,1) estende il classico modello GARCH(1,1) aggiungendo il coefficiente “ α_1^- ” per tenere conto del segno del rendimento del periodo precedente “ y_{t-1} ”. La specificazione del modello è la seguente:

$$y_t = \mu_{t|t-1} + \sqrt{h_t} \epsilon_t, \quad \epsilon_t \sim \text{NID}(0, 1),$$

$$h_t = \alpha_0 + (\alpha_1 + \alpha_1^- I(\xi_{t-1} < 0)) \xi_{t-1}^2 + \beta_1 h_{t-1},$$

dove

$$\alpha_0 > 0, \quad \alpha_1, \beta_1 \geq 0, \quad \alpha_1 + \alpha_1^- > 0.$$

L'indicatore

$$I(\xi_{t-1} < 0)$$

assume valore 1 quando ξ_{t-1} è negativo e 0 altrimenti. Tale formulazione consente di modellare l'asimmetria della volatilità, ovvero una maggiore risposta della varianza ai rendimenti negativi rispetto a quelli positivi, un fenomeno noto come 'effetto leverage'. Il modello EGARCH(1,1) offre un'alternativa per modellare la volatilità, in cui il logaritmo della varianza condizionata viene utilizzato per garantire valori positivi senza imporre restrizioni sui parametri. La specificazione del modello è la seguente:

$$y_t \mid \mathcal{F}_{t-1} \sim \text{NID}(\mu_{t|t-1}, h_t),$$

$$\ln h_t = \alpha_0(1 - \alpha_1) + \alpha_1 \ln h_{t-1} + \theta \epsilon_{t-1} + \gamma \left(|\epsilon_{t-1}| - \sqrt{\frac{2}{\pi}} \right) = c + \alpha_1 \ln h_{t-1} + \theta \epsilon_{t-1} + \gamma |\epsilon_{t-1}|,$$

dove:

$$c = \alpha_0(1 - \alpha_1) - \gamma \sqrt{\frac{2}{\pi}}.$$

Questa formulazione consente di catturare sia l'effetto leverage che l'effetto size incorporando sia il segno dell'ultimo rendimento standardizzato osservato (tramite il coefficiente gamma) sia la sua dimensione (tramite il coefficiente teta).

Prima della stima dei modelli, è stata considerata la crosscorrelazione e il rapporto funzionale tra i rendimenti e il loro quadrato per verificare graficamente la presenza di leverage.




Figure 11: Cross-Correlazioni

La figura 11 mostra la cross correlazione tra rendimenti e rendimenti al quadrato. Se ci fosse effetto leverage il grafico delle crosscorrelazioni, dovrebbe presentare correlazioni ≈ 0 per i lag negativi e una correlazione negativa e decrescente all'aumentare dei lag positivi ovvero che, quando i rendimenti sono alti, i rendimenti al quadrato tendono ad essere più bassi, indicando una relazione inversa tra volatilità e rendimenti. Nel nostro caso, non è possibile osservare questa dinamica, infatti per ritardi positivi (lag > 0), dove

ci si aspetterebbe l'effetto leva (correlazioni negative), le crosscorrelazioni sono molto basse e spesso non significative e inoltre, per ritardi negativi ($\text{lag} < 0$), si osservano crosscorrelazioni diverse da 0. Nel complesso quindi, il grafico indica che l'effetto leva è molto debole o quasi assente in questa serie.




Figure 12: Volatility smile.

La Figura 12 mostra il c.d. "Volatility smile", ossia la relazione tra rendimenti e rendimenti al quadrato. In presenza di leverage la relazione funzionale tra i rendimenti e il loro quadrato dovrebbe mostrare il tipico andamento a forma di "V", che indica che sia i rendimenti positivi che quelli negativi sono associati a un aumento dei rendimenti al quadrato, il che implica una maggiore volatilità; in particolare l'asimmetria del rapporto funzionale in cui i rendimenti negativi portano a incrementi maggiori dei rendimenti al quadrato rispetto ai rendimenti positivi, è indicativa dell'effetto leva; che suggerisce che gli shock negativi (o i cali dei rendimenti) comportano aumenti più significativi della volatilità rispetto agli shock positivi di pari entità. Nel nostro caso, questo andamento asimmetrico non è così evidente il che conferma quanto detto in precedenza sulla presenza di un debole se non assente effetto leverage.

Inseriamo ora i modelli GJR-GARCH(1,1) e EGARCH(1,1) utilizzando sia le distribuzioni Gaussiane che t-student. L'obiettivo è quello di confermare l'eventuale presenza di leverage e confrontare i risultati con quelli ottenuti dal precedente modello GARCH (1,1).

ARIMA(1,0,2) Model Seasonally Integrated with Seasonal MA(7) (Gaussian Distribution)

Effective Sample Size: 2223
Number of Estimated Parameters: 8
Log-Likelihood: 3847.06
AIC: -7678.12
BIC: -7632.47

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	0	0	NaN	NaN
AR{1}	0.98768	0.003077	320.99	0
MA{1}	0.054345	0.022797	2.3839	0.01713
MA{2}	-0.10906	0.023635	-4.6145	3.9408×10^{-6}
SMA{7}	-0.88489	0.0078943	-112.09	0

GJR(1,1) Conditional Variance Model (Gaussian Distribution)

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	4.1525×10^{-5}	8.4725×10^{-6}	4.9012	9.5271×10^{-7}
GARCH{1}	0.8474	0.0088296	95.973	0
ARCH{1}	0.15151	0.012236	12.383	3.2484×10^{-35}
Leverage{1}	0.0021702	0.014533	0.14934	0.88129

ARIMA(1,0,2) Model Seasonally Integrated with Seasonal MA(7) (Gaussian Distribution)

Effective Sample Size: 2223
Number of Estimated Parameters: 8
Log-Likelihood: 3744.05
AIC: -7472.1
BIC: -7426.45

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	0	0	NaN	NaN
AR{1}	0.98936	0.0028944	341.81	0
MA{1}	0.046082	0.020422	2.2565	0.024038
MA{2}	-0.1076	0.021811	-4.9335	8.078×10^{-7}
SMA{7}	-0.89065	0.007469	-119.25	0

EGARCH(1,1) Conditional Variance Model (Gaussian Distribution)

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	-0.10697	0.024321	-4.3983	1.091×10^{-5}
GARCH{1}	0.97921	0.0040056	244.46	0
ARCH{1}	0.28708	0.015533	18.482	2.8824×10^{-76}
Leverage{1}	0.0041825	0.0087416	0.47847	0.63232

ARIMA(1,0,2) Model Seasonally Integrated with Seasonal MA(7) (t Distribution)

Effective Sample Size: 2223
Number of Estimated Parameters: 9
Log-Likelihood: 3847.08
AIC: -7676.16
BIC: -7624.8

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	0	0	NaN	NaN
AR{1}	0.99529	0.0031858	312.41	0
MA{1}	0.043604	0.020745	2.1019	0.035563
MA{2}	-0.10054	0.021654	-4.6428	3.4374×10^{-6}
SMA{7}	-0.8776	0.0082131	-106.85	0
DoF	3.8034	0.38723	9.8221	9.0477×10^{-23}

GJR(1,1) Conditional Variance Model (t Distribution)

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	5.9653×10^{-5}	1.599×10^{-5}	3.7306	0.00019102
GARCH{1}	0.86207	0.015958	54.022	0
ARCH{1}	0.1325	0.024261	5.4613	4.7261×10^{-8}
Leverage{1}	0.0063285	0.030506	0.20745	0.83566
DoF	3.8034	0.38723	9.8221	9.0473×10^{-23}

ARIMA(1,0,2) Model Seasonally Integrated with Seasonal MA(7) (t Distribution)

Effective Sample Size: 2223
Number of Estimated Parameters: 9
Log-Likelihood: 3851.24
AIC: -7684.49
BIC: -7633.13


Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	0	0	NaN	NaN
AR{1}	0.99509	0.0031117	319.79	0
MA{1}	0.038449	0.020155	1.9077	0.056428
MA{2}	-0.10149	0.021341	-4.7554	1.9808×10^{-6}
SMA{7}	-0.88041	0.0079632	-110.56	0
DoF	3.8465	0.40093	9.594	8.476×10^{-22}

EGARCH(1,1) Conditional Variance Model (t Distribution)

Parameter	Value	Standard Error	T-Statistic	P-Value
Constant	-0.13417	0.036019	-3.7251	0.00019522
GARCH{1}	0.97747	0.0058745	166.39	0
ARCH{1}	0.24671	0.027823	8.8671	7.5084×10^{-19}
Leverage{1}	0.0024828	0.017746	0.1399	0.88874
DoF	3.8465	0.40093	9.594	8.4762×10^{-22}

- **GJR(1,1) con distribuzione gaussiana:** Il parametro del leverage risulta essere particolarmente basso, e di conseguenza non ha un impatto significativo sul modello. Tale risultato è confermato anche dal valore del p-value, che risulta essere molto maggiore rispetto alla normale soglia di significatività di 0.05. Inoltre, l'assunzione gaussiana potrebbe non catturare i valori estremi in modo efficace, come indicato dalle performance del modello.
- **EGARCH(1,1) con distribuzione gaussiana:** Anche in questo caso, il coefficiente del leverage è molto basso e dall'analisi del p-value concludiamo che non è statisticamente significativo. I risultati sotto la distribuzione gaussiana sono in linea con quelli sotto la distribuzione t, ma il modello gaussiano potrebbe essere meno efficace nel catturare il comportamento delle code della distribuzione.
- **GJR(1,1) con distribuzione t-student:** Il parametro del leverage risulta essere basso; quindi, anche in questo caso l'effetto del leverage risulta essere praticamente assente. Il parametro DoF molto basso e significativo suggerisce che la distribuzione t-student è adatta per questo modello.
- **EGARCH(1,1) con distribuzione t-student:** Anche in questo caso, il coefficiente leverage non è statisticamente significativo. Il numero dei gradi di libertà basso e statisticamente significativo indica che la distribuzione t-student risulta essere più appropriata.

I modelli stimati sotto la distribuzione t generalmente offrono prestazioni migliori nel catturare la natura a code pesanti della distribuzione dei prezzi logaritmici. Sulla base dei criteri AIC e BIC, i modelli t-student risultano infatti essere migliori rispetto ai modelli con distribuzione gaussiana. Data però l'assenza di effetto leverage significativo, si può notare come sia nel caso gaussiano che nel caso t-student, sulla base dei criteri AIC e BIC, il modello SARIMA-GARCH(1,1) è preferibile al modello GJR-GARCH (che è una estensione del modello GARCH classico), mentre il modello EGARCH continua a essere superiore a entrambi: questo è dovuto probabilmente alla caratteristica del modello che data la sua particolare specificazione non necessita di restrizioni sui parametri da stimare. Possiamo ora quindi effettuare un confronto tra le deviazioni standard stimare tramite i modelli sopra presentati:



- **SARIMA-GARCH vs SARIMA-GJR-GARCH:** A causa dell'assenza di effetto leverage significativo, i due modelli producono stime della deviazione standard condizionata piuttosto simili.
- **SARIMA-EGARCH:** L'EGARCH modella la volatilità condizionata tramite il suo logaritmo, rendendo le stime della volatilità più stabili e meno soggette a esplosioni improvvise, rispetto ai modelli GARCH e GJR-GARCH, che invece modellano direttamente la varianza condizionata. Questo meccanismo, combinato all'assenza di effetto leverage, tende a "smorzare" i picchi estremi della volatilità, anche se questi sono molto elevati, e rende il modello meno sensibile agli shock violenti.




Figure 13: Analisi miglior modello

Di seguito un'analisi del miglior modello tra quelli presentati:

Rendimenti al quadrato (a): Il grafico dei rendimenti al quadrato mostra periodi di volatility clustering dove grandi variazioni nei rendimenti sono seguite da ulteriori grandi variazioni, e piccole variazioni sono seguite da piccole variazioni, come tipicamente accade nelle serie finanziarie.

Deviazione standard condizionata (b): Il grafico della deviazione standard condizionata cattura i picchi di volatilità osservati nella serie dei rendimenti logaritmici al quadrato della serie in analisi, dimostrando la capacità del SARIMA-EGARCH (t-student) di modellare l'eteroschedasticità condizionata.

4 Esperimento di previsione rolling dei prezzi

4.1 Rolling Forecast

Il Rolling Forecast è una tecnica in cui un modello viene stimato iterativamente su una finestra mobile di dati storici (rolling window). Questo è particolarmente utile per simulare la previsione in tempo reale, aggiornando il modello man mano che nuove informazioni diventano disponibili. Abbiamo effettuato un esperimento di previsione rolling dei prezzi del Gas naturale, con finestra mobile $n = 1500$ osservazioni consecutive, mediante il modello SARIMA-EGARCH con distribuzione t-student, e lo confrontiamo con le previsioni ottenute un periodo in avanti:

- Dal modello Random Walk stagionale, $P_{t+1|t} = P_{t-6}$, dove il valore previsto per il giorno successivo ($t + 1$) è basato sul valore osservato 7 giorni prima, data la stagionalità settimanale della serie;
- Dal modello AR(7), attraverso il quale la stima del valore P_{t+1} viene effettuata mediante un processo autoregressivo che tiene conto dei valori passati del Prezzo fino al suo settimo ritardo:

$$P_t = \phi_0 + \phi_1 P_{t-1} + \phi_2 P_{t-2} + \phi_3 P_{t-3} + \phi_4 P_{t-4} + \phi_5 P_{t-5} + \phi_6 P_{t-6} + \phi_7 P_{t-7} + \epsilon_t$$



Figure 14: Previsioni rolling dei prezzi vs Prezzi osservati.

La Figura 14 riporta il confronto delle previsioni dei Prezzi effettuate dai tre modelli considerati a confronto con i dati reali della serie finanziaria. Dal confronto grafico, il

modello SARIMA-EGARCH è quello che effettua previsioni che meglio si adattano alla serie originale, tranne nel picco dei Prezzi osservato nel 2023, a causa probabilmente dello scoppio della guerra in Ucraina, dove il modello SARIMA-EGARCH tende a sovrastimare i Prezzi stessi. Anche il modello AR (7) effettua previsioni che non si discostano fortemente dai reali dati osservati, performando meglio durante l'aumento dei Prezzi sopra descritto, ma meno in media, rispetto al SARIMA-EGARCH; infine, il modello RW stagionale risulta essere il peggiore fra i tre, infatti data la sua specificazione risulta avere una scarsa capacità predittiva nei cambiamenti di trend (le previsioni risultano infatti essere “ritardate” di una settimana rispetto a quelle effettuate dagli altri due modelli e rispetto alla serie originale).

4.2 Metriche di errore

Per valutare l'accuratezza delle previsioni dei vari modelli, usiamo le tre metriche di errore:

- **Errore quadratico medio di previsione (Mean Square Forecast Error, MSFE):** misura la media dei quadrati delle differenze tra i valori effettivi (y_t) e i valori previsti ($\hat{y}_t$)

$$\text{MSFE} = \frac{1}{m} \sum_{t=t_1}^{t_m} \left(P_{t+1} - \tilde{P}_{t+1|t} \right)^2$$

L'MSFE penalizza in maniera quadratica gli errori: errori più grandi hanno un impatto maggiore e per questo risulta sensibile agli outliers. L'MSFE ha un valore sempre positivo: più basso è il valore più le previsioni sono accurate.

Parameter	msfe_egarch	msfe_rw	msfe_ar7
Value	10.459	58.489	9.2865

Table 6: MSFE

- **Errore di previsione medio percentuale (Mean Percentage Error, MPE):** calcola l'errore medio in percentuale tra i valori osservati (y_t) e quelli previsti ($\hat{y}_t$) da un modello.

$$\text{MPE} = 100 \times \frac{1}{m} \sum_{t=t_1}^{t_m} \frac{P_{t+1} - \tilde{P}_{t+1|t}}{P_{t+1}}$$

L'MPE indica se, in media, il modello tende a sottostimare o sovrastimare i valori reali:

- $MPE > 0$: il modello tende a sottostimare i valori reali.
- $MPE < 0$: il modello tende a sovrastimare i valori reali.

Il limite di questa metrica di errore è che poiché gli errori possono essere sia positivi che negativi, possono annullarsi tra loro, dando un valore di MPE basso anche se il modello non è accurato; per questo generalmente viene presentato insieme ad altre metriche come l'MSFE e il MAPE.

Parameter	mpe_egarch	mpe_rw	mpe_ar7
Value	-0.087833	-0.97586	-0.26917

Table 7: MPE

- **Errore assoluto medio percentuale (Mean Absolute Percentage Error, MAPE):** misura l'errore medio in termini percentuali rispetto ai valori osservati. Viene calcolato come la media del valore assoluto delle differenze tra valori osservati e previsti, rapportate ai valori osservati stessi.

$$\text{MAPE} = 100 \times \frac{1}{m} \sum_{t=t_1}^{t_m} \frac{|P_{t+1} - \tilde{P}_{t+1|t}|}{P_{t+1}}$$

Il MAPE, esprimendo l'errore medio in termini percentuali, è facilmente interpretabile e rende più agevoli le comparazioni tra modelli diversi: un valore più basso del MAPE indica previsioni più precise; inoltre, è meno sensibile agli outliers rispetto all'MSFE e, utilizzando i valori assoluti, fa sì che gli errori positivi e negativi non si annullino tra loro (come accade nel MPE).

Parameter	mape_egarch	mape_rw	mape_ar7
Value	3.2618	8.5479	3.5179

Table 8: MAPE

Di seguito una analisi dei risultati ottenuti per ognuno dei tre modelli messi a confronto (SARIMA-EGARCH, RW stagionale e AR (7)) : come emerge dai per la prima metrica in questione, cioè l'MSFE riportato in Tabella 6, il miglior modello risulterebbe essere l'AR(7), mentre per le altre due metriche (MPE e MAPE, riportate in Tabella 7 e in Tabella 8) il modello migliore è il SARIMA-EGARCH. Con riferimento all'MSFE probabilmente viene preferito il modello AR rispetto al modello SARIMA a causa della caratteristica della metrica di penalizzare fortemente grandi errori di stima (elevandoli al quadrato) e risultando anche più sensibile alla presenza di outliers: il risultato riflette la quindi la sovrastima dei prezzi effettuata dal modello SARIMA, rispetto al modello AR(7), durante l'impennata dei prezzi nel 2023. L'MPE invece suggerisce che il miglior modello è il SARIMA con disturbi EGARCH, infatti, ha un valore più vicino allo zero rispetto a quello ottenuto con gli altri due modelli; da questa metrica osserviamo inoltre come tutti e tre i modelli tendono a sovrastimare i valori reali dato l'MPE negativo in tutti e tre i casi. Infine, il MAPE , conferma il SARIMA-EGARCH come miglior modello previsionale tra quelli in analisi; infatti, il valore del MAPE del modello è quello più vicino allo zero e pari a 3.2616 indicando che le previsioni si discostano in media $\approx 3\%$ dai valori reali. Il modello Random Walk stagionale risulta essere il peggiore per tutte le metriche considerate, avendo quindi minore capacità predittiva rispetto agli altri due modelli, risultato che era già stato ipotizzato nell'analisi grafica delle previsioni.

A supporto dei risultati numerici, viene fornita l'analisi grafica degli errori di previsione:




Figure 15: Errori di previsione.

Dalla Figura 15 si evince che il SARIMA-EGARCH è il modello che fornisce previsioni più accurate in media, poiché presenta errori piccoli e stabili, ma come già detto in precedenza, presenta elevati errori di stima negativi (sovrastima) durante il periodo di elevata volatilità dei prezzi. L'AR (7) è risulta essere un buon compromesso ma commettendo in media più errori rispetto al modello SARIMA con disturbi egarch. Come avevamo già anticipato, il RW stagionale è il modello meno performante, mostra errori elevati e instabili, specialmente durante i periodi di alta volatilità.

5 Conclusioni

In questo studio, l'analisi della serie storica MPG-GAS ha permesso di approfondire le caratteristiche statistiche dei prezzi del gas naturale nel contesto del mercato italiano. Attraverso l'analisi della stagionalità e della volatilità, si è evidenziato come i prezzi del gas siano influenzati sia da dinamiche interne al mercato (come per esempio la ciclicità della Domanda di gas) che da fattori esterni, quali variazioni internazionali e condizioni geopolitiche (come per esempio lo scoppio della guerra in Ucraina nel 2022).

L'applicazione di modelli SARIMA combinati con diverse specificazioni di eteroschedasticità condizionata (GARCH, GJR, EGARCH) ci hanno permesso di modellare la serie dei prezzi logaritmici date le sue caratteristiche. La scelta di una distribuzione t di Student si è rivelata utile per catturare la presenza di code pesanti nei dati, mentre la modellazione della stagionalità settimanale ha contribuito a una descrizione più accurata delle dinamiche dei prezzi.

L'esperimento di previsione rolling ha permesso di confrontare il modello selezionato come migliore fra quelli stimati, con approcci alternativi come il Random Walk stagionale e il modello AR(7). I risultati ottenuti attraverso metriche di errore come MSFE, MPE e MAPE hanno evidenziato le potenzialità e i limiti di ciascuna strategia previsiva. In particolare, il modello proposto ha dimostrato una maggiore capacità di adattarsi alla struttura dinamica dei prezzi rispetto ai metodi più semplici.

Questa analisi offre strumenti utili per comprendere meglio le dinamiche del mercato del gas e per sviluppare approcci previsivi efficaci. Tuttavia, una modellazione più approfondita potrebbe includere l'integrazione di variabili esogene, come prezzi internazionali, shock geopolitici o dati meteorologici, per migliorare ulteriormente la capacità dei modelli di spiegare e prevedere l'andamento dei prezzi.

A Appendice: Codice Matlab

Listing 1: Il tuo codice MATLAB

```
1 clear all
2 TT = readtimetable("MPG_GAS.xlsx");
3 vp = TT.vp; % prezzi
4 vdates = TT.Time;
5 y = log(vp); %p logaritmici
6 dy = diff(y); %rendimenti
7
8 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
9 %ANALISI DESCRITTIVA
10
11 %grafico prezzi
12 figure ;
13 plot (vdates , vp );
14 xlabel ('Date');
15 ylabel ('P');
16 title ('Time_Series_of_Natural_Gas_prices');
17
18 %grafico log-p
19 logp = y;
20 figure ;
21 plot (vdates , logp);
22 xlabel ('Dates');
23 ylabel ('Log_p');
24 title ('Time_Series_of_Natural_Gas_log-Prices');
25
26 %grafico rendimenti
27 figure ;
28 plot (vdates(2:end,1) , dy);
29 xlabel ('Dates');
30 ylabel ('Returns');
31 title ('Time_Series_of_Natural_Gas_Rerturns');
32
33 % Calculate statistical measures
34 mean_dy = mean(dy);
35 sd_dy = std(dy);
36 ku_dy = kurtosis(dy);
37 sk_dy = skewness(dy);
38
39 mean_logp = mean(y);
40 sd_logp = std(y);
41 ku_logp = kurtosis(y);
42 sk_logp = skewness(y);
43 % Display the results in a table
44 disp ( table ( mean_logp , sd_logp , ku_logp , sk_logp));
45 disp ( table ( mean_dy , sd_dy , ku_dy , sk_dy));
46
47 % Check for asymmetry ( Skewness )
48 if sk_dy > 0
```

```

49 fprintf ('The distribution is right-skewed.\n');
50 elseif sk_dy < 0
51 fprintf ('The distribution is left-skewed.\n');
52 else
53 fprintf ('The distribution is symmetric.\n');
54 end
55
56 % Check for asymmetry ( Skewness )
57 if sk_logp > 0
58 fprintf ('The distribution is right-skewed.\n');
59 elseif sk_logp < 0
60 fprintf ('The distribution is left-skewed.\n');
61 else
62 fprintf ('The distribution is symmetric.\n');
63 end
64 % Check for heavy tails ( Kurtosis )
65 if ku_dy > 3
66 fprintf ('The distribution has heavier tails than a normal
distribution (Leptokurtic).\n');
67 elseif ku_dy < 3
68 fprintf ('The distribution has lighter tails than a normal
distribution (Platykurtic).\n');
69 else
70 fprintf ('The distribution has normal kurtosis (Mesokurtic).\n'
);
71 end
72
73 % Check for heavy tails ( Kurtosis )
74 if ku_logp > 3
75 fprintf ('The distribution has heavier tails than a normal
distribution (Leptokurtic).\n');
76 elseif ku_logp < 3
77 fprintf ('The distribution has lighter tails than a normal
distribution (Platykurtic).\n');
78 else
79 fprintf ('The distribution has normal kurtosis (Mesokurtic).\n'
);
80 end
81
82 figure ;
83 histfit (dy , 150) ;
84 xlabel ('Returns');
85 ylabel ('Absolute Frequency');
86 title ('Returns distribution vs Gaussian distribution');
87
88 %rendimenti ^2 e in valore assoluto
89 dy_2 = dy.^2;
90 dy_abs = abs(dy);
91 figure;
92 plot(vdates(2:end,1),dy_2)
93 figure;

```

```

94 plot(vdates(2:end),1),dy_abs)
95 figure;
96 subplot(2,1,1)
97 autocorr(dy_2,'NumLags',40)
98 subplot(2,1,2)
99 autocorr(dy_abs,'NumLags',40)
100
101 figure;
102 autocorr(dy,'NumLags',40)
103 figure;
104 parcorr(dy,'NumLags',40)
105
106
107
108 [h, pValue, stat, criticalValues] = adftest(logp);
109 % Visualizzare i risultati
110 disp('Risultati del test ADF:');
111 disp(['Decisione H: ', num2str(h)]); % h = 1 indica che la serie
    stazionaria, 0 non lo
112 disp(['P-Value: ', num2str(pValue)]);
113 disp(['Statistica del test: ', num2str(stat)]);
114 disp('Valori critici:');
115 disp(criticalValues);
116 disp(table(h, pValue, stat, criticalValues));
117
118
119 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
120 %VARIANCE RATIO
121 y = log(vp);
122 dy = diff(y);
123 n = length(dy);
124 g0 = fautocovariance(dy, 0); % var(y,1)
125 maxK = floor(n^0.33);
126 vVarRatio = NaN(1, maxK);
127 for kval = 1:maxK
128     dnum = 2* pi * fBartlettSpectralDensityEst(dy, kval+1, 0);
129     vVarRatio(kval) = dnum / g0;
130 end
131
132 plot(2:maxK+1, vVarRatio, 'LineWidth', 2, 'Marker','o'); %
    vVarRatio contains [Vhat_2, Vhat_3, ..., Vhat_maxK]
133 ylim([0.5 1.2])
134 line([2,maxK+1],[1,1], 'Color','red', 'LineStyle','--')
135
136 kvalues = 2:maxK;
137 K = length(kvalues);
138 [~, pValue, stat, ~, VR] = vratiotest(y,'period',kvalues,'IID',
    false(1,K));
139
140 plot(kvalues, pValue, 'red*'); hold off;
141 %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%

```



```

142 %STIMATORE DI BARTLETT
143 m = 15; % Lunghezza della finestra di Bartlett
144 omega = linspace(0, pi, 1000); % Frequenze per lo spettro
145
146 % Stima della densit  spettrale
147 sdf = arrayfun(@(w) fBartlettSpectralDensityEst(dy, m, w), omega)
148 ;
149 plot(omega, sdf);
150 xlabel('\omega');
151 ylabel('Densit  spettrale');
152 title('Stima della densit  spettrale con finestra di Bartlett m
153 =15');
154
155 function gamma = fAutocovarianceFunction(y, m)
156 % Calcola l'autocovarianza fino al lag m
157 n = length(y);
158 y_mean = mean(y);
159 gamma = zeros(m + 1, 1); % Include lag 0 fino a lag m
160 for k = 0:m
161     gamma(k + 1) = sum((y(1:end-k) - y_mean) .* (y(k+1:end) -
162         y_mean)) / n;
163 end
164 end
165
166 function sdf = fBartlettSpectralDensityEst(y, m, omega)
167 % Calcola la densit  spettrale con una finestra di Bartlett
168 gamma = fAutocovarianceFunction(y, m); % Funzione di
169 autocovarianza
170 sdf = gamma(1); % Inizia con il valore a lag 0
171 for k = 1:m
172     bartlett_weight = (m - k) / m; % Peso della finestra di
173     Bartlett
174     sdf = sdf + 2 * bartlett_weight * gamma(k + 1) * cos(
175         omega * k);
176 end
177 sdf = sdf / (2 * pi); % Normalizzazione
178 end
179
180 %%
181 % MODELLI SARIMA-GARCH
182 CondVarMdl_1 = garch(1,1);
183 Mdl_1 = arima('Constant',0,'ARLags',1,'D',0,'MALags',1:2,'
184     Seasonality',7,'SMALags',7,'Variance',CondVarMdl_1);
185 [EstMdl_1,EstParamCov_1,~,~] = estimate(Mdl_1, y); %stima modello
186 summarize(EstMdl_1); %parametri modello
187 [res_1,h_1,logL_1] = infer(EstMdl_1, y); %residui e stima
188 volatilit
189 ve_1 = res_1 ./ sqrt(h_1); %residui standardizzati
190 [~, p_value_1, dEngle, dcrit] = archtest(ve_1); %arch test
191 modello 1

```

```

184 figure;
185 autocorr(ve_1,'NumLags',40) %autocorrelazione residui stand.
186 title('Autocorrelazione_residui')
187 figure;
188 autocorr(ve_1.^2,'NumLags',40) %autocorrelazione residui stand.^2
189 title('Autocorrelazione_residui^2')
190 [~, pValue_1, stat_1, criticalValue_1] = lbqtest(ve_1.^2); %LB
    test per resisui^2
191 table(pValue_1, stat_1, criticalValue_1)
192 figure;
193 qqplot(ve_1);
194 title ('Q-Q_Plot_Residui_standardizzati_modello_GARCH(1,1)');
195
196 %LEVERAGE
197 dy_2 = dy.^2;
198 figure(); plot(dy(1:end-1), dy_2(2:end), '.')
199 vfit = smooth(dy(1:end-1), dy_2(2:end), 0.95, 'loess'); %
    nonparametric regression function
200 figure(); plot(dy(1:end-1), dy_2(2:end), 'b.', dy(1:end-1), vfit,
    'r*'); %grafico volatility smile e rendimenti
201 figure(); plot(dy(1:end-1),vfit, 'r*'); %grafico solo volatility
    smile
202 crosscorr(dy, dy_2)
203
204 %GJR-GARCH
205 CondVarMdl_2 = gjr(1,1);
206 Mdl_2 = arima('Constant',0,'ARLags',1,'D',0,'MALags',1:2,'
    Seasonality',7,'SMALags',7,'Variance',CondVarMdl_2);
207 [EstMdl_2,EstParamCov_2,~,~] = estimate(Mdl_2, y); %stima modello
208 summarize(EstMdl_2); %parametri modello
209 [res_2,h_2,logL_2] = infer(EstMdl_2, y); %residui e stima
    volatilit
210 ve_2 = res_2 ./ sqrt(h_2); %residui standardizzati
211 [~, p_value_2, dEngle, dcrit] = archtest(ve_2); %arch test
    modello 2
212 figure;
213 autocorr(ve_2,'NumLags',40) %autocorrelazione residui stand.
214 title('Autocorrelazione_residui_standardizzati')
215 figure;
216 autocorr(ve_2.^2,'NumLags',40) %autocorrelazione residui stand.^2
217 title('Autocorrelazione_residui^2')
218 [~, pValue_2, stat_2, criticalValue_2] = lbqtest(ve_2.^2); %LB
    test per resisui^2
219 table(pValue_2, stat_2, criticalValue_2)
220 figure;
221 qqplot(ve_2);
222 title ('Q-Q_Plot_Residui_standardizzati_modello_GJR(1,1)');
223
224 %EGARCH
225 CondVarMdl_3 = egarch(1,1);

```

```

226 Mdl_3 = arima('Constant',0,'ARLags',1,'D',0,'MALags',1:2,'
      Seasonality',7,'SMA Lags',7,'Variance',CondVarMdl_3);
227 [EstMdl_3,EstParamCov,~,~] = estimate(Mdl_3, y); %stima modello
228 summarize(EstMdl_3); %parametri modello
229 [res_3,h_3,logL_3] = infer(EstMdl_3, y); %residui e stima
      volatilit
230 ve_3 = res_3 ./ sqrt(h_3); %residui standardizzati
231 [~, p_value_3, dEngle, dcrit] = archtest(ve_3); %arch test
      modello 2
232 figure;
233 autocorr(ve_3,'NumLags',40) %autocorrelazione residui stand.
234 title('Autocorrelazione_residui_standardizzati')
235 figure;
236 autocorr(ve_3.^2,'NumLags',40) %autocorrelazione residui stand.^2
237 title('Autocorrelazione_residui^2')
238 [~, pValue_3, stat_3, criticalValue_3] = lbqtest(ve_3.^2); %LB
      test per resisui^2
239 table(pValue_3, stat_3, criticalValue_3)
240 figure;
241 qqplot(ve_3);
242 title ('Q-Q_Plot_Residui_standardizzati_modello_GJR(1,1)');
243
244 %GARCH T-STUDENT
245 CondVarMdl_4 = garch(1,1);
246 CondVarMdl_4.Distribution = "t";
247 Mdl_4 = arima('Constant',0,'ARLags',1,'D',0,'MALags',1:2,'
      Seasonality',7,'SMA Lags',7,'Variance',CondVarMdl_4);
248 [EstMdl_4,EstParamCov_4,~,~] = estimate(Mdl_4, y); %stima modello
249 summarize(EstMdl_4); %parametri modello
250 [res_4,h_4,logL_4] = infer(EstMdl_4, y); %residui e stima
      volatilit
251 ve_4 = res_4 ./ sqrt(h_4); %residui standardizzati
252
253 %GJR T-STUDENT
254 CondVarMdl_5 = gjr(1,1);
255 CondVarMdl_5.Distribution = "t";
256 Mdl_5 = arima('Constant',0,'ARLags',1,'D',0,'MALags',1:2,'
      Seasonality',7,'SMA Lags',7,'Variance',CondVarMdl_5);
257 [EstMdl_5,EstParamCov_5,~,~] = estimate(Mdl_5, y); %stima modello
258 summarize(EstMdl_5); %parametri modello
259 [res_5,h_5,logL_5] = infer(EstMdl_5, y); %residui e stima
      volatilit
260 ve_5 = res_5 ./ sqrt(h_5); %residui standardizzati
261
262 %EGARCH T-STUDENT
263 CondVarMdl_6 = egarch(1,1);
264 CondVarMdl_6.Distribution = "t";
265 Mdl_6 = arima('Constant',0,'ARLags',1,'D',0,'MALags',1:2,'
      Seasonality',7,'SMA Lags',7,'Variance',CondVarMdl_6);
266 [EstMdl_6,EstParamCov_6,~,~] = estimate(Mdl_6, y); %stima modello
267 summarize(EstMdl_6); %parametri modello

```

```

268 [res_6,h_6,logL_6] = infer(EstMdl_6, y); %residui e stima
      volatilit
269 ve_3 = res_6 ./ sqrt(h_6); %residui standardizzati
270
271 %Grafico per il miglior modello
272 figure('Name', 't-student_Egarch(1,1)');
273 subplot(2,1,1), plot(vdates(2:end), dy.^2); title('Rendimenti^2')
274 subplot(2,1,2), plot(vdates(2:end),sqrt(h_6(2:end)), 'r'); title(
      'Deviazione_Standard_stimata_con_EGARCH')
275
276 %Grafico confronto deviazioni standard dei modelli stimati
277 figure;
278 subplot (3, 2, 1) , plot (vdates , sqrt(h_1),'r');
279 title ('Conditional_Standard_Deviations_GARCH');
280 xlabel('Dates'); ylabel ('\sigma');
281 subplot (3, 2, 2) , plot(vdates , sqrt(h_4) , 'r');
282 title ('Conditional_Standard_Deviations_t-student_GARCH');
283 xlabel('Dates'); ylabel ('\sigma');
284 subplot(3, 2, 3) , plot(vdates , sqrt(h_2), 'b' );
285 title ('Conditional_Standard_Deviations_GJR-GARCH');
286 xlabel ('Dates'); ylabel ('\sigma');
287 subplot (3, 2, 4) , plot (vdates , sqrt(h_5), 'b');
288 title ('Conditional_Standard_Deviations_t-student_GJR-GARCH');
289 xlabel ('Dates'); ylabel ('\sigma');
290 subplot (3, 2, 5) , plot (vdates , sqrt(h_3), 'g');
291 title ('Conditional_Standard_Deviations_E-GARCH');
292 xlabel ('Dates'); ylabel ('\sigma');
293 subplot (3, 2, 6) , plot (vdates , sqrt(h_6), 'g');
294 title ('Conditional_Standard_Deviations_t-student_E-GARCH');
295 xlabel ('Dates'); ylabel ('\sigma');
296
297 %%
298 %PREVISIONI
299 cn = length(y); % sample size
300 cT = 1500; % Lunghezza della finestra temporale rolling
301 cm = cn - cT - 1; % Numero di iterazioni (rolling forecast)
302 CondVarMdl_6 = egarch(1,1);
303 CondVarMdl_6.Distribution = "t";
304 Mdl_6 = arima('Constant',0,'ARLags',1,'D',0,'MALags',1:2,'
      Seasonality',7,'SMALags',7,'Variance',CondVarMdl_6);
305 Mdl_7 = arima('ARLag',1:7);
306 for i = 0:cm-1
307     vyr = y(i+1:cT+i); % rolling sample
308     if any(i== 0:30:cm)
309         [EstMdl_egarch,~,~,~] = estimate(Mdl_6, vyr);
310     end
311     [forecast_1,~,~] = forecast(EstMdl_egarch, 1,'Y0',vyr);
312     forecast_egarch(i+1) = exp(forecast_1);
313
314 % Modello Random Walk Stagionale (RW)
315 forecasts_rw(i+1) = exp(y(cT + i - 6));

```

```

316
317     if any(i== 0:30:cm)
318         [EstMdl_AR, ~, ~] = estimate(Mdl_7, vyr);
319     end
320     [forecast_3,~,~]= forecast(EstMdl_AR, 1, 'Y0', vyr);
321     forecasts_ar7(i+1) = exp(forecast_3);
322 end
323
324
325 % Creazione del grafico delle previsioni
326 figure;
327 plot(vdates(cT+1:end-1),forecast_egarch, 'b', 'DisplayName', '
    SARIMA-EGARCH'); % Previsioni EGARCH
328 hold on;
329 plot(forecasts_rw, 'r', 'DisplayName', 'RW_Stagionale'); %
    Previsioni RW
330 hold on;
331 plot(forecasts_ar7, 'g', 'DisplayName', 'AR(7)'); % Previsioni AR
    (7)
332 hold on
333 plot (exp(y(cT+1:cT+cm)), 'y','DisplayName', 'Actual_Gas_Prices')
    ;
334 legend('show');
335 title('Previsioni_dei_Prezzi');
336 xlabel('Tempo');
337 ylabel('Previsioni');
338 grid on;
339
340 %metriche di performance
341 p_actual = exp(y(cT+1:cT+cm));
342 p_actual_trasposto = p_actual';
343
344 t1 = 1; % Indice della prima previsione
345 tm = cm; % Indice dell'ultima previsione
346 m = length(t1:tm);
347
348 % Errore quadratico medio di previsione (MSFE)
349 msfe_egarch = sum((p_actual_trasposto - forecast_egarch).^2) / m;
350 msfe_rw = sum((p_actual_trasposto - forecasts_rw).^2) / m;
351 msfe_ar7 = sum((p_actual_trasposto - forecasts_ar7).^2) / m;
352
353 % Errore di previsione medio percentuale (MPE)
354 mpe_egarch = 100 * sum((p_actual_trasposto - forecast_egarch) ./
    p_actual_trasposto) / m;
355 mpe_rw = 100 * sum((p_actual_trasposto - forecasts_rw) ./
    p_actual_trasposto) / m;
356 mpe_ar7 = 100 * sum((p_actual_trasposto - forecasts_ar7) ./
    p_actual_trasposto) / m;
357
358 % Errore assoluto medio percentuale (MAPE)

```

```

359 mape_egarch = 100 * sum(abs((p_actual_trasposto - forecast_egarch
    ) ./ p_actual_trasposto)) / m;
360 mape_rw = 100 * sum(abs((p_actual_trasposto - forecasts_rw) ./
    p_actual_trasposto)) / m;
361 mape_ar7 = 100 * sum(abs((p_actual_trasposto - forecasts_ar7) ./
    p_actual_trasposto)) / m;
362
363 % Visualizzazione dei risultati
364 fprintf('MSFE_□EGARCH:□%.4f\n', msfe_egarch);
365 fprintf('MSFE_□RW:□%.4f\n', msfe_rw);
366 fprintf('MSFE_□AR(7):□%.4f\n', msfe_ar7);
367 disp(table(msfe_egarch,msfe_rw,msfe_ar7))
368
369 fprintf('MPE_□EGARCH:□%.4f\n', mpe_egarch);
370 fprintf('MPE_□RW:□%.4f\n', mpe_rw);
371 fprintf('MPE_□AR(7):□%.4f\n', mpe_ar7);
372 disp(table(mpe_egarch,mpe_rw,mpe_ar7))
373
374
375 fprintf('MAPE_□EGARCH:□%.4f\n', mape_egarch);
376 fprintf('MAPE_□RW:□%.4f\n', mape_rw);
377 fprintf('MAPE_□AR(7):□%.4f\n', mape_ar7);
378 disp(table(mape_egarch,mape_rw,mape_ar7))
379
380 %errori di previsione
381 ve1 = p_actual_trasposto - forecast_egarch; % forecast errors
    method 1
382 ve2 = p_actual_trasposto - forecasts_rw; % forecast errors
    method 2
383 ve3 = p_actual_trasposto - forecasts_ar7;% forecast errors
    method 3
384 figure();
385 plot(vdates(cT+1:end-1),ve1)
386 hold on
387 plot(ve2),
388 hold on
389 plot(ve3);
390 legend('SARIMA-EGARCH', 'RW', 'AR')

```