



TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

LAUREA MAGISTRALE IN

**ECONOMIA DEI MERCATI E
DEGLI INTERMEDIARI
FINANZIARI**

Approvazione del prestito: un'analisi tramite regressione logistica

Quali fattori influenzano l'esito di una richiesta di credito?

Professore:

Giovanni Trovato

Studente:

Marco Soriano

a.a 2024/2025

Sommario

1. Introduzione	2
2. Analisi descrittiva del dataset completo	2
3. Regressione logistica	8
3.1. Applicazione del modello logit e ottimizzazione	9
4. Analisi di robustezza del modello logit	11
4.1. Analisi sul dataset completo	13
5. Conclusioni	14
Appendice Codice Rstudio	15
Bibliografia e sitografia	21


1. Introduzione

L'accesso al credito è un elemento centrale nei sistemi economici moderni. L'approvazione o il rifiuto di una richiesta di prestito dipende da molteplici fattori legati al profilo del richiedente, alla sua affidabilità creditizia e alla natura del prestito richiesto. L'obiettivo di questo lavoro è analizzare i fattori che influenzano l'approvazione di un prestito mediante un modello di regressione logistica. L'analisi si basa su un dataset che simula dati reali sul rischio di credito, ampliato con ulteriori variabili legate al profilo finanziario dei richiedenti. Per aumentare il numero di osservazioni, è stato impiegato l'algoritmo SMOTENC. Sarà possibile identificare i fattori più significativi che influenzano la probabilità di approvazione, offrendo spunti utili anche per il miglioramento dei processi di credit scoring.


2. Analisi descrittiva del dataset completo

Il dataset analizzato è composto da 14 variabili contenenti 45.000 osservazioni relative a richieste di prestito. Le variabili disponibili descrivono il profilo anagrafico, finanziario e creditizio di ciascun soggetto. Il dataset è stato filtrato rimuovendo osservazioni con dati mancanti e gli outlier relativi alla variabile *person_gender*. Poiché il dataset è simulato, sono emersi tali valori anomali legati all'età del richiedente. In questo modo il dataset filtrato contiene 44.993 osservazioni. Il nostro focus sarà la variabile *loan_status*, che assume valore 1 se il prestito è stato approvato e 0 altrimenti. Di seguito presentiamo le principali variabili prese in considerazione per la costruzione del nostro modello.


- *person_age*: età del richiedente. Il campione mostra una distribuzione omogenea con una media intorno ai 34 anni. Il valore minimo è pari a 20 anni mentre quello massimo è pari a 94.
- *person_gender*: genere del richiedente, con una suddivisione tra uomini e donne equilibrata nel dataset. il 45% dei soggetti presenti in questo campione sono donne, il 55% sono uomini.
- *person_education*: titolo di studio. Le categorie presenti sono *High School*, *Bachelor*, *Master*, *Doctorate* e *Other*. La maggior parte dei soggetti ha conseguito un titolo universitario di primo livello (*Bachelor*, 29,78%) o un diploma tecnico (*Associate*, 26,73%). Una quota simile (26,60%) ha un titolo di scuola superiore (*High School*), mentre percentuali più ridotte si riscontrano tra coloro con un titolo di *Master* (15,51%) e di *Dottorato* (1,38%).



- *person_income*: reddito annuale dichiarato dal richiedente. Il reddito medio è pari a 79.908 dollari, con una forte variabilità (deviazione standard $\approx 63.322.13$). Il valore minimo osservato è di 8.000 dollari, mentre il massimo raggiunge 2.448.661 dollari. La mediana è di 67.048 dollari.
- *person_emp_exp*: anni di esperienza lavorativa. I soggetti hanno in media 5,4 anni di esperienza lavorativa. Il minimo è 0 anni, mentre il massimo raggiunge i 76. Una maggiore esperienza può indicare maggiore stabilità occupazionale.
- *person_home_ownership*: descrive la condizione abitativa del richiedente. La maggior parte del campione vive in affitto (52,10%), seguita da coloro che possiedono un'abitazione con un mutuo in corso (41,09%). Solo una piccola parte (6,56%) detiene un'abitazione di proprietà piena (*OWN*), mentre il restante 0,26% rientra in altre categorie (*OTHER*). Dal grafico si evince come solo una piccola percentuale del campione risulta essere proprietaria della propria abitazione.




- *loan_amnt*: ammontare del prestito richiesto. Il prestito medio richiesto è di circa 9.583 dollari, con un minimo di 500 dollari e un massimo di 35.000 dollari. La mediana si attesta a 8.000 dollari e il 75% dei richiedenti non supera i 12.237 dollari.
- *loan_intent*: finalità del prestito. Si osserva che le finalità più comuni per la richiesta di prestito sono l'istruzione (20,34%), le spese mediche (19,00%) e le iniziative imprenditoriali (17,38%). Seguono i prestiti personali generici (16,78%) e quelli destinati al consolidamento dei debiti (15,88%). Solo una minoranza dei prestiti (10,63%) è destinata a lavori di ristrutturazione o miglioramento dell'abitazione. Questa distribuzione evidenzia come la domanda di credito si concentri prevalentemente su esigenze familiari, sanitarie ed educative, con una quota comunque significativa riservata a scopi imprenditoriali.




- *loan_int_rate*: tasso d'interesse associato al prestito. Il tasso medio applicato è dell'11,01%, con una variabilità contenuta (deviazione standard $\approx 2,98$). I valori oscillano tra un minimo del 5,42% e un massimo del 20%. Il 50% dei richiedenti ha ricevuto un tasso compreso tra 8,59% e 12,99% (rispettivamente, i valori del primo quartile e del terzo quartile).
- *loan_percent_income*: rappresenta la quota di reddito annuale destinata al rimborso del prestito richiesto. Essa fornisce un'indicazione immediata della sostenibilità finanziaria dell'operazione: valori elevati potrebbero segnalare difficoltà future nel rimborso. Nel dataset analizzato, i valori di questa variabile variano tra circa 0,02 e oltre 1,0, con una distribuzione concentrata tra 0,1 e 0,5.

Min	1st Qu.	Median	Mean	3rd Qu.	Max.
0	0.07	0.12	0.1397	0.19	0.66




- *cb_person_cred_hist_length*: durata della storia creditizia in anni. I valori variano da 1 a 8 anni, con una media di circa 4 anni. Una storia creditizia più estesa è generalmente associata a un rischio inferiore di default.

Min	1st Qu.	Median	Mean	3rd Qu.	Max.
2	3	4	5.867	8	30




- *credit_score*: punteggio di credito assegnato al richiedente. In generale, un punteggio più alto corrisponde a una maggiore probabilità di ricevere l'approvazione del prestito, poiché segnala un comportamento finanziario positivo. Nel dataset analizzato, i punteggi oscillano principalmente tra 500 e 750, con una media attorno a 650. Il credit score è una delle variabili più significative nei modelli di scoring utilizzati dalle istituzioni finanziarie.

Min	1st Qu.	Median	Mean	3rd Qu.	Max.
390	601	640	632.6	670	784




- *previous_loan_default_on_file*: è un indicatore binario della presenza di eventi negativi nella storia creditizia del richiedente, in particolare default su prestiti precedenti. Questo tipo di informazione ha un peso significativo nella valutazione del rischio di credito. Come atteso, la probabilità di approvazione del prestito è molto più bassa per chi ha avuto precedenti negativi. Nel dataset, il 51% rappresenta i soggetti che hanno avuto un evento negativo nella storia creditizia, mentre il restante 49% non ha nessuno storico negativo.

Default su prestiti precedenti




I valori sono confermati ulteriormente considerando un dataset che contenga solo soggetti a cui non è stato approvato il prestito (*loan_status* = 0). In questo dataset, il 65% dei soggetti ha avuto almeno un evento negativo nel passato, a differenza del restante 35%.

Default su prestiti precedenti tra i soggetti non approvati



Al fine di selezionare le variabili da includere nel modello di regressione, è stata costruita una matrice di correlazione basata sul coefficiente di Spearman, così da tenere conto di eventuali relazioni non lineari tra le variabili indipendenti.



Dalla matrice di correlazione si può notare come le variabili indipendenti non siano particolarmente correlate se non con l'eccezione di alcune: ad esempio il valore della correlazione tra *person_age* e *person_emp_exp* è molto alto (0.89), perché all'aumentare dell'età aumenta anche l'esperienza lavorativa. Pertanto, la variabile *person_emp_exp* sarà omessa dal modello completo, siccome le

informazioni di quest'ultima sono incluse nella variabile legata all'età, e potrebbero sorgere problemi di multicollinearità.

3. Regressione logistica

La regressione logistica, nota anche come modello logit, è una tecnica statistica utilizzata per modellare la probabilità che un'unità statistica possieda una determinata caratteristica dicotomica (ossia l'accadimento o meno dell'evento). Il modello permette di stimare l'influenza che un insieme di variabili indipendenti, che siano qualitative o quantitative, discrete o continue, ha sulla probabilità di osservare un certo esito. L'obiettivo è quello di identificare i fattori determinanti dell'evento, discriminare tra le unità che possiedono o meno la caratteristica e prevedere la probabilità che un'osservazione futura rientri in una delle due categorie. Una delle caratteristiche fondamentali di questo modello è che non assume normalità degli errori e gestisce una variabile dipendente di tipo binario.

$$\text{logit}(\pi) = \log\left(\frac{\pi(x)}{1 - \pi(x)}\right) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

- $\pi(x)$ rappresenta la probabilità che l'evento si verifichi (o probabilità di appartenenza a una specifica classe) per un'osservazione.
- β_0 è l'intercetta.
- β_k sono i coefficienti di regressione associati alle variabili esplicative.
- $\log\left(\frac{\pi}{1-\pi}\right)$ rappresenta il log-odds, ossia il logaritmo del rapporto tra la probabilità di successo e insuccesso.

3.1. Applicazione del modello logit e ottimizzazione

Per la costruzione del modello di regressione logistica è stato inizialmente preso in considerazione il dataset filtrato (*d_new*), il quale contiene 14 variabili e 44.993 osservazioni. Sono state rimosse alcune variabili, come *loan_intent*, *person_education* e *person_home_ownership*, poiché essendo variabili categoriali con più livelli, avrebbero richiesto la creazione di diverse dummy e aumentato la complessità del modello, senza apportare benefici estremamente significativi.

Table 1	
	Dependent variable
	<i>loan_status</i>
<i>Constant</i>	-0.0906 (0.2678)
<i>person_age</i>	0.0114* (0.0058)
<i>person_gender</i>	0.0225 (0.0339)
<i>person_income</i>	0.0000012** (0.0000004)
<i>loan_amnt</i>	-0.00011*** (0.000004)
<i>loan_int_rate</i>	0.3359*** (0.00629)
<i>loan_percent_income</i>	16.03691*** (0.3391)
<i>cb_person_cred_hist_length</i>	-0.01222 (0.0089)
<i>credit_score</i>	-0.0090*** (0.00038)
<i>previous_loan_defaults_on_file</i>	-20.5998 (104.1166)
Observations	44.993
Log Likelihood	-10702.89
Akaike Inf. Criteria	21.426
Note	*p<0.1, **p<0.05, ***p<0.01

Table 1: Risultati del modello logit completo

Dall'analisi della *Table 1* è possibile notare un livello di significatività per le variabili *person_age*, *person_income*, *loan_amnt*, *loan_int_rate*, *loan_percent_income* e *credit_score*. La variabile *loan_percent_income* evidenzia che la quota di reddito destinata al rimborso del prestito incide in modo rilevante sulle probabilità di approvazione del prestito. La variabile *loan_amnt* mostra un effetto negativo sulle probabilità di approvazione, in quanto all'aumentare dell'importo richiesto, diminuiscono tali probabilità.

Per migliorare la performance del modello è stata eseguita una minimizzazione dell'Akaike Information Criterion, ossia un metodo utilizzato per valutare e confrontare modelli statistici, al fine di selezionare quello più performante. Il modello migliore sarà quello caratterizzato da un AIC più

basso, che consente di trovare un equilibrio tra bontà di adattamento del modello ai dati e complessità del modello stesso. Attraverso la procedura stepwise backward abbiamo ottenuto un secondo modello di regressione logistica che fornisce i seguenti risultati:

Table 2	
	Dependent variable
	<i>loan_status</i>
<i>Constant</i>	0.0434 (0.2515)
<i>person_age</i>	0.0045 (0.0028)
<i>person_income</i>	0.0000012 (0.0000004)
<i>loan_amnt</i>	-0.00011*** (0.000004)
<i>loan_int_rate</i>	0.3357*** (0.00628)
<i>loan_percent_income</i>	16.0190*** (0.3388)
<i>credit_score</i>	-0.0090*** (0.00038)
<i>previous_loan_defaults_on_file</i>	-20.5998 (104.1266)
Observations	44.993
Log Likelihood	-10704.05
Akaike Inf. Criteria	21.424
Note	*p<0.1, **p<0.05, ***p<0.01

Table 2: Risultati modello logit che minimizza AIC

Tramite il processo stepwise l'AIC è passato da 21426 del modello completo a 21424 nel modello ristretto. Tale cambiamento non è sostanziale, ma la procedura ha comunque rimosso le variabili ritenute non rilevanti, migliorando il bilanciamento tra bontà dell'adattamento e numero di variabili. In generale, il modello ottenuto risulterà comunque più performante.

4. Analisi di robustezza del modello logit

Per valutare la robustezza del modello, è stato creato un vettore composto in maniera casuale da 0 e 1, generando 34.993 osservazioni da una distribuzione binomiale con una probabilità del successo del 60%. In questo modo viene simulato un processo in cui ogni campione rappresenta un evento binario (inclusione/esclusione dal campione) con una probabilità del 60%. Dunque, è stata creata la classe *y_0* contenente i soggetti che non hanno ricevuto il prestito, e che costituiscono la classe maggioritaria del dataset principale. Da questi, è stato estratto un sotto-campione casuale del 60%, ottenendo un insieme ridotto denominato *y_0_ridotto*. Successivamente, sono stati selezionati i soggetti a cui è stato approvato il prestito in un altro dataframe indicato con *y_1*, che rappresenta l'intera classe minoritaria, ossia i soggetti a cui è stato approvato il prestito. L'unione di *y_0_ridotto* (60% dei default) e *y_1* (100% degli in bonis), ha prodotto un nuovo dataset training, denominato *df1*, bilanciato rispetto alla distribuzione originale. Su questo dataset è stato stimato un modello logit, successivamente validato su un campione complementare costituito dal restante 40% dei default.

Table 3	
	Dependent variable
	<i>loan_status</i>
<i>Constant</i>	0.3879 (0.2853)
<i>person_age</i>	0.0046 (0.0032)
<i>person_income</i>	0.0000014** (0.000000516)
<i>loan_amnt</i>	-0.00011*** (0.0000052)
<i>loan_int_rate</i>	0.3307*** (0.007)
<i>loan_percent_income</i>	15.9318*** (0.3979)
<i>credit_score</i>	-0.0087*** (0.00043)
<i>previous_loan_defaults_on_file</i>	-20.9835 (133.6396)
Observations	31.153
Log Likelihood	-8336.186
Akaike Inf. Criteria	16.688
Note	*p<0.1, **p<0.05, ***p<0.01


Table 3: Risultati modello logit del sottocampione

Per verificare la robustezza del modello, sono stati presi i valori predetti e sono stati applicati sul dataset contenente i valori esclusi dall'analisi precedente. Dopodiché, con l'ausilio della tabella di contingenza, sono stati confrontati i valori stimati con quelli reali e, per vedere la capacità predittiva del modello, è stata generata la *confusion matrix*.

Valutazione stimata	Comportamento effettivo	
	Default	In bonis
Default	12446	1791
In bonis	1394	8209

Table 4: Matrice di contingenza sul modello ristretto

La matrice di contingenza evidenzia dunque la corrispondenza tra i valori osservati e quelli predetti dal modello, distinguendo correttamente i soggetti a cui è stato approvato il prestito (in bonis) e quelli a cui è stato rifiutato (default). È stato ottenuto un livello di *accuracy* dell'86,76%, ossia la percentuale di predizioni corrette rispetto al totale delle predizioni. Non è un valore eccellente, ma rimane comunque un valore ottimo ai fini dell'analisi, in quanto identifica una buona parte dei soggetti che si vedranno un prestito rifiutato o meno. Per un'analisi più approfondita, sono stati considerati gli indicatori di *sensitivity*, che misura la proporzione di soggetti in bonis correttamente identificati come tali, e quindi la capacità di individuare i veri positivi del modello, e di *specificity*, che rappresenta la proporzione di soggetti default correttamente riconosciuti a loro volta come tali, quindi la capacità del modello di individuare i veri negativi. I valori ottenuti per i due indicatori sono rispettivamente di 0.9022 e 0.8193, e confermano un buon bilanciamento del modello nella classificazione delle due classi, a fronte di un campione caratterizzato inizialmente da una forte asimmetria iniziale.



La valutazione complessiva del modello è stata effettuata anche tramite la curva ROC, uno strumento grafico che rappresenta la relazione tra *sensitivity* e *specificity*. Il grafico è stato costruito tracciando i punti corrispondenti alle coppie di valori (1-Specificity, Sensitivity) calcolati per tutti i valori della confusion matrix. Un modello è considerato efficiente quando la curva cresce rapidamente verso l'alto e si avvicina all'angolo superiore sinistro del grafico, indicando un'elevata capacità di distinguere tra le classi.

Per descrivere le prestazioni della curva in un unico indicatore si utilizza l'AUC (Area Under the Curve), ossia l'area al di sotto della curva ROC. Più l'AUC si avvicina a 1, maggiore è la capacità discriminante del modello. Nel caso analizzato, il valore dell'AUC è pari allo 0.9471, un valore ottimo per l'analisi in questione.


4.1. Analisi sul dataset completo

Nel contesto dell'erogazione del credito, i soggetti creditizi si trovano a dover prendere decisioni rapide circa l'approvazione o il rifiuto della richiesta di prestito da parte dei clienti. Per poter supportare tali decisioni, è fondamentale utilizzare strumenti statistici che consentano l'analisi dettagliata del profilo di ogni richiedente, in modo tale da poter trarre una valutazione. L'obiettivo dell'analisi è quello di identificare, tramite la regressione logistica, le variabili significative che influenzano l'esito della richiesta. Il modello è stato quindi inizialmente bilanciato, mentre nell'analisi finale i valori predetti verranno applicati all'intero dataset, per identificare le rispettive probabilità dei due eventi sul campione completo e verificare se il modello è performante.

Valutazione stimata	Comportamento effettivo	
	Default	In bonis
Default	31405	1791
In bonis	3588	8209

Table 5: Matrice di contingenza sul modello completo

L'analisi sul modello completo risulta coerente con l'esito ottenuto con il modello ristretto. Ciò è dimostrato dal valore di *accuracy*, che ha raggiunto un valore pari all'88,04%, e dai valori degli indicatori di *sensitivity* e *specificity*, che continuano ad attestarsi su valori positivi, rispettivamente di 0.8975 e 0.8209, dimostrando una buona capacità del modello di distinguere tra le richieste approvate e rifiutate. Anche il valore dell'AUC è pressoché simile a quello precedente: il nuovo valore è 0.9467, e quest'ultimo continua a denotare un'ottima capacità discriminante.



5. Conclusioni

L'analisi condotta in questo progetto è stata eseguita su un dataset simulato contenente informazioni rilevanti sul profilo finanziario dei soggetti richiedenti, tramite una regressione logistica. L'obiettivo è stato quello di stimare in maniera affidabile la probabilità che una richiesta venga accettata o respinta, individuando le variabili rilevanti che influenzano la decisione. Pertanto, possono essere descritte le variabili statisticamente significative. La variabile *person_income* ha un coefficiente positivo, quindi all'aumentare del reddito dell'individuo aumentano le probabilità che il prestito venga approvato. La variabile *loan_amnt* presenta un coefficiente negativo, il quale si traduce in una probabilità di approvazione del prestito che diminuisce all'aumentare dell'importo richiesto. Importi più elevati comportano un rischio maggiore per l'emittente, quindi la soglia di accettazione diventa più selettiva. La variabile *loan_int_rate* mostra che all'aumentare del tasso, aumenta la probabilità che una richiesta venga approvata. Tale relazione suggerisce che i richiedenti a cui viene associato un tasso più elevato risultano, nel complesso, più frequentemente approvati, e ciò potrebbe derivare da ulteriori fattori compensativi presenti nel profilo del cliente, oppure è un risultato imputabile alla natura simulata del dataset. La variabile *loan_percent_income*, con coefficiente positivo, indica che all'aumentare della percentuale di reddito assorbita dal prestito, aumenta la probabilità che la richiesta venga approvata. Un'interpretazione potrebbe essere che il cliente che si espone maggiormente in rapporto al proprio reddito sia anche quello più motivato ad ottenere il prestito. Inoltre, il valore del VIF (Variance Inflation Factor) è circa pari a 3.10, dimostrando una moderata collinearità con altre variabili, che però non compromette la stabilità delle stime. Infine, la variabile *credit_score*, anch'essa con coefficiente positivo indica che, a parità di altre condizioni, un punteggio di credito elevato è associato ad una maggiore possibilità che la richiesta di prestito venga approvata. L'inclusione di ulteriori variabili non presenti nel modello, come ad esempio indicatori relativi alla linea di credito o variabili comportamentali, avrebbe potuto contribuire a una maggiore robustezza e precisione delle stime ottenute, ma in generale il modello ha restituito buoni risultati in termini di *accuracy*, *sensitivity* e *specificity*, confermando una certa solidità dell'approccio adottato.

Appendice Codice Rstudio

```
rm(list = ls())

library(ggplot2)
library(dplyr)
library(caret)
library(pROC)
library(lessR)
library(pscl)
library(MASS)
library(car)

#1. Introduzione

# Lettura dataset
dataset <- read.csv("C:/Users/soria/Desktop/Econometria & Data
Science/dataset 14 var/loan_data.csv")
str(dataset)
summary(dataset)

#2. Analisi descrittiva del dataset

# Prima filtrazione del dataset e rimozione degli outlier
d_new=na.omit(dataset[1:14])
d_new <- subset(dataset,
                person_age <= 100)

# Trasformazione variabili categoriche in fattori
d_new <- read.csv("C:/Users/soria/Desktop/Econometria & Data
Science/dataset 14 var/loan_data_filtered.csv")
d_new$loan_status <- as.factor(d_new$loan_status)
d_new$person_gender <- as.factor(d_new$person_gender)
d_new$person_education <- as.factor(d_new$person_education)
d_new$person_home_ownership <- as.factor(d_new$person_home_ownership)
d_new$loan_intent <- as.factor(d_new$loan_intent)

# Statistiche descrittive

#PERSON_GENDER
count(d_new, person_gender)
PieChart(person_gender, data=d_new)

#PERSON_EDUCATION
BarChart(person_education, data=d_new,
          main="Distribuzione livello di istruzione",
          horiz=TRUE, sort="-", fill="blue")
```



```

round(prop.table(table(dataset$person_education)) * 100, 2)
summary(dataset$person_emp_exp)

#PERSON_HOME_OWNERSHIP
BarChart(person_home_ownership, data=d_new,
          main="Distribuzione titolarità abitazione",
          horiz=TRUE, sort="-", fill="blue")
round(prop.table(table(dataset$person_home_ownership)) * 100, 2)
table(dataset$person_home_ownership, dataset$loan_status)
#Tra coloro hanno una certa titolarità della casa, la percentuale degli 0
è andata in default.
round(prop.table(table(dataset$person_home_ownership,
dataset$loan_status), margin = 1) * 100, 2)

#PERSON_AGE
freq_relativa <- prop.table(table(d_new$person_age))
barplot_age<- cut(d_new$person_age, breaks = seq(20,
max(d_new$person_age), by = 5))
barplot(prop.table(table(barplot_age)),
        main = "Istogramma Età con Frequenze Relative",
        xlab = "Classe di Età",
        ylab = "Frequenze Relative",
        col = "blue")
summary(d_new$person_age)

#PERSON_INCOME
summary(d_new$person_income)
sd(d_new$person_income)

#PERSON_EMP_EXP
summary(d_new$person_emp_exp)

#LOAN_AMNT
summary(d_new$loan_amnt)

#LOAN_INTENT
round(prop.table(table(d_new$loan_intent)) * 100, 2)
BarChart(loan_intent, data=d_new,
          main="Distribuzione finalità del prestito",
          horiz=TRUE, sort="-", fill="blue")

#LOAN_INT_RATE
summary(d_new$loan_int_rate)
sd(dataset$loan_int_rate, na.rm = TRUE)

#LOAN_PERCENT_INCOME
summary(d_new$loan_percent_income)
sd(d_new$loan_percent_income, na.rm = TRUE)
hist(d_new$loan_percent_income,
     main = "",

```

```

xlab = "Percentuale del reddito dedicata al prestito",
col = "lightgreen",
breaks = 40)

#CB_PERSON_CRED_HIST_LENGTH
summary(d_new$cb_person_cred_hist_length)
sd(d_new$cb_person_cred_hist_length, na.rm = TRUE)
hist(d_new$cb_person_cred_hist_length,
     main = "",
     xlab = "Anni di storia creditizia",
     col = "lightblue",
     breaks = 8)

#CREDIT_SCORE
summary(d_new$credit_score)
sd(d_new$credit_score, na.rm = TRUE)
hist(d_new$credit_score,
     main = "",
     xlab = "Credit Score",
     col = "orange",
     breaks = 30)

#PREVIOUS_LOAN_DEFAULT_ON_FILE
table(d_new$previous_loan_defaults_on_file)
round(prop.table(table(d_new$previous_loan_defaults_on_file)) * 100, 2)
PieChart(previous_loan_defaults_on_file,
         data = d_new,
         main = "Default su prestiti precedenti")
table(d_default$previous_loan_defaults_on_file)
round(prop.table(table(d_default$previous_loan_defaults_on_file)) * 100,
2)

# Creazione di un dataset contenente solo soggetti in default
d_default = d_new
d_default$loan_status[d_default$loan_status == "1"] <- NA
d_default = na.omit(d_default[1:14])

# Statistiche descrittive di d_default

#PERSON_GENDER
PieChart(person_gender, data=d_default, main="Default per genere")

#PERSON_AGE
Histogram(person_age, data=d_default, main="Età per default")

#PERSON_EDUCATION
BarChart(person_education, data=d_default, main="Tipo di istruzione dei
default")

#PERSON_HOME_OWNERSHIP

```

```

BarChart(person_home_ownership,data=d_default,main="Tipo di casa dei
default")

#PERSON_INCOME
Histogram(person_income,data=d_default,main="Stipendio netto dei
default")

#PERSON_EMP_EXP
Histogram(person_emp_exp,data=d_default,main="Numero di giorni di
occupazione")

#LOAN_AMNT
Histogram(loan_amnt,data=d_default,main="Ammontare prestito richiesto dei
default")

#LOAN_INTENT
BarChart(loan_intent, data=d_default,
         main="Distribuzione finalità del prestito dei default",
         horiz=TRUE, sort="-", fill="blue")

#LOAN_INT_RATE
Histogram(loan_int_rate,data=d_default,main="Tasso associato al prestito
dei default")

#LOAN_PERCENT_INCOME
Histogram(loan_percent_income,data=d_default,main="Quota destinata al
rimborso dei default")

#CB_PERSON_CRED_HIST_LENGTH
Histogram(cb_person_cred_hist_length,data=d_default,main="Durata della
storia creditizia in anni")

#CREDIT SCORE
Histogram(credit_score,data=d_default,main="Credit score default")
Histogram(credit_score,data=d_new,main="Credit score totale")

#PREVIOUS_LOAN_DEFAULT_ON_FILE
PieChart(previous_loan_defaults_on_file,
         data = d_default,
         main = "Default su prestiti precedenti tra i soggetti non
approvati")

table(d_default$previous_loan_defaults_on_file)
table(d_new$previous_loan_defaults_on_file)
table(dataset$previous_loan_defaults_on_file)

# Creazione MATRICE DI CORRELAZIONE
library(corrplot)
numeriche <- d_new[, sapply(d_new, is.numeric)]
cor_matrix <- cor(numeriche, method = "spearman", use = "complete.obs")

```

```
round(cor_matrix, 2)
corrplot(cor_matrix, method = "color", type = "upper",
          tl.cex = 0.7, number.cex = 0.7, addCoef.col = "black")
```

#3. Regressione Logistica

Modello Logit completo

```
modello_logit1 <- glm(loan_status ~ person_age + person_gender +
                      person_income +
                      loan_amnt + loan_int_rate + loan_percent_income +
                      cb_person_cred_hist_length + credit_score +
previous_loan_defaults_on_file, data = d_new, family = binomial)
summary(modello_logit1)
vif(modello_logit1)
logLik(modello_logit1)
modello_stepwise=stepAIC(modello_logit1)
summary(modello_stepwise)

AIC(modello_logit1)
AIC(modello_stepwise)
```

Modello Logit che minimizza l'AIC

```
modello_ristretto1 <- glm(loan_status ~ person_age + person_income
                          + loan_amnt
                          + loan_int_rate + loan_percent_income +
                          + credit_score +
previous_loan_defaults_on_file,
                        data = d_new, family = binomial)

summary(modello_ristretto1)
logLik(modello_ristretto1)
AIC(modello_ristretto1)
```

#4. Analisi di robustezza del modello Logit

Creazione di un dataset contenente il 60% dei default e il 100% dei bonis

```
set.seed(123)
indzero <- rbinom(nrow(y_0), 1, 0.6)
y_0 = d_new[d_new$loan_status == 0,]
y_0_ridotto = y_0[indzero == 1,]
y_1 = d_new[d_new$loan_status == 1,]

df1 = rbind(y_0_ridotto, y_1)
df1<- subset(df1, select = -loan_intent)
df1<- subset(df1, select = -person_home_ownership)
df1<- subset(df1, select = -person_education)
df1<- subset(df1, select = -cb_person_cred_hist_length)
df1<- subset(df1, select = -person_gender)
```

```

df1<- subset(df1, select = -person_emp_exp)

# Creazione di un dataset contenente il 40% dei default e il 100% dei bonis
z_0 = y_0[indzero == 0,] #z0 = 40% dei default
newdf=rbind(z_0,y_1)
newdf<- subset(newdf, select = -loan_intent)
newdf<- subset(newdf, select = -person_home_ownership)
newdf<- subset(newdf, select = -person_education)
newdf<- subset(newdf, select = -cb_person_cred_hist_length)
newdf<- subset(newdf, select = -person_gender)
newdf<- subset(newdf, select = -person_emp_exp)

loan_status_vettore=newdf$loan_status
newdf<- subset(newdf, select = -loan_status)

modello_df<-glm(loan_status~. , data = df1, family = "binomial")
summary(modello_df)
logLik(modello_df)
predictions_df <- predict(modello_df, newdata = newdf, type = "response")
predictions_01<-ifelse(predictions_df>0.5,1,0)
table_prova=table(Predicted=predictions_01,Actual=loan_status_vettore)
confusionMatrix(table_prova)

# Creazione ROC curve (ridotto)
par(pty="s")
roc(loan_status_vettore,predictions_df,plot=TRUE,legacy.axes=TRUE,percent
=TRUE,
    xlab="1-Specificity",ylab="Sensitivity",main="ROC Curve")

#4.1 Analisi sul dataset completo

loan_status_comp=d_new$loan_status
newdf_comp<-subset(d_new, select = -loan_status)
newdf_comp<- subset(newdf_comp, select = -loan_intent)
newdf_comp<- subset(newdf_comp, select = -person_home_ownership)
newdf_comp<- subset(newdf_comp, select = -person_education)
newdf_comp<- subset(newdf_comp, select = -cb_person_cred_hist_length)
newdf_comp<- subset(newdf_comp, select = -person_gender)
newdf_comp<- subset(newdf_comp, select = -person_emp_exp)

modello_df_finale<-glm(loan_status~., data = df1, family = "binomial")
predictions_df_finale <- predict(modello_df_finale, newdata = newdf_comp,
type = "response")
predictions_02<-ifelse(predictions_df_finale>0.5,1,0)
table_prova_finale=table(Predicted=predictions_02,Actual=loan_status_comp
)
confusionMatrix(table_prova_finale)
# Creazione ROC curve (completo)
par(pty="s")

```

```
roc(loan_status_comp,predictions_df_finale,plot=TRUE,legacy.axes=TRUE,percent=TRUE,  
    xlab="1-Specificity",ylab="Sensitivity",main="ROC Curve")
```

Bibliografia e sitografia

- Faraway, J. J. (2006). *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models*. Chapman & Hall/CRC.
- Trovato, G.. *Dispense delle lezioni*, Università degli studi di Roma Tor Vergata.
- Wooldridge, J. M. (2012). *Introductory Econometrics: A Modern Approach* (4th ed.).
- <https://medium.com/analytics-vidhya/a-guide-to-machine-learning-in-r-for-beginners-part-5-4c00f2366b90>
- <https://www.kaggle.com/datasets/taweilo/loan-approval-classification-data>