



**TOR VERGATA**  
UNIVERSITÀ DEGLI STUDI DI ROMA

**Facoltà di Economia**

**Corso di laurea in**  
**Economia dei Mercati e degli Intermediari**  
**Finanziari**

**Tesi in Finanza Quantitativa**

**“Componenti di volatilità e previsione  
mediante il modello MF2-GARCH”**

**Relatore:**

Chiar.mo Prof.  
Tommaso Proietti

**Laureando:**

Marco Soriano  
Matricola: 0351483

**Anno Accademico 2024/2025**

# Indice

|                                                              |           |
|--------------------------------------------------------------|-----------|
| <b>Introduzione</b>                                          | <b>5</b>  |
| <b>1 Analisi della Volatilità</b>                            | <b>8</b>  |
| 1.1 Volatilità: definizione e rilevanza . . . . .            | 8         |
| 1.2 Proprietà stilizzate dei rendimenti . . . . .            | 10        |
| 1.2.1 Volatility clustering . . . . .                        | 10        |
| 1.2.2 Leptocurtosi . . . . .                                 | 10        |
| 1.2.3 Effetto leva . . . . .                                 | 11        |
| 1.2.4 Persistenza della volatilità . . . . .                 | 11        |
| 1.2.5 Variabili macroeconomiche . . . . .                    | 12        |
| 1.3 Modelli classici di volatilità condizionata . . . . .    | 12        |
| 1.3.1 Modello ARCH . . . . .                                 | 13        |
| 1.3.2 Modello GARCH . . . . .                                | 14        |
| 1.3.3 Modello GJR-GARCH . . . . .                            | 15        |
| 1.4 Limiti dei modelli tradizionali . . . . .                | 16        |
| 1.5 Modelli a componenti multiple . . . . .                  | 18        |
| <b>2 Il Multiplicative Factor Multi-Frequency GARCH</b>      | <b>20</b> |
| 2.1 La motivazione empirica . . . . .                        | 20        |
| 2.2 La struttura del modello . . . . .                       | 23        |
| 2.2.1 Componente a breve termine (GJR-GARCH) . . . . .       | 24        |
| 2.2.2 Componente a lungo termine (MEM su errori medi mobili) | 25        |
| 2.2.3 Stima di Quasi-Massima Verosimiglianza . . . . .       | 26        |
| 2.3 Proprietà teoriche . . . . .                             | 29        |
| 2.3.1 Stazionarietà e varianza incondizionata . . . . .      | 29        |
| 2.3.2 News Impact Curve . . . . .                            | 30        |
| 2.3.3 Previsioni multi-step e misure di rischio . . . . .    | 33        |
| 2.4 Estensioni del modello . . . . .                         | 36        |
| 2.4.1 MF2-GARCH con pesi beta . . . . .                      | 36        |

|          |                                                              |            |
|----------|--------------------------------------------------------------|------------|
| 2.4.2    | Componente di lungo periodo a bassa frequenza . . . . .      | 36         |
| 2.5      | Differenze con altri modelli . . . . .                       | 38         |
| <b>3</b> | <b>Dataset</b>                                               | <b>40</b>  |
| 3.1      | S&P 500 . . . . .                                            | 40         |
| 3.2      | Serie storica . . . . .                                      | 42         |
| 3.3      | Equity Market Volatility Tracker & WSJ Stock Jumps . . . . . | 44         |
| <b>4</b> | <b>Analisi empirica</b>                                      | <b>47</b>  |
| 4.1      | Analisi in-sample . . . . .                                  | 47         |
| 4.2      | Implicazioni per la previsione della volatilità . . . . .    | 52         |
| 4.3      | Previsioni Out-of-Sample . . . . .                           | 54         |
| 4.3.1    | Valutazione pre-covid . . . . .                              | 55         |
| 4.3.2    | Valutazione sul periodo completo . . . . .                   | 61         |
| 4.4      | Simulazione Monte Carlo . . . . .                            | 65         |
| 4.5      | Componente di lungo periodo e tracker EMV . . . . .          | 69         |
| 4.6      | Effetto immediato e intermedio delle notizie . . . . .       | 72         |
| 4.7      | Value at Risk & Expected Shortfall . . . . .                 | 76         |
|          | <b>Conclusioni</b>                                           | <b>91</b>  |
|          | <b>Appendice</b>                                             | <b>93</b>  |
|          | <b>Bibliografia</b>                                          | <b>108</b> |
|          | <b>Sitografia</b>                                            | <b>113</b> |

# Indice delle figure

|     |                                                                                                                                     |    |
|-----|-------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1 | Stima di un modello GJR-GARCH(1,1) sui rendimenti giornalieri dell'S&P 500. . . . .                                                 | 21 |
| 2.2 | News Impact Curve dell'MF2-GARCH-rw. . . . .                                                                                        | 33 |
| 3.1 | Serie temporale dei prezzi logaritmici. . . . .                                                                                     | 42 |
| 3.2 | Distribuzione di RV e log-RV dell'S&P 500. . . . .                                                                                  | 43 |
| 3.3 | ACF di RV e log-RV dell'S&P 500. . . . .                                                                                            | 43 |
| 3.4 | Serie “Equity Market Volatility Tracker”: Overall. . . . .                                                                          | 46 |
| 4.1 | Volatilità condizionata e di lungo periodo del modello MF2-GARCH-rw-63. . . . .                                                     | 50 |
| 4.2 | Confronto <i>in-sample</i> tra MF2-GARCH-rw-63 e GJR-GARCH nel sottoperiodo 2020–2021. . . . .                                      | 51 |
| 4.3 | Confronto <i>in-sample</i> tra MF2-GARCH-rw-63 e GJR-GARCH nel sottoperiodo 2025. . . . .                                           | 52 |
| 4.4 | Confronto tra previsioni <i>out-of-sample</i> MF2-GARCH-rw-63 e GJR-GARCH in tre sottoperiodi. . . . .                              | 53 |
| 4.5 | Confronto delle perdite cumulate di SE e QLIKE tra MF2-GARCH-rw-63 e GJR-GARCH nel campione completo. . . . .                       | 64 |
| 4.6 | Effetto di “Macro News” e “Monetary News” sulla volatilità condizionata dei modelli MF2-GARCH-rw-63 e GJR-GARCH. . . . .            | 73 |
| 4.7 | Value at Risk nel periodo <i>in-sample</i> per distribuzione Normale e $t$ di Student per MF2 con $m = 21$ e $m = 63$ . . . . .     | 80 |
| 4.8 | Value at Risk nel periodo <i>out-of-sample</i> per distribuzione Normale e $t$ di Student per MF2 con $m = 21$ e $m = 63$ . . . . . | 82 |
| 4.9 | Previsioni di VaR ed ES di MF2-GARCH-rw-21- $t$ e GJR-GARCH- $t$ nel sottoperiodo 2019–2023. . . . .                                | 90 |

# Indice delle tabelle

|      |                                                                                                                    |    |
|------|--------------------------------------------------------------------------------------------------------------------|----|
| 2.1  | Statistiche descrittive dell'S&P 500 e risultati del test LM. . . .                                                | 22 |
| 4.1  | Risultati delle stime <i>in-sample</i> sull'S&P 500. . . . .                                                       | 49 |
| 4.2  | Out-of-sample forecasting: S&P 500 – pre-Covid-19. . . . .                                                         | 60 |
| 4.3  | Out-of-sample forecasting: S&P 500 – Full OOS. . . . .                                                             | 62 |
| 4.4  | Stime dei parametri tramite simulazioni Monte Carlo. . . . .                                                       | 68 |
| 4.5  | Fattori determinanti della volatilità a lungo termine. . . . .                                                     | 71 |
| 4.6  | Impatto delle notizie macroeconomiche, corporate e monetarie<br>sulla volatilità condizionata. . . . .             | 75 |
| 4.7  | Confronto Backtest VaR: $m = 21$ vs $m = 63$ ( <i>in-sample</i> ). . . . .                                         | 81 |
| 4.8  | Confronto Backtest VaR: $m = 21$ vs $m = 63$ ( <i>out-of-sample</i> ). . .                                         | 83 |
| 4.9  | Performance congiunte <i>out-of-sample</i> relative all'Historical Si-<br>mulation: MF2-GARCH e GJR-GARCH. . . . . | 87 |
| 4.10 | Diebold–Mariano test per l'MF2-GARCH sui benchmark HS,<br>GJR- $t$ , e GJR-Normal. . . . .                         | 88 |

# Introduzione

Il 2 aprile 2025, con l'annuncio dei dazi commerciali generalizzati da parte dell'amministrazione Trump, il VIX (l'indice che misura la volatilità implicita delle opzioni sull'S&P 500) ha subito una crescita di circa 30 punti, raggiungendo un valore di 52 punti in soli cinque giorni di contrattazione; nei giorni successivi al picco, il VIX è rimasto su livelli più elevati rispetto a quanto osservato prima dello shock. La stessa dinamica si è verificata durante la pandemia, quando il 16 marzo 2020 l'indice ha raggiunto un picco di 82 punti, con un rapido calo nei primi giorni e una discesa più graduale nei mesi successivi, ma pur mantenendo un livello più elevato rispetto ai valori osservati prima del picco. Il modello che verrà trattato nella tesi è costruito proprio per tenere conto di una transizione da tempi normali a tempi eccezionali. Un altro aspetto riguarda la relazione tra la volatilità e le notizie. Nell'estate del 2021, i mercati sono entrati in una fase di tranquillità con il VIX ai minimi dall'inizio della pandemia; i mercati avevano incorporato la narrativa della Federal Reserve secondo cui l'incremento dell'inflazione sarebbe stato transitorio. Per questo, anche in presenza di dati sull'inflazione elevati, non vi sono stati picchi di volatilità. Tale calma si rivelò fondata su una previsione errata, in quanto nel 2022 la FED cominciò un ciclo di rialzo dei tassi, che provocò un incremento della volatilità, la quale rimase strutturalmente elevata nei mesi a venire. Ne emerge dunque che la relazione tra notizie e volatilità non è meccanica né stabile nel tempo, ma dipende essenzialmente dall'interpretazione che il mercato attribuisce alle informazioni disponibili e dalle aspettative che costruisce sul loro sviluppo. In questi contesti turbolenti, ci si può chiedere se un modello tradizionale di previsione della volatilità sia in grado di prevedere correttamente il rischio oppure possa sottostimare la probabilità che il prossimo shock colpisca un mercato strutturalmente più debole, generando un picco di volatilità ancora più alto. La risposta risiede nella capacità di un modello di previsione di distinguere la reazione immediata agli shock e il livello del rischio sistemico, che cambia più lentamente e riflette lo stato dell'economia.

Per questo motivo la modellazione e lo studio della volatilità risulta uno dei campi più attivi nell'area di ricerca finanziaria; essa è una grandezza latente, quindi non osservabile, e riflette l'incertezza dei mercati in un dato istante. La modellizzazione di questa grandezza è iniziata con il lavoro di Engle (1982) che introdusse l'ARCH, per poi estendersi al GARCH di Bollerslev (1986), creando di fatto la famiglia dei modelli GARCH tradizionali. Tali modelli hanno rappresentato per molto tempo lo strumento principale per la descrizione della dinamica della volatilità condizionata, ma in contesti caratterizzati da numerosi cambi di regime, hanno manifestato i propri limiti: la volatilità trattata come un processo unitario implica che vengano assorbite in un unico meccanismo sia oscillazioni di breve periodo che variazioni più lente, ossia trend di lungo periodo.

I limiti sono stati superati mediante l'introduzione di una classe di modelli a componenti multiple, in grado di separare e distinguere le diverse tipologie di oscillazioni che si verificano sui mercati: tra questi modelli è incluso il Multiplicative Factor Multi-Frequency GARCH elaborato da Conrad & Engle (2025), i quali documentano un fatto empirico rilevante, ossia che gli errori di previsione giornalieri standardizzati dei GARCH a una componente mostrano un comportamento anticiclico, sottostimando la volatilità durante le recessioni e sovrastimandola nelle fasi espansive. Tale evidenza pone le basi per la costruzione del modello MF2-GARCH, che decompone la varianza condizionata in una componente a breve termine, specificata come un GJR-GARCH a varianza unitaria, e una componente a lungo termine, modellata come un *Multiplicative Error Model* sugli errori di previsione passati. Quest'ultima specificazione moltiplicativa garantisce la positività della varianza e consente una diversa interpretazione delle due componenti principali: una reagisce agli shock di mercato mentre la seconda apprende dagli errori sistematici passati adattandosi ai trend di mercato e ai cicli macroeconomici.

Il seguente elaborato si presenta come un contributo aggiuntivo legato alla letteratura già esistente sul modello MF2-GARCH, con l'obiettivo di confermare e validare le performance del modello su un dataset più esteso rispetto a quello originale, affiancando valutazioni anche sui diversi modelli concorrenti. Inoltre, l'analisi mira a comprendere se il modello principale sia adatto per valutare la gestione del rischio.

Il contenuto è suddiviso come segue: nel primo capitolo sono introdotti la volatilità, con una descrizione della sua struttura e dei suoi campi di applicazione, e i rendimenti, dei quali vengono discusse le loro proprietà stilizzate,

fortemente connesse alle dinamiche della volatilità. Il capitolo si conclude con una descrizione dei principali modelli di volatilità condizionata tradizionali, mettendo in evidenza i principali limiti che hanno portato all'evoluzione di modelli più avanzati a componenti multiple. Nel secondo capitolo viene descritto il modello MF2-GARCH, in particolare la motivazione che ha portato alla sua costruzione, la sua specificazione standard e le rispettive specificazioni alternative. Vengono inoltre discusse le differenze rispetto ad altri modelli della medesima classe di modelli multifattoriali. Nel terzo capitolo sono elencati tutti i dati a disposizione nell'analisi: i rendimenti dell'S&P 500 sono il dataset principale di riferimento per le previsioni, affiancate dai dati di volatilità realizzata ricavati da Da & Xiu (2021), utili come proxy della varianza nell'analisi *out-of-sample*. Inoltre, l'analisi ha lo scopo di comprendere in che modo i fattori macroeconomici possono influenzare la componente a lungo termine del modello e in che modo le notizie possano impattare sulla volatilità, nel breve e nel medio termine: per questo sono utilizzati gli Equity Market Volatility Tracker e i WSJ Stock Jumps, entrambi costruiti da Baker et al. (2019). Nel quarto capitolo viene effettuata l'analisi empirica, che prevede un'analisi *in-sample* per valutare l'adattamento dei modelli ai dati storici, e un'analisi *out-of-sample*, per valutarne la capacità previsiva sulla base di determinate funzioni di perdita. Successivamente viene effettuata una simulazione Monte Carlo su un campione di dati finiti per valutare le proprietà dello stimatore di quasi-verosimiglianza del modello standard e verificarne le capacità di adattabilità per campioni con elevate dimensioni campionarie. Dopodiché, con l'utilizzo dei dataset di Baker et al. (2019) si verifica in che modo i driver macroeconomici più importanti impattano sulla componente di lungo periodo e in che modo le notizie possono impattare a breve termine sulla volatilità condizionata. L'elaborato si conclude con l'analisi sulla gestione del rischio; tramite procedure di backtesting si verifica se il modello MF2, applicato ai rendimenti dell'S&P 500, riesca a fornire stime affidabili delle misure di rischio e a garantire un'adequata capacità di copertura quando valutato *out-of-sample*.



# Capitolo 1

## Analisi della Volatilità

### 1.1 Volatilità: definizione e rilevanza

La volatilità è un concetto fondamentale nella finanza. Essa è associata a imprevedibilità, incertezza e rischio, ed è una misura che riflette il grado di variabilità dei rendimenti di una variabile nel tempo. La letteratura empirica ha riconosciuto che i fattori a cui essa è associata sono componenti fondamentali del comportamento e del movimento dei prezzi; in questo modo la volatilità ha assunto rilevanza in questo campo.

Da un punto di vista analitico, nei modelli di serie storica la volatilità è interpretata come la deviazione standard condizionale dei rendimenti, ossia la radice quadrata della loro varianza condizionata rispetto all'informazione disponibile fino al periodo precedente, indicata con  $\mathcal{F}_{t-1}$  (Engle, 1982). Formalmente, se  $r_t$  è il rendimento e  $\epsilon_t$  l'errore di previsione, allora

$$\text{Var}(r_t|\mathcal{F}_{t-1}) = h_t, \quad (1.1)$$

dove  $h_t$  rappresenta la varianza condizionata e la volatilità è data da  $\sigma_t = \sqrt{h_t}$ . Questo approccio, introdotto da Engle (1982) e formalizzato da Bollerslev (1986), fornisce la base teorica per la modellazione della volatilità. Nel caso dei modelli univariati, la volatilità è uno scalare, individuato con  $h_t$ , in quanto si lavora con un'unica variabile di interesse, mentre nei modelli multivariati è individuata da una matrice quadrata, simmetrica e semidefinita positiva, ossia  $\Omega_t$ , di dimensioni pari al numero di variabili considerate.

In ambito econometrico, è di fondamentale importanza distinguere tra varianza condizionata e varianza incondizionata, in quanto indicano due concetti differenti di rischio e pongono le loro basi su diversi presupposti informativi:

la varianza condizionata misura la variabilità attesa dei rendimenti in un dato istante, condizionatamente all'informazione disponibile fino al periodo precedente. È alla base di tutti i modelli *time-varying*, perché si tratta di una misura dinamica della volatilità, che cambia nel tempo e riflette il modo in cui il mercato incorpora le nuove informazioni.

La varianza non condizionata è una misura di lungo periodo e globale della volatilità dei rendimenti, e non dipende dall'informazione passata. Può essere scritta come:

$$\text{Var}(r_t) = E[h_t]. \quad (1.2)$$

Un tratto distintivo della volatilità è la presenza di dinamiche che persistono nel tempo, in cui si possono presentare degli shock che possono avere grandi o lievi ripercussioni per i periodi futuri. Si parla quindi della volatilità come un fenomeno caratterizzato da persistenza, e possibilmente da memoria lunga, e che può risalire a eventi passati. La persistenza si riferisce alla durata dell'effetto di uno shock sulla serie storica; nel contesto della memoria lunga, essa descrive una dipendenza temporale che decade molto lentamente. Nello specifico, secondo Hassler (2018), un processo stazionario manifesta memoria lunga se la sua funzione di autocovarianza decade così lentamente da non essere assolutamente sommabile

$$\sum_{h=0}^H |\gamma(h)| = \infty \quad \text{con } H \rightarrow \infty, \quad (1.3)$$

altrimenti presenta memoria breve

$$\sum_{h=0}^{\infty} |\gamma(h)| < \infty. \quad (1.4)$$

La volatilità è una grandezza latente e stocastica, e la sua evoluzione deriva dalla struttura informativa dei mercati (Andersen et al., 2006). Questa non può essere osservata direttamente, ma solamente stimata attraverso modelli statistici oppure approssimata tramite indicatori costruiti sulla base di dati di mercato. Nel corso degli anni è aumentato sempre di più l'interesse verso la modellizzazione della volatilità; la natura latente di quest'ultima è risultata essere un tema centrale nella letteratura finanziaria, con implicazioni rilevanti in diversi ambiti, tra cui la valutazione del rischio (*Value at Risk*, *Expected Shortfall*), la determinazione del prezzo delle opzioni (Black & Scholes, 1973), l'asset allocation e la previsione dei rendimenti (Andersen et al., 2006; Brownlees & Engle, 2012).

Sebbene sia maggiormente associata al rischio, la volatilità rappresenta per molti operatori di mercato anche uno strumento per generare profitti o per adoperare strategie di copertura, come evidenziato da Figlewski (2001). Inoltre, essa influenza il costo del capitale e le decisioni di portafoglio, poiché gli investitori richiedono premi per il rischio maggiori in presenza di una variabilità più elevata dei rendimenti (Conrad & Engle, 2025).

## **1.2 Proprietà stilizzate dei rendimenti**

Le serie storiche sono caratterizzate da diverse regolarità empiriche, definite anche come proprietà stilizzate, che si ripetono nei mercati e nei diversi periodi temporali. La letteratura finanziaria ha mostrato che questi fenomeni sono fondamentali e che costituiscono tratti strutturali delle dinamiche finanziarie.

### **1.2.1 Volatility clustering**

La clusterizzazione della volatilità è la tendenza dei periodi ad alta volatilità ad essere seguiti da periodi turbolenti, mentre fasi tranquille sono seguite da periodi relativamente calmi. Come osservato da Mandelbrot (1963):

“Le variazioni di grande entità tendono a essere seguite da altre variazioni di grande entità, di qualunque segno, mentre le variazioni di piccola entità tendono a essere seguite da altre variazioni di piccola entità.”

Questo conferma il continuo alternarsi di ampie e piccole oscillazioni intorno al valore medio. Il fenomeno può essere analizzato quantitativamente osservando i rendimenti; in particolare, anche se i rendimenti semplici non mostrano autocorrelazione, le loro trasformazioni non lineari presentano una funzione di autocorrelazione positiva, statisticamente significativa e caratterizzata da un decadimento lento nel tempo (Cont, 2007).

### **1.2.2 Leptocurtosi**

Le serie storiche sui rendimenti sono caratterizzate da distribuzioni leptocurtiche, ossia code pesanti ed eccesso di curtosi rispetto alla distribuzione Normale. I primi a documentare questo fenomeno sono stati Mandelbrot (1963) e Fama (1965, 1970); oltre a una maggiore frequenza di rendimenti estremi (sia positivi

che negativi), si presenta anche una maggiore densità di probabilità attorno alla media.

Pertanto, eventi molto grandi e osservazioni molto vicine al valore medio risultano più probabili di quanto non accadrebbe sotto l'ipotesi di normalità. Sebbene la leptocurtosi possa manifestarsi anche in processi *i.i.d.*, nei rendimenti finanziari tale fenomeno è parzialmente spiegato dalla presenza di eteroschedasticità condizionata (*volatility clustering*). Infatti, come descritto da Cont (2001) e Pagan (1996), i modelli statistici come ARCH e GARCH generano code pesanti nella distribuzione incondizionata perché implicano la mescolanza di distribuzioni condizionate con volatilità variabile nel tempo.

### 1.2.3 Effetto leva

Un importante effetto identificato da Black (1976) è l'effetto leva, che descrive la tendenza per cui le misure di volatilità dei rendimenti aumentano quando il prezzo di un titolo diminuisce (Cont, 2001); l'effetto è maggiore rispetto all'effetto di un incremento della stessa entità in valore assoluto. Questo suggerisce una correlazione negativa tra i rendimenti e le variazioni successive della volatilità.

Black attribuisce questa asimmetria alla maggiore leva finanziaria a seguito di un calo dei prezzi: questo si traduce in una diminuzione del valore dell'equity, che implica un aumento della leva finanziaria dell'impresa (misurata come *debt-to-value ratio*) e un accrescimento della volatilità del prezzo delle azioni. Tuttavia, l'effetto leva da solo non è in grado di spiegare completamente le asimmetrie nei prezzi.

### 1.2.4 Persistenza della volatilità

Un'altra proprietà è la persistenza a lungo termine, ossia gli shock sulla volatilità tendono a svanire più lentamente (Andersen et al., 2006). A livello empirico, tale fenomeno è evidenziato dalla funzione di autocorrelazione (ACF) dei rendimenti al quadrato o dei valori assoluti ( $|r_t|$ ), la quale risulta positiva e statisticamente significativa per lunghi periodi. In altri termini, la volatilità sul mercato presenta persistenza elevata, ossia tende a stabilizzarsi su livelli alti o bassi per lunghi periodi prima di convergere verso la media.

Nella letteratura, è ampiamente riconosciuta l'idea che un decadimento così lento sia coerente con l'idea che i rendimenti azionari seguano un processo stazionario dotato di memoria lunga. Come notato da Li et al. (2025)

“Troviamo prove robuste di *long memory* nella volatilità realizzata, suggerendo che gli shock alla volatilità decadono molto lentamente e persistono su orizzonti lunghi”.

### 1.2.5 Variabili macroeconomiche

Un ruolo centrale nell’influenza della volatilità nei mercati è determinato dalle condizioni macroeconomiche. Diversi contributi sottolineano la rilevanza di queste variabili: Schwert (1989) evidenzia che nei periodi di recessione e di crisi finanziarie la volatilità cresce, mentre risulta in calo quando l’economia è in fase di espansione.

Secondo Glosten et al. (1993), è presente una relazione diretta tra la volatilità dei rendimenti e i tassi d’interesse, anche se empiricamente in maniera debole; periodi di incertezza coincidono infatti con rialzi dei tassi e incrementi di volatilità, anche se non possono essere considerati come una determinante principale per giustificare le dinamiche della volatilità.

Engle & Rangel (2008) mostrano che la *secular volatility* dei mercati azionari, definita come la componente a bassa frequenza che rappresenta il trend di lungo periodo della varianza, segue un andamento lento e correlato a variabili macro. Inoltre, Christiansen et al. (2012) e Paye (2012) trovano evidenza per cui variabili finanziarie come tassi d’interesse o spread creditizi possono predire cambiamenti futuri della volatilità.

## 1.3 Modelli classici di volatilità condizionata

Il modello più semplice dei minimi quadrati ordinari (OLS) assume che il valore atteso dei residui al quadrato sia costante nel tempo, ovvero che i termini di errore siano omoschedastici. Nell’analisi delle serie storiche, al fine di stimare un modello che contenga dati non omoschedastici, ossia con le varianze degli errori non costanti, Engle (1982) creò il primo modello di eteroschedasticità condizionata, ossia l’ARCH, che tratta l’eteroschedasticità come varianza da modellare. Il modello si rivelò estremamente utile nelle applicazioni finanziarie, diventando uno dei principali strumenti di riferimento per prevedere l’entità degli errori del modello.

Successivamente, sulla base del modello di Engle, nacquero diversi modelli, tra cui il GARCH di Bollerslev (1986), che possiede sia una memoria lunga che una struttura dei ritardi più flessibile rispetto al modello ARCH, e l’estensione GJR-GARCH di Glosten et al. (1993), che si presenta come un metodo

alternativo per tenere in considerazione gli effetti asimmetrici degli shock di prezzo positivi e negativi.

### 1.3.1 Modello ARCH

Il modello ARCH proposto da Engle (1982) descrive la varianza condizionata dei rendimenti come funzione dei quadrati dei residui passati. L'idea di base è che la varianza condizionata dei rendimenti non sia costante nel tempo ma dipenda dagli shock passati.

Si consideri  $r_t$  come il rendimento di un'attività finanziaria con media condizionata nulla  $E(r_t|\mathcal{F}_{t-1}) = 0$ . Il modello ARCH(p) può essere scritto come

$$\begin{aligned} r_t|\mathcal{F}_{t-1} &\sim N(0, h_t), \\ r_t &= \sqrt{h_t}\epsilon_t, \quad \epsilon_t \sim \text{I.I.D.}(0, 1), \\ h_t &= \text{Var}(r_t|\mathcal{F}_{t-1}) = \omega + \sum_{i=1}^p \alpha_i r_{t-i}^2 \end{aligned} \tag{1.5}$$

dove  $h_t$  indica la varianza condizionata e  $\epsilon_t$  un *white noise* indipendente ed identicamente distribuito. Quest'ultimo è distribuito come una Normale con media pari a 0 e varianza unitaria. In particolare, il valore atteso del rendimento condizionato all'informazione passata pari a 0 garantisce l'assenza di un trend sistematico, mentre la varianza unitaria assicura che  $h_t$  rappresenti effettivamente la varianza condizionata di  $r_t$ . Per garantire la positività della varianza, sono imposti alcuni vincoli

$$\omega > 0, \quad \alpha_i \geq 0 \quad \text{per } i = 1, \dots, p. \tag{1.6}$$

La stazionarietà del processo richiede che la somma dei coefficienti sia inferiore a 1:

$$\sum_{i=1}^p \alpha_i < 1. \tag{1.7}$$

In tal caso, la varianza incondizionata è finita ed è pari a

$$\text{Var}(r_t) = \frac{\omega}{1 - \sum_{i=1}^p \alpha_i}. \tag{1.8}$$

L'ipotesi chiave si basa sugli shock passati, i quali influenzano la varianza futura: nel momento in cui si verifica uno shock nei rendimenti,  $h_t$  tende ad aumentare generando il fenomeno del *volatility clustering*, che denota persistenza della volatilità. Sebbene l'introduzione di questo modello sia stata una

svolta nell'analisi delle serie finanziarie, nella pratica presenta molti limiti, dovuti sia ai vincoli di non negatività per garantire  $h_t > 0$  che alla necessità di utilizzare ordini elevati ( $p$  grande) per descrivere adeguatamente la dinamica della varianza. Tali motivazioni hanno portato alla prima estensione proposta da Bollerslev (1986), il modello GARCH.

### 1.3.2 Modello GARCH

Rispetto al modello proposto da Engle, il modello GARCH consente di includere anche i valori ritardati della varianza condizionata, in modo tale da ridurre il numero di parametri da inserire rispetto a un ARCH dello stesso ordine. Il modello GARCH( $p, q$ ) descrive la varianza condizionata al tempo  $t$  come una combinazione lineare di  $p$  ritardi dei residui al quadrato, che derivano dall'equazione della media condizionata, e i  $q$  ritardi della varianza condizionata.

Il risultato è un modello decisamente più flessibile rispetto al primo modello di Engle; esso è specificato come segue:

$$\begin{aligned} r_t | \mathcal{F}_{t-1} &\sim N(\mu_{t|t-1}, h_t), \\ r_t &= \mu_{t|t-1} + \xi_t, \quad \xi_t = \sqrt{h_t} \epsilon_t, \quad \epsilon_t \sim \text{I.I.D.}(0, 1), \\ h_t &= \omega + \sum_{i=1}^p \alpha_i \xi_{t-i}^2 + \sum_{j=1}^q \beta_j h_{t-j}, \end{aligned} \tag{1.9}$$

dove il valore osservato di  $r_t$  è costituito dalla somma tra il valore atteso di  $r_t$ , dato l'insieme di informazioni disponibili in  $t - 1$ , e  $\xi_t$ , che rappresenta la componente imprevedibile del rendimento, e quindi lo shock al tempo  $t$ . Nel modello,  $\epsilon_t$  rappresenta l'innovazione standardizzata, che segue una distribuzione Normale standard con media 0 e varianza pari a 1. Nel GARCH, le condizioni sufficienti sono le seguenti

$$\sum_{i=1}^p \alpha_i + \sum_{j=1}^q \beta_j < 1, \tag{1.10}$$

con  $\omega > 0$ ,  $\alpha_i \geq 0$ ,  $\beta_j \geq 0$ . Queste condizioni implicano che la varianza incondizionata sia rappresentata come segue

$$\text{Var}(r_t) = \frac{\omega}{1 - \sum_{i=1}^p \alpha_i - \sum_{j=1}^q \beta_j}. \tag{1.11}$$

Il modello GARCH mostra essenzialmente come costruire un modello che sia in

grado di riprodurre i principali comportamenti nei mercati, ossia *volatility clustering*, *mean reversion* e *persistenza degli shock*. La volatilità viene scomposta in tre parametri fondamentali ( $\omega$ ,  $\alpha$  e  $\beta$ ), i quali possono essere analizzati.

Il parametro  $\omega$  è la costante e garantisce la positività della varianza condizionata in tutte le condizioni di mercato,  $\alpha$  cattura le reazioni della volatilità agli shock di mercato, e quindi quanto le variazioni di prezzo di oggi influenzano le aspettative di volatilità future, e infine  $\beta$  rappresenta la velocità di decadimento della volatilità; in particolare, cattura la dipendenza della volatilità dai suoi valori passati, indicando la memoria del processo. La persistenza si misura tramite la somma tra  $\alpha$  e  $\beta$ : un valore molto vicino a 1 (ad esempio 0.9) descrive una persistenza di medio periodo che può generare tensione nei mercati finanziari, mentre valori inferiori come 0.7 indicano transizioni più veloci e shock che si dileguano rapidamente.

### 1.3.3 Modello GJR-GARCH

Un'importante estensione del modello GARCH è rappresentata dal modello GJR-GARCH, elaborato da Glosten et al. (1993). Il modello è stato proposto per rappresentare un comportamento asimmetrico della volatilità, consentendo alla varianza condizionata di reagire diversamente ai rendimenti passati positivi e negativi.

L'evidenza empirica mostra, infatti, che gli shock negativi sui rendimenti tendono a generare aumenti di volatilità di maggiore intensità rispetto agli aumenti dovuti agli shock positivi di pari intensità. Il GJR-GARCH(p,q) è specificato come segue

$$\begin{aligned} r_t | \mathcal{F}_{t-1} &\sim N(\mu_{t|t-1}, h_t), \\ r_t &= \sqrt{h_t} \epsilon_t, \quad \epsilon_t \sim \text{I.I.D.}(0, 1), \\ h_t &= \omega + \sum_{i=1}^p (\alpha_i + \gamma_i \mathbf{1}_{\{r_{t-i} < 0\}}) r_{t-i}^2 + \sum_{j=1}^q \beta_j h_{t-j}, \end{aligned} \tag{1.12}$$

con  $\omega > 0$ ,  $\beta_j \geq 0$ ,  $\alpha_i + \gamma_i > 0$ .

La componente  $\mathbf{1}_{\{r_{t-i} < 0\}}$  è una variabile indicatrice che assume valore 1 per rendimenti negativi e 0 per rendimenti positivi. Nel modello,  $\omega$  garantisce la positività della volatilità,  $\alpha_i$  è la componente simmetrica che cattura la volatilità per ogni shock, indipendentemente dal segno,  $\gamma_i$  misura l'asimmetria: se  $\gamma_i > 0$  esiste un effetto asimmetrico, altrimenti se  $\gamma_i = 0$  si torna al GARCH(1,1) simmetrico. Infine,  $\beta_j$  misura la persistenza. La volatilità



incondizionata è indicata come

$$\text{Var}(r_t) = \frac{\omega}{1 - \sum_{i=1}^p (\alpha_i + \gamma_i/2) - \sum_{j=1}^q \beta_j}. \quad (1.13)$$

Ad oggi, il GJR-GARCH è una delle estensioni più utilizzate, in quanto l'asimmetria si conferma essere una caratteristica strutturale dei rendimenti finanziari, e di conseguenza il modello si dimostra molto più versatile ed efficace rispetto alle versioni simmetriche. Il modello sarà anche la base della componente di breve periodo nel modello MF2-GARCH di Conrad & Engle (2025), che sarà trattato nei capitoli successivi.

## 1.4 Limiti dei modelli tradizionali

Nel corso degli anni, i primi modelli elaborati da Engle (1982) e Bollerslev (1986) sono stati un punto di riferimento essenziale per la modellizzazione della volatilità e hanno posto le basi per tutte le estensioni successive. I nuovi approcci hanno fatto emergere alcuni limiti strutturali presenti nei GARCH tradizionali, in particolare quando confrontati con dati caratterizzati da dinamiche molto complesse.

Uno dei principali problemi è quello legato all'eccessiva persistenza; in particolare, nei modelli GARCH(1,1) è ricorrente stimare coefficienti di persistenza molto elevati, che implicano un decadimento molto lento degli shock alla volatilità e una memoria quasi infinita. Tali caratteristiche configurano un modello GARCH integrato (IGARCH), introdotto da Engle & Bollerslev (1986), in cui uno shock sulla varianza condizionale risulta persistente per ogni orizzonte temporale futuro, diventando una componente rilevante nel lungo periodo.

L'interpretazione di una persistenza di questo tipo è dibattuta. Secondo Lamoureux & Lastrapes (1990) l'omissione di cambiamenti strutturali o trend a lungo termine della varianza possono far apparire la volatilità più persistente di quanto non lo sia normalmente, facendo così rilevare una memoria lunga spuria. Sviluppi successivi della letteratura presentano invece l'elevata persistenza non come un errore di specificazione, ma come una reale proprietà di memoria lunga dei dati finanziari. Modelli avanzati come il FIGARCH di Baillie et al. (1996) permettono di stabilire se la varianza condizionale sia caratterizzata da memoria lunga.

Un altro problema dei modelli tradizionali è la difficoltà nel separare le diverse componenti frequenziali; il GARCH non è in grado di distinguere tra

movimenti ad alta frequenza, quindi di breve periodo, e movimenti a bassa frequenza, ossia di lungo periodo. Il modello tradizionale non riesce a separare le due dimensioni quando si osservano, nei dati finanziari, oscillazioni giornaliere o settimanali della volatilità sovrapposte a trend di volatilità persistenti nel medio-lungo periodo. Di conseguenza, l'interpretazione economica diventa complicata e il modello non fornisce indicazioni su quale parte della volatilità sia transitoria o dovuta a cambiamenti strutturali.

La letteratura evidenzia la necessità di più fattori: ad esempio l'approccio di Amado & Teräsvirta (2008) prevede una separazione delle componenti della volatilità, utile per prevenire stime distorte della persistenza degli shock. Tale distorsione, infatti, deriva dall'erronea attribuzione a dinamiche di breve periodo di variazioni originate da cambiamenti strutturali macroeconomici. Fouque et al. (2000) documentano la presenza di due scale temporali distinte nella volatilità dei mercati, ciascuna associata a diversi fattori stocastici: una legata da shock ad alta frequenza, e una componente lenta associata a variazioni macroeconomiche più persistenti. La stessa evidenza viene riconfermata da Fouque et al. (2003), che formalizzano un modello multiscala in grado di distinguere le frequenze temporali. Un'ulteriore limitazione dei GARCH tradizionali riguarda la scarsa performance predittiva *out-of-sample*; Figlewski (1997) afferma che i modelli a medie mobili producono previsioni di volatilità più accurate; per i mercati azionari asiatici, Tse (1991) fornisce evidenze solide contro la performance dei GARCH nelle previsioni *out-of-sample*. Queste difficoltà principali si possono tradurre in una mancanza di adattabilità del modello tradizionale monocomponente a cambiamenti come shock strutturali, che porterà a previsioni errate e quindi a una peggiore capacità predittiva. Inoltre, l'assenza di driver esogeni<sup>1</sup> nel GARCH impedisce di sfruttare informazioni che si possono rivelare utili per prevedere cambiamenti nella volatilità. Di fronte a tali criticità, la comunità scientifica ha proposto diverse soluzioni, tra cui i modelli a componente multipla, i quali introducono due componenti separate per la volatilità di breve e lungo periodo, che mitigano l'eccessiva persistenza (attribuendo la parte più persistente alla componente di lungo periodo), distinguono i movimenti a diverse scale temporali (favorendo una migliore interpretazione dei risultati) e migliorano la robustezza predittiva *out-of-sample*.

---

<sup>1</sup>Per driver esogeni si intendono variabili esterne ai rendimenti — tipicamente indicatori macroeconomici o finanziari — che influenzano il livello della volatilità. Il GARCH classico, basandosi solo su shock e varianza passata, non è in grado di incorporare tali informazioni, limitandone la capacità predittiva nei periodi caratterizzati da cambiamenti macro-finanziari.

## 1.5 Modelli a componenti multiple

La letteratura sulla volatilità condizionata ha mostrato tramite evidenze empiriche che la varianza condizionata dei rendimenti è costituita da più componenti per catturare dinamiche per diverse frequenze temporali, generalmente a breve termine e a lungo termine. Nel corso degli anni sono stati presentati molteplici modelli a due fattori, basati sul GARCH, che hanno dimostrato la loro superiorità rispetto ai modelli a un fattore.

Ding & Granger (1996) introdussero un GARCH a due componenti applicato ai rendimenti giornalieri dell'S&P 500 che mostrò fin da subito performance migliori rispetto al modello base; la componente aggiuntiva serviva infatti a catturare la forte persistenza della volatilità. Successivamente, Engle & Lee (1999) elaborarono il “Component-GARCH” (o CGARCH), il quale scompone la varianza condizionata in una componente temporanea di breve periodo, che cattura le deviazioni rispetto al livello di equilibrio di lungo periodo, e una permanente di lungo periodo, che descrive la persistenza della volatilità. Questa scomposizione rappresenta di fatto un modo per emulare la memoria lunga delle serie finanziarie. Tale processo ha migliorato la capacità descrittiva del modello sui rendimenti azionari, evidenziando diversi livelli di *mean reversion* per gli shock di breve e lungo periodo. Un altro modello è quello elaborato da Adrian & Rosenberg (2008), il quale scompone la volatilità in una componente di breve periodo, che cattura il rischio di asimmetria del mercato, interpretato come una misura della rigidità delle condizioni finanziarie, e in una componente di lungo periodo, associata al rischio ciclico dell'economia. Anche in questo caso le performance sono nettamente superiori al modello a un fattore.

È possibile trovare ulteriore evidenza negli studi di Christoffersen et al. (2012), che propongono un modello GARCH di tipo Heston & Nandi (2000) con le due componenti di volatilità di breve e lungo periodo e mirato alla valutazione delle opzioni. Il risultato ottenuto è una valutazione migliore dei prezzi rispetto al classico GARCH(1,1) grazie alla presenza della componente di lungo periodo.

Un ulteriore modello è quello proposto da Dorion (2016), il “macro-finance GARCH”, che combina le variabili macro-finanziarie con il GARCH; esso è caratterizzato, oltre alla componente di breve periodo, da una componente a lungo termine guidata da indicatori macro. Questi riescono a spiegare le variazioni a bassa frequenza della volatilità e a migliorare le valutazioni sui derivati, grazie alla capacità di cogliere gli effetti di stato dell'economia sul livello di rischio di mercato.

Un altro approccio è il Time-Varying GARCH (TV-GARCH) di Amado & Teräsvirta (2008), utilizzato per descrivere la volatilità dei rendimenti quando questa appare non stazionaria. Il modello assume una forma moltiplicativa, in cui la componente  $h_t$  descrive l'eteroschedasticità condizionata nel processo dei rendimenti mediante un GARCH standard e  $g_t$  è una funzione deterministica che modella la non stazionarietà derivante dai cambiamenti strutturali. Le due componenti descrivono rispettivamente la dinamica di breve periodo e di lungo periodo.

Uno sviluppo significativo della modellazione a due componenti è rappresentato dallo Spline-GARCH proposto da Engle & Rangel (2008). Il modello prevede la scomposizione in due componenti a bassa e alta frequenza. Mentre la dinamica di breve periodo è regolata da un GARCH(1,1) standard, la componente di lungo periodo viene modellata tramite una funzione spline quadratica esponenziale<sup>2</sup>, che genera una curva liscia e descrive con successo la componente a lungo termine basandosi esclusivamente sull'evidenza dei dati.

Infine, Engle et al. (2013) propongono una classe di modelli che integra le dinamiche di breve periodo del GARCH con una componente di lungo periodo modellata tramite la metodologia MIDAS (*Mixed Data Sampling*). La volatilità del modello GARCH-MIDAS è scomposta in due componenti moltiplicative, una di lungo periodo che riflette l'effetto delle variabili economiche a bassa frequenza, e una di breve periodo descritta da un processo GARCH a varianza unitaria. Questo modello è stato già confrontato con il GARCH tradizionale da Asgharian et al. (2013) e la conclusione che ne deriva è una maggiore capacità predittiva della volatilità condizionata in quanto incorpora le informazioni incluse nelle variabili macroeconomiche.

La letteratura converge quindi sull'idea di scomporre la volatilità condizionata in due componenti, per cogliere le oscillazioni di breve periodo dovute agli shock di mercato e le tendenze di lungo periodo dovute principalmente al ciclo macroeconomico. Il risultato è una migliore performance di previsione e un miglior *fitting* dei dati finanziari.

---

<sup>2</sup>La componente di lungo periodo  $\tau_t$  è specificata come:

$$\tau_t = c \exp \left( w_0 t + \sum_{i=1}^k w_i ((t - t_{i-1})_+)^2 + z_t \gamma \right). \quad (1.14)$$

La funzione esponenziale garantisce la positività del termine; la funzione operatore  $(x)_+$  restituisce  $x$  se  $x > 0$  e 0 altrimenti. L'insieme  $\{t_0 = 0, t_1, \dots, t_k = T\}$  rappresenta una partizione dell'orizzonte temporale  $T$  in  $k$  intervalli equispaziati.  $k$  indica il numero di nodi nel modello *Spline*, scelto in maniera ottimale tramite il BIC; a valori più alti di  $k$  corrispondono cicli più frequenti. I coefficienti  $w_i$  determinano l'ampiezza di ogni ciclo.

## Capitolo 2

# Il Multiplicative Factor Multi-Frequency GARCH

### 2.1 La motivazione empirica

Prima di introdurre la struttura del modello MF2-GARCH, è necessario comprendere in modo più approfondito le motivazioni che hanno portato alla nascita di tale specificazione. Conrad & Engle (2025) documentano un nuovo fatto empirico riguardante gli errori di previsione della volatilità: le medie mobili sulle *rolling windows* mostrano un comportamento anticiclico. Si considera il rendimento logaritmico al giorno  $t$  come  $r_t$ ; l'eteroschedasticità condizionata è modellata attraverso un processo GARCH,

$$r_t = \sqrt{h_t}\epsilon_t, \quad (2.1)$$

dove  $h_t$  è la varianza condizionata e  $\epsilon_t$  sono i.i.d. con media 0 e varianza 1. Come specificazione più generale dell'equazione 2.1, si ipotizza che il termine di errore abbia una struttura del tipo  $\epsilon_t = \sqrt{\tau_t}Z_t$ , dove  $\tau_t$  indica una componente di volatilità a lungo termine moltiplicativa omessa. Se il modello a una componente fosse specificato correttamente, gli errori standardizzati al quadrato, quindi  $\epsilon_t^2 = r_t^2/h_t$  dovrebbero essere i.i.d. e comportarsi come un *white noise*.

L'evidenza empirica mostra però che tale assunzione viene violata, e per rilevare la misspecificazione, si analizza la media mobile dei quadrati degli errori standardizzati su una *rolling window* di  $m$ , definita come segue

$$\tilde{V}_{t-1}^{(m)} = \frac{1}{m} \sum_{j=1}^m \frac{r_{t-j}^2}{h_{t-j}}. \quad (2.2)$$

Nella figura 2.1 è possibile vedere l'evoluzione di  $\tilde{V}_{t-1}^{(m)}$  calcolata sulla serie storica dell'S&P500 per le diverse ampiezze della finestra temporale ( $m \in \{1, 15, 25, 45\}$ ).




Figura 2.1: *Stima di un GJR-GARCH(1,1) sui rendimenti giornalieri dell'S&P 500 per il periodo compreso tra gennaio 1971 e settembre 2025. La linea tratteggiata indica il valore teorico pari a 1.*

Per  $m = 1$  non vi sono trend evidenti, in quanto è presente rumore nella serie. Tuttavia, all'aumentare dell'ampiezza della finestra, si osserva uno scostamento sistematico della variabile dal valore teorico per periodi prolungati; tale fenomeno è in parte giustificato dall'autocorrelazione indotta dalla media mobile. Emerge dunque un comportamento anticiclico, che si traduce in una sottostima della volatilità durante periodi di recessione (si osservi come  $\tilde{V}_{t-1}^{(m)}$  sia persistentemente superiore al valore teorico durante la crisi del 2008 e la pandemia nel 2020), e a una sovrastima della volatilità durante fasi espansive ( $\tilde{V}_{t-1}^{(m)} < 1$ ). I risultati mostrano che i modelli tradizionali trascurano le dinamiche di lungo periodo, e giustificano l'introduzione di una componente a lungo periodo  $\tau_t$  progettata per correggere questo bias locale apprendendo dagli errori passati.

Un'ulteriore evidenza a favore del modello multifattoriale, che consente di rigettare l'adeguatezza del modello GARCH a una componente, è fornita dal test statistico dei Moltiplicatori di Lagrange (LM test) sviluppato da Conrad & Schienle (2020) per la rilevazione di componenti di lungo periodo omesse. Il seguente test assume come ipotesi nulla che il modello a una singola com-

ponente sia correttamente specificato e che la componente a lungo termine sia costante, di conseguenza i residui standardizzati al quadrato devono essere i.i.d. (come posto nella precedente analisi). L'ipotesi alternativa assume invece che esista una componente di lungo periodo e nel caso in cui fosse omessa, si commetterebbe un errore di specificazione; in questo modo è possibile testare se la media mobile  $\tilde{V}_{t-1}^{(m)}$  ha potere predittivo sui residui  $\epsilon_t$ <sup>2</sup>.

Tabella 2.1: Statistiche descrittive dell'S&P 500 e risultati del test LM.

|                                                                                    | Media | DS    | Asimmetria | Curtosi | Min     | Max    | AC(1)  |
|------------------------------------------------------------------------------------|-------|-------|------------|---------|---------|--------|--------|
| <b>Panel A: Statistiche descrittive</b>                                            |       |       |            |         |         |        |        |
| $r_t$                                                                              | 0.029 | 1.094 | -1.000     | 26.868  | -22.900 | 10.957 | -0.023 |
| <b>Panel B: LM test – Variabile esplicativa <math>\tilde{V}_{t-1}^{(m)}</math></b> |       |       |            |         |         |        |        |
| $m$                                                                                | 1     | 5     | 15         | 25      | 35      | 45     | 55     |
| $p$ -value                                                                         | 0.913 | 0.959 | 0.425      | 0.017   | 0.001   | 0.001  | 0.001  |

*Note:* Il Panel A mostra le statistiche descrittive per i rendimenti giornalieri ( $r_t$ ) dell'S&P 500 nel periodo compreso tra gennaio 1971 e settembre 2025. Il Panel B riporta i  $p$ -value del test LM di Conrad e Schienle (2020) per l'ipotesi nulla di un modello GJR-GARCH(1,1) a una singola componente correttamente specificato contro l'alternativa di una componente di lungo periodo omessa. Il test è eseguito per diverse ampiezze  $m$  della finestra mobile.

I risultati ottenuti confermano quanto mostrato nella figura 2.1: se si considerano finestre temporali brevi ( $m \in \{1, 5, 15\}$ ), la serie risulta rumorosa e l'ipotesi nulla non viene rifiutata, cosa che non accade all'aumentare dell'orizzonte, dove il  $p$ -value raggiunge valori prossimi allo zero che portano a un rifiuto dell'ipotesi nulla. Di conseguenza, è necessaria l'introduzione di un modello che presenti  $\tilde{V}_{t-1}^{(m)}$  nella sua struttura. Tali dinamiche forniscono la base principale per l'introduzione del modello MF2-GARCH.

## 2.2 La struttura del modello

Il modello “Multiplicative Factor Multi-Frequency GARCH” (MF2-GARCH) elaborato da Conrad & Engle (2025) è stato proposto per superare le limitazioni dei modelli di volatilità a singola componente. La necessità di questo approccio modellistico deriva dall’osservazione empirica secondo cui gli errori standardizzati giornalieri di previsione dei modelli GARCH a una componente risultino prevedibili tramite una media mobile degli errori standardizzati passati.

Questa dinamica si traduce in una componente di lungo periodo che apprende dagli errori di previsione passati e offre una rappresentazione più fedele e realistica della persistenza della volatilità. La componente a lungo termine, specificata come *Multiplicative Error Model* (MEM) sugli errori di previsione passati della componente GARCH, è combinata con una componente GJR-GARCH a breve termine.

Il modello appartiene alla classe dei modelli MIDAS (*Mixed Data Sampling*) in quanto la componente a lungo termine può evolvere sia con la frequenza della componente a breve sia a una frequenza più bassa. Rispetto ad altri GARCH multi-componente, l’MF2 presenta rendimenti stazionari e previsioni di lungo periodo della volatilità *mean-reverting*; inoltre, Conrad e Engle mostrano come il modello presenti performance predittive superiori al GARCH tradizionale o a modelli affini come il GARCH-MIDAS.

Formalmente, si indichi con  $r_t$  il rendimento logaritmico giornaliero

$$r_t = \sigma_t Z_t, \quad \sigma_t = \sqrt{h_t \tau_t}. \quad (2.3)$$

Si denoti il set informativo al giorno  $t$  con  $\mathcal{F}_t$ . La deviazione standard condizionata  $\sigma_t$  è fattorizzata in due componenti, dove  $h_t$  rappresenta la componente di breve periodo e  $\tau_t$  è la componente di lungo periodo. A differenza di altri modelli<sup>1</sup> in cui la componente di lungo periodo è deterministica (Spline-GARCH) o guidata da variabili esogene a bassa frequenza (GARCH-MIDAS-X), nel modello MF2 la componente di lungo periodo è endogena e stocastica, guidata dalle performance predittive della componente a breve.

Infine,  $Z_t$  rappresenta l’innovazione, ed è una variabile casuale indipendente ed identicamente distribuita con media pari a 0 e varianza unitaria ( $E[Z_t] = 0$  e  $E[Z_t^2] = 1$ ). Inoltre,  $Z_t^2$  ha una distribuzione non degenera con  $\kappa = E[Z_t^4] < \infty$ .

---

<sup>1</sup>Ulteriori differenze con altrettanti modelli saranno trattate in maniera più dettagliata a fine capitolo.



Si assume che la densità di  $Z_t$  sia simmetrica (assunzione fatta comunemente per il GJR-GARCH), per consentire un calcolo diretto di previsione della varianza condizionata *multi-step*, mentre  $\kappa = E[Z_t^4] < \infty$  assicura la finitezza della varianza incondizionata (*Prima assunzione*).

### 2.2.1 Componente a breve termine (GJR-GARCH)

Nell'MF2 di Conrad e Engle, la componente a breve termine  $h_t$  è utilizzata per catturare le dinamiche inerenti alle fluttuazioni transitorie della volatilità, *volatility clustering* e l'asimmetria in risposta agli shock dei mercati. Per modellare tale componente, viene adottata una specificazione GJR-GARCH (Glosten et al., 1993), caratterizzata da varianza unitaria  $E[h_t] = 1$ .

Il GJR-GARCH utilizzato in questo modello presenta alcune differenze rispetto a quello tradizionale di Glosten et al. (1993); infatti, mentre nel GJR standard la varianza condizionata viene aggiornata utilizzando i rendimenti passati al quadrato ( $r_{t-i}^2$ ), nella nuova specificazione la componente a breve termine  $h_t$  viene aggiornata utilizzando rendimenti scalati dalla componente di lungo periodo ( $r_{t-1}^2/\tau_{t-1}$ ); tale modifica significa che lo shock viene normalizzato dal livello corrente della volatilità di lungo periodo prima di entrare nell'equazione del GARCH. Un'altra differenza risiede nella varianza: come già anticipato, nel nuovo modello è specificata come una componente a varianza unitaria. Infatti, affinché  $h_t$  abbia una media pari a 1, è necessario che l'intercetta sia vincolata al valore  $(1 - \phi)$ , dove  $\phi = \alpha + \beta + \gamma/2$ . Invece, nel GJR standard, il parametro  $\omega$ , ossia l'intercetta, deve essere stimato in modo tale da determinare assieme ad  $\alpha$  e  $\beta$  il livello di varianza incondizionata verso cui converge il modello. La specificazione della componente di breve periodo per l'MF2 GARCH è un GJR-GARCH(1,1)

$$h_t = (1 - \phi) + \left( \alpha + \gamma \mathbf{1}_{\{r_{t-1} < 0\}} \right) \frac{r_{t-1}^2}{\tau_{t-1}} + \beta h_{t-1}. \quad (2.4)$$

Si assume inoltre che i parametri soddisfino le condizioni per cui  $\alpha > 0$ ,  $\alpha + \gamma > 0$ ,  $\beta > 0$  e  $\phi < 1$  (*Seconda assunzione*). Se quest'ultima assunzione viene rispettata assieme a  $Z_t$  i.i.d. e con densità simmetrica, allora  $r_t/\sqrt{\tau_t} = \sqrt{h_t}Z_t$  segue un GJR-GARCH(1,1) stazionario in covarianza<sup>2</sup> con  $E[h_t Z_t^2] = E[h_t] = 1$ . Come descrivono Conrad & Engle, se il GJR-GARCH(1,1) cattura interamente l'eteroschedasticità condizionata, allora  $\tau_t$  è pari a una costante e

---

<sup>2</sup>Un processo è stazionario in covarianza se ha media costante, varianza incondizionata finita e costante nel tempo, e autocovarianze che dipendono solo dal lag.

il modello moltiplicativo si riduce a un GJR-GARCH a una componente per i rendimenti giornalieri.

### 2.2.2 Componente a lungo termine (MEM su errori mobili)

L'innovazione principale del modello MF2 risiede nella specificazione della componente a lungo termine,  $\tau_t$ . Il suo scopo principale è catturare le variazioni a bassa frequenza nella volatilità, e la sua specificazione è motivata dall'osservazione empirica per cui gli errori di previsione standardizzati giornalieri dei GARCH a una componente sono prevedibili quando mediati a frequenze più basse.

La componente  $\tau_t$  è specificata come segue

$$\tau_t = \lambda_0 + \lambda_1 V_{t-1}^{(m)} + \lambda_2 \tau_{t-1}, \quad (2.5)$$

in cui

$$V_{t-1}^{(m)} = \frac{1}{m} \sum_{j=1}^m V_{t-j} = \frac{1}{m} \sum_{j=1}^m \frac{r_{t-j}^2}{h_{t-j}}. \quad (2.6)$$

Nell'equazione precedente,  $V_{t-1}^{(m)}$  rappresenta la media mobile su  $m$  periodi dei rendimenti “deGARCHed” al quadrato e una misura a finestra mobile del bias locale della varianza condizionata a breve termine rispetto agli  $m$  giorni precedenti. Sulla base di Engle (2009a), gli autori definiscono  $r_t/\sqrt{h_t}$  come rendimenti deGARCHizzati, e di conseguenza  $V_t = r_t^2/h_t = \tau_t Z_t^2$  come rendimenti deGARCHizzati al quadrato, i quali possono essere pensati come errori di previsione della volatilità standardizzati. Nel caso in cui la componente GARCH riesce a catturare l'eteroschedasticità condizionata, allora, per la prima assunzione, i  $V_t$  sono i.i.d. Tuttavia, Conrad & Engle dimostrano che tale condizione difficilmente si verifica nei dati reali, soprattutto per lunghi orizzonti temporali; quello che si osserva è una persistente autocorrelazione positiva di  $V_t$ . Ciò implica che i GARCH a una componente hanno la tendenza a sottostimare sistematicamente la volatilità durante periodi negativi (recessioni) e a sovrastimarla durante periodi di calma.

L'equazione *Multiplicative Error Model* (MEM) agisce come meccanismo di correzione degli errori: se  $h_t$  ha sottostimato la volatilità nei recenti  $m$  giorni (quindi  $V_{t-1}^{(m)} > 1$ ), un valore elevato di  $V_{t-1}^{(m)}$  fa aumentare  $\tau_t$  attraverso il coefficiente  $\lambda_1$ , correggendo verso l'alto la previsione futura della volatilità. Al contrario, una sovrastima della volatilità porta ad una riduzione di  $\tau_t$ , che

segnala un regime di bassa volatilità. In questo modo  $\tau_t$  apprende dagli errori di previsione passati per adattarsi ai cicli macroeconomici di volatilità.

Affinché il processo della componente a lungo termine sia definito e stazionario (in media), si impongono delle condizioni per i parametri:  $\lambda_0 > 0$ ,  $\lambda_1 > 0$ ,  $\lambda_2 > 0$  e  $\lambda_1 + \lambda_2 < 1$  (*Terza assunzione*).

L'equazione 2.5 può essere scritta anche come un MEM(1,  $m$ ), assumendo che gli  $m$  coefficienti ARCH siano dati da  $\lambda_1/m$ . Il MEM(1,  $m$ ) è stazionario in covarianza se la somma dei coefficienti ARCH e GARCH è minore di 1. Se valgono la prima e la terza assunzione,  $V_t = \tau_t Z_t^2$  è un MEM stazionario in covarianza con  $E[V_t|F_{t-1}] = \tau_t$  e  $E[V_t] = \lambda_0/(1 - \lambda_1 - \lambda_2)$ .

Le equazioni 2.4 e 2.5 forniscono la parametrizzazione nota come MF2-GARCH-rw- $m$ .

### 2.2.3 Stima di Quasi-Massima Verosimiglianza

Per la stima dei parametri del modello, Conrad e Engle utilizzano come metodo la stima di Quasi-Massima Verosimiglianza (QMLE), ossia una tecnica utilizzata per produrre stimatori con caratteristiche simili a quelle degli stimatori di massima verosimiglianza. L'uso della QMLE invece della Massima Verosimiglianza (MLE) è motivato essenzialmente dalla necessità di robustezza rispetto alla reale distribuzione degli errori: ciò significa che viene utilizzata una funzione di log-verosimiglianza gaussiana per la stima dei parametri, anche se la vera distribuzione del modello non è gaussiana. In altre parole, la MLE richiederebbe di specificare la distribuzione di probabilità dei dati, mentre la QMLE non richiede l'esatta specificazione della forma funzionale della densità di probabilità. Le stime dei parametri generate da tale funzione di verosimiglianza sono valide e consistenti, purché siano rispettate determinate condizioni sui momenti<sup>3</sup>. Lo stimatore QMLE per il modello MF2-GARCH è costruito facendo riferimento ai lavori svolti da Wang & Ghysels (2015), che hanno formalizzato la teoria asintotica specificamente per il modello GARCH-MIDAS-RV, e Francq et al. (2024), che estendono la teoria di Wang e Ghysels a un caso senza assunzioni sui momenti per il processo osservato.

Si definiscono  $\boldsymbol{\theta}_{GA} = (\alpha, \beta, \gamma)'$  e  $\boldsymbol{\theta}_{MEM} = (\lambda_0, \lambda_1, \lambda_2)'$  come vettori dei parametri delle componenti a breve e a lungo termine. Inoltre, sia  $\boldsymbol{\theta} = (\boldsymbol{\theta}'_{GA}, \boldsymbol{\theta}'_{MEM})'$ . La funzione di quasi-log-verosimiglianza Gaussiana, con co-

---

<sup>3</sup>Affinché l'inferenza statistica della QMLE sia valida e la varianza incondizionata sia finita, è strettamente necessario che il momento quarto delle innovazioni sia finito ( $\kappa = E[Z_t^4] < \infty$ )

stante omessa, assume la stessa formula del modello del GARCH-MIDAS-RV di Wang e Ghysels e si può scrivere come  $L(\boldsymbol{\theta}|r_T, r_{T-1}, \dots) = \sum_{t=1}^T l_t$  con

$$l_t = -\frac{1}{2} \left[ \ln(h_t) + \ln(\tau_t) + \frac{r_t^2}{h_t \tau_t} \right], \quad (2.7)$$

dove  $h_t = h_t(\boldsymbol{\theta})$  e  $\tau_t = \tau_t(\boldsymbol{\theta})$  sono definiti come nelle equazioni 2.4 e 2.5. La derivata prima e seconda della log-verosimiglianza sono indicate come

$$\mathbf{s}_t(\boldsymbol{\theta}) = \frac{\partial l_t}{\partial \boldsymbol{\theta}} \quad \text{e} \quad \mathbf{d}_t(\boldsymbol{\theta}) = \frac{\partial^2 l_t}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'}. \quad (2.8)$$

La derivata prima può essere scritta come

$$\mathbf{s}_t(\boldsymbol{\theta}) = \frac{1}{2} \left[ \frac{r_t^2}{h_t \tau_t} - 1 \right] \mathbf{y}_t(\boldsymbol{\theta}), \quad (2.9)$$

con

$$\mathbf{y}_t(\boldsymbol{\theta}) = \left( \frac{1}{h_t} \frac{\partial h_t}{\partial \boldsymbol{\theta}} + \frac{1}{\tau_t} \frac{\partial \tau_t}{\partial \boldsymbol{\theta}} \right). \quad (2.10)$$

La derivata seconda è individuata come

$$\mathbf{d}_t(\boldsymbol{\theta}) = \frac{\partial \mathbf{s}_t(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}'} = -\frac{1}{2} \frac{r_t^2}{h_t \tau_t} \mathbf{y}_t(\boldsymbol{\theta}) \mathbf{y}_t(\boldsymbol{\theta})' + \frac{1}{2} \left[ \frac{r_t^2}{h_t \tau_t} - 1 \right] \frac{\partial \mathbf{y}_t(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}'}. \quad (2.11)$$

È importante notare che il processo di ottimizzazione per l'MF2-GARCH presenta una complessità strutturale maggiore rispetto al GARCH-MIDAS-RV. In questo modello, è presente una dipendenza bidirezionale tra  $h_t$  e  $\tau_t$ : la prima dipende dalla seconda, e viceversa; di conseguenza, il calcolo del gradiente richiede il calcolo di derivate incrociate. La derivata di  $h_t$  rispetto al parametro  $\alpha$  dipende dalla derivata di  $\tau_{t-1}$  rispetto ad  $\alpha$  e viceversa. Poiché si osserva solo  $r_t$  per  $t = 1, \dots, T$  con  $T \gg m$ ,  $L(\boldsymbol{\theta}|r_T, r_{T-1}, \dots, r_0, r_{-1}, \dots)$  è inosservabile. Si denota con  $\tilde{L}(\boldsymbol{\theta}|r_T, r_{T-1}, \dots, r_1) = \sum_{t=1}^T \tilde{l}_t$  la versione osservabile che dipende dai valori iniziali per la componente a breve e lungo termine. Utilizzando una notazione simile alla precedente, si definisce la derivata prima e seconda della verosimiglianza osservabile come  $\tilde{\mathbf{s}}_t(\boldsymbol{\theta})$  e  $\tilde{\mathbf{d}}_t(\boldsymbol{\theta})$ . Per lo stimatore di quasi-massima verosimiglianza,  $\hat{\boldsymbol{\theta}}$ , vale che  $\sum_t \tilde{\mathbf{s}}_t(\hat{\boldsymbol{\theta}}) = 0$ .

La distribuzione asintotica dello stimatore QMLE può essere definita sotto alcune condizioni: innanzitutto, si assumono valide le assunzioni dei paragrafi precedenti. Inoltre, si assume che il vero vettore dei parametri  $\boldsymbol{\theta}_0$  giaccia in uno spazio parametrico compatto appropriatamente definito, in cui si

esclude che  $h_t$  e  $\tau_t$  siano pari a zero<sup>4</sup>. Infine, siccome  $\frac{r_t^2}{h_t(\boldsymbol{\theta}_0)\tau_t(\boldsymbol{\theta}_0)} = Z_t^2$ , segue che  $E[s_t(\boldsymbol{\theta}_0)|\mathcal{F}_{t-1}] = 0$ , quindi  $s_t(\boldsymbol{\theta}_0)$  segue una sequenza di differenze di martingala<sup>5</sup>. La distribuzione asintotica della QMLE è data da

$$\sqrt{T}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}(0, \mathbf{D}^{-1}\boldsymbol{\Omega}\mathbf{D}^{-1}), \quad (2.12)$$

dove

$$\boldsymbol{\Omega} = \boldsymbol{\Omega}(\boldsymbol{\theta}_0) = E[s_t(\boldsymbol{\theta}_0)s_t(\boldsymbol{\theta}_0)'] \quad \text{e} \quad \mathbf{D} = \mathbf{D}(\boldsymbol{\theta}_0) = -E[d_t(\boldsymbol{\theta}_0)]. \quad (2.13)$$

Tali espressioni si semplificano in

$$\boldsymbol{\Omega} = \frac{1}{4}(\kappa - 1)E[y_t(\boldsymbol{\theta}_0)y_t(\boldsymbol{\theta}_0)'] \quad \text{e} \quad \mathbf{D} = \frac{1}{2}E[y_t(\boldsymbol{\theta}_0)y_t(\boldsymbol{\theta}_0)']. \quad (2.14)$$

Così come in Wang & Ghysels (2015), si ottiene

$$\mathbf{D}^{-1}\boldsymbol{\Omega}\mathbf{D}^{-1} = (\kappa - 1)(E[y_t(\boldsymbol{\theta}_0)y_t(\boldsymbol{\theta}_0)'])^{-1} = (\kappa - 1) \left( E \left[ \frac{1}{h_t^2 \tau_t^2} \frac{\partial \sigma_t^2}{\partial \boldsymbol{\theta}} \frac{\partial \sigma_t^2}{\partial \boldsymbol{\theta}'} (\boldsymbol{\theta}_0) \right] \right)^{-1}. \quad (2.15)$$

Come discusso da Francq & Zakoïan (2007), se i coefficienti della componente di lungo periodo fossero nulli, la distribuzione asintotica dello stimatore non sarebbe più Normale, rendendo l'inferenza standard non più affidabile. Per affrontare tale problema, si stima un GJR-GARCH a una sola componente e si applica il test di Conrad & Schienle (2020) descritto nella sezione 2.1. Se l'ipotesi nulla viene rifiutata, viene confermata la presenza significativa della componente a lungo termine, e si può procedere alla stima dell'MF2-GARCH tramite QMLE.

---

<sup>4</sup>Nel caso in cui le componenti siano nulle, sorgerebbero alcune complicazioni, tra cui la distribuzione asintotica dello stimatore QMLE che non sarebbe più Gaussiana.

<sup>5</sup>Una sequenza di variabili casuali  $\{s_t\}$  è definita *differenza di martingala* rispetto a una filtrazione  $\mathcal{F}_{t-1}$  se  $E[|s_t|] < \infty$  e  $E[s_t | \mathcal{F}_{t-1}] = 0$ . In pratica, data tutta l'informazione passata, la miglior previsione del valore futuro è zero.

## 2.3 Proprietà teoriche

L'introduzione di una componente di lungo periodo stocastica e indipendente rende più complessa l'analisi delle proprietà teoriche del modello di Conrad & Engle rispetto a modelli GARCH tradizionali. Comunque, il modello mantiene proprietà desiderabili di stazionarietà, che permettono la derivazione della varianza incondizionata, della *News Impact Curve* e di previsioni a più passi avanti (*Multistep Ahead Forecasts*).

### 2.3.1 Stazionarietà e varianza incondizionata

La stazionarietà è uno dei punti critici di questa tipologia di modelli. Modelli come lo Spline-GARCH (Engle & Rangel, 2008) assumono una componente di lungo periodo deterministica che varia nel tempo, rendendo il processo dei rendimenti localmente stazionario, ma non globalmente. Altri modelli, come il GARCH-MIDAS-RV (a volatilità realizzata) presentano una varianza incondizionata divergente o indefinita.

Il modello MF2-GARCH differisce da queste specificazioni in quanto ammette una soluzione stazionaria in covarianza. Per garantire tale proprietà, oltre alle assunzioni sui parametri introdotte in precedenza, è necessario soddisfare anche una condizione di stabilità globale che dipende dall'interazione tra  $h_t$  e  $\tau_t$ . Per derivare l'espressione della varianza incondizionata ed esplicitare tale condizione, gli autori espongono un teorema, secondo cui la varianza incondizionata dei rendimenti giornalieri dipende congiuntamente dai parametri delle rispettive componenti e dal momento quarto delle innovazioni ( $\kappa$ ).

$$Var[r_t] = E[\tau_t h_t] = \left( \lambda_0 + \frac{\lambda_0}{1 - \lambda_1 - \lambda_2} (1 - \phi)(\lambda_1 + \lambda_2) + \Delta_m \right) / (1 - \Gamma_m), \quad (2.16)$$

dove

$$\Delta_m = (1 - \phi) \lambda_1 \frac{\lambda_0}{1 - \lambda_1 - \lambda_2} \left( \frac{m-1}{m} + \frac{1}{m} \sum_{j=2}^m \sum_{k=1}^{j-2} \phi^k \right). \quad (2.17)$$

La condizione di stabilità che deve essere rispettata è la seguente

$$\Gamma_m = (\lambda_1 \frac{1}{m} \phi_k + \lambda_2 \phi) + \lambda_1 \phi_k \frac{1}{m} \sum_{j=2}^m \phi^{j-1} < 1, \quad (2.18)$$

con  $\phi_k = (\alpha + \gamma/2)\kappa + \beta$ . Se la condizione  $\Gamma_m < 1$  è soddisfatta, la varianza incondizionata è finita e costante nel tempo, determinata dall'interazione tra le componenti di breve e lungo periodo. Il fatto che la varianza incondizionata

dipenda dal momento quarto delle innovazioni è dovuto alla correlazione delle due principali componenti; dunque, essa aumenta con  $\kappa$  e diminuisce con  $m$ .

### 2.3.2 News Impact Curve

La *News Impact Curve* (NIC), introdotta da Pagan & Schwert (1990) e poi discussa per altri modelli da Engle & Ng (1993), è una misura utile per valutare in che modo le nuove informazioni vengono incorporate nelle stime di volatilità. Nei modelli GARCH standard, la curva è simmetrica, quindi notizie positive o negative hanno lo stesso effetto sulla volatilità. Tuttavia, l'evidenza empirica suggerisce spesso un comportamento asimmetrico, ossia l'effetto leva, che viene catturato da modelli come il GJR e l'MF2.

Per quanto riguarda un GJR-GARCH(1,1) con varianza condizionata definita come  $\tilde{h}_t = \omega + (\alpha + \gamma \mathbf{1}_{\{r_{t-1} < 0\}})r_{t-1}^2 + \beta \tilde{h}_{t-1}$ , la NIC è definita come

$$\text{NIC}_{t+1}^{GJR} = \tilde{h}_{t+1}(r_t | \tilde{h}_t) = A_t^{GJR} + (\alpha + \gamma \mathbf{1}_{\{r_t < 0\}})r_t^2, \quad (2.19)$$

in cui  $A_t^{GJR} = \omega + \beta h_t$  rappresenta l'intercetta della NIC e il livello di volatilità previsto prima di considerare le nuove informazioni. Il modello riesce a catturare l'effetto asimmetrico tramite il coefficiente  $\gamma$ , ma ha un problema di natura strutturale, ovvero che la reattività della varianza condizionata agli shock è costante.

Infatti, i parametri fissi  $\alpha$  e  $\gamma$  determinano l'entità dell'effetto marginale delle nuove informazioni e non dipendono in alcun modo dal livello di volatilità corrente. Tale caratteristica si traduce in uno shock che produce i medesimi effetti sulla volatilità futura, che sia in una fase di calma o in una fase di turbolenza dei mercati; ciò crea una rigidità che non permette al modello di cogliere la dinamica per cui, nei periodi di stress, variazioni ampie dei prezzi sono eventi attesi e dovrebbero avere un minore impatto sul rischio atteso rispetto a quando avvengono in periodi stabili.

La NIC del modello MF2-GARCH risolve il problema di rigidità presente nel GJR tramite una struttura più complessa che incorpora lo stato corrente della volatilità. La funzione è costituita da tre termini distinti ed è definita come segue

$$\text{NIC}_{t+1}^{MF} = \sigma_{t+1}^2(r_t | \tau_t, h_t) = A_t^{MF} + B_t^{MF} + \left( \lambda_1 \beta \frac{1}{m} + \lambda_2 (\alpha + \gamma \mathbf{1}_{\{r_t < 0\}}) \right) r_t^2. \quad (2.20)$$

Questa struttura dinamica *state-dependent*<sup>6</sup> consente di studiare l'impatto delle nuove informazioni su più livelli. Analizzandola, si può denotare come l'impatto marginale delle nuove informazioni non sia fisso, ma varia in funzione delle componenti  $h_t$  e  $\tau_t$ .

In maniera analoga al GJR-GARCH, l'intercetta  $A_t^{MF}$ , nota condizionata a  $\mathcal{F}_{t-1}$ , incorpora la componente che penalizza maggiormente i rendimenti negativi, garantendo un maggiore impatto sulla varianza condizionata.

$$\begin{aligned} A_t^{MF} = & \lambda_0(1 - \phi) + \lambda_0\beta h_t + \lambda_1(1 - \phi) \frac{1}{m} \sum_{j=1}^{m-1} \frac{r_{t-j}^2}{h_{t-j}} \\ & + \lambda_1\beta h_t \frac{1}{m} \sum_{j=1}^{m-1} \frac{r_{t-j}^2}{h_{t-j}} + \lambda_2(1 - \phi)\tau_t + \lambda_2\beta\sigma_t^2. \end{aligned} \quad (2.21)$$

La novità è invece introdotta dalla componente  $B_t^{MF}$  grazie alla presenza della componente di lungo periodo al denominatore che, in base al suo valore, genera output differenti: nel caso in cui vi sia bassa volatilità, e quindi  $\tau_t$  basso, aumenta la sensibilità agli shock, e la nuova informazione viene percepita come un evento inatteso, portando a una revisione delle previsioni di rischio e ad una curva ripida. Al contrario, per  $\tau_t$  alto (regime di alta volatilità), grandi spostamenti dei prezzi sono eventi attesi e prevedibili e hanno un impatto marginale minore sulle aspettative future, generando così una curva piatta. Il termine  $B_t^{MF}$  mostra che l'effetto marginale di  $r_t^2$  dipende anche dalla varianza condizionata corrente,  $\sigma_t^2$ , così come da  $h_t$  e  $\tau_t$  singolarmente.

$$\begin{aligned} B_t^{MF} = & \lambda_0 \left( \alpha + \gamma \mathbf{1}_{\{r_t < 0\}} \right) \frac{r_t^2}{\tau_t} + (1 - \phi) \frac{1}{m} \frac{r_t^2}{h_t} + \lambda_1 \left( \alpha + \gamma \mathbf{1}_{\{r_t < 0\}} \right) \frac{1}{m} \frac{r_t^4}{\sigma_t^2} \\ & + \lambda_1 \left( \alpha + \gamma \mathbf{1}_{\{r_t < 0\}} \right) \frac{r_t^2}{\tau_t} \frac{1}{m} \sum_{j=1}^{m-1} \frac{r_{t-j}^2}{h_{t-j}}. \end{aligned} \quad (2.22)$$

La dinamica della *News Impact Curve* è strettamente dipendente dalla scelta e dalla stima del parametro  $m$ . La sua selezione non è arbitraria, ma si basa su un approccio data-driven: Conrad e Engle stimano il modello MF2 standard e l'estensione con pesi beta<sup>7</sup> per valori di  $m$  fino a 160 e selezionano il valore ottimale di  $m$  che minimizza il *Bayesian Information Criterion* (BIC). Tale approccio si rivela il più efficace per la NIC del modello. I risultati ottenuti mostrano che il valore di  $m$  che minimizza il BIC è pari a 63 giorni: questo da-

---

<sup>6</sup>Il termine *state-dependent* indica che la funzione di risposta alle nuove informazioni cambia al variare dello stato del processo.

<sup>7</sup>L'estensione in questione viene presentata successivamente nella sezione 2.4.1.



to suggerisce come la componente di lungo periodo rifletta maggiormente cicli economici su base trimestrale. Se si confronta tale parametro con le finestre mensili o semestrali, si denota rispettivamente una componente di lungo periodo troppo volatile e una componente eccessivamente liscia, che non si adatta in maniera efficiente ai cambi di regime. Per  $m = 63$ ,  $\tau_t$  varia gradualmente ma in maniera decisa quando si presentano cambiamenti strutturali; tale comportamento consente alla NIC di appiattirsi durante periodi di alta volatilità, rendendo prevedibili i cambiamenti rapidi di prezzi, e accentuare l'ampiezza nei periodi di calma, quando le nuove informazioni impattano maggiormente. Tali caratteristiche sono anche visibili nella figura 2.2 che mostra la NIC (standardizzata) per l'MF2-GARCH-rw- $m$  con  $m = 63$  e  $m = 21$ . La NIC viene rappresentata in funzione del rendimento per  $\tau_t \in \{0.5, 1, 1.5\}$  e sulla base di parametri ottimali<sup>8</sup>. Inoltre, si fissa componente di breve periodo pari al suo valore medio incondizionato, ossia  $h_t = 1$ , e si assume che preveda correttamente la volatilità nei giorni da  $t - 1$  a  $t - m - 1$  (viene posto  $r_{t-j}^2/h_{t-j} = 1$  per  $j = 1, \dots, m - 1$ ), mentre i parametri della componente di lungo periodo sono stati scelti in modo tale che  $E[\tau_t] = 1$ . Di conseguenza, la linea nera continua rappresenta lo scenario in cui sia  $h_t$  che  $\tau_t$  sono al loro livello medio. La NIC è standardizzata in modo tale che l'impatto delle notizie sia nullo per  $r_t = 0$  e viene riportato in termini di volatilità annualizzata (con 252 giorni di trading), per cui si può tracciare

$$\sqrt{252 (\sigma_{t+1}^2(r_t \mid r_{t-m}, h_t = 1) - \sigma_{t+1}^2(r_t = 0 \mid r_{t-m}, h_t = 1))}.$$

Il termine di asimmetria di  $h_t$  provoca un impatto maggiore dei rendimenti negativi rispetto a quelli positivi, e le altre due linee mostrano che l'effetto delle nuove informazioni diventa più forte (più debole) nel momento in cui la volatilità di lungo periodo è al di sotto (al di sopra) della propria aspettativa, evidenziando una volatilità condizionata più sensibile alle notizie nei periodi di bassa volatilità. Il risultato è ragionevole poiché ci si aspetta un valore assoluto di  $r_t$  più elevato durante fasi turbolente e più basso in fasi tranquille. Di conseguenza, coerentemente con l'osservazione per cui la varianza dei rendimenti diminuisce all'aumentare di  $m$ , l'impatto delle notizie risulta più debole per  $m = 63$  rispetto a  $m = 21$ , confermando di fatto la robustezza della dinamica di lungo periodo, che riesce a filtrare maggiormente il rumore di breve periodo.

---

<sup>8</sup>I valori utilizzati, e descritti nella figura 2.2, riflettono le proprietà tipiche delle serie storiche, ossia elevata persistenza della volatilità ed effetto leva, senza violare le assunzioni del modello.




Figura 2.2: *News Impact Curve (standardizzata) dell'MF2-GARCH-rw-m con  $m = 63$  e  $m = 21$ . I parametri utilizzati per la stima sono  $\alpha = 0.02$ ,  $\gamma = 0.1$ ,  $\beta = 0.8$ ,  $\lambda_0 = 0.02$ ,  $\lambda_1 = 0.05$  e  $\lambda_2 = 0.94$ .*

### 2.3.3 Previsioni multi-step e misure di rischio

Una proprietà fondamentale del modello MF2-GARCH è la possibilità di costruire previsioni di volatilità a più passi avanti, dovuta alla caratteristica del modello stesso di essere dinamicamente completo e di specificare interamente la dinamica della varianza condizionata. Le previsioni *multi-step* possono essere generate per ogni orizzonte desiderato e possono essere calcolate ricorsivamente.

Sulla base del set informativo  $\mathcal{F}_t$ , la previsione al tempo  $t$  per la volatilità al periodo  $t+s$  (ovvero  $E[\sigma_{t+s}^2|\mathcal{F}_t]$ ), è ottenuta iterando le aspettative condizionate di  $h_{t+s}$  e  $\tau_{t+s}$ . Per  $s \geq 2$ , la previsione a  $s$ -passi avanti della componente a breve periodo è indicata da

$$E[h_{t+s}|\mathcal{F}_t] = 1 + \phi^{s-1}(h_{t+1} - 1). \quad (2.23)$$

Le previsioni per la componente a lungo termine per  $s \geq 2$  sono ricorsivamente calcolate come segue

$$\begin{aligned} E[\tau_{t+s}|\mathcal{F}_t] &= \lambda_0 + \left(\lambda_1 \frac{1}{m} + \lambda_2\right) E[\tau_{t+s-1}|\mathcal{F}_t] \\ &+ \lambda_1 \frac{1}{m} \sum_{j=2}^{s-1} E[\tau_{t+s-j}|\mathcal{F}_t] + \lambda_1 \frac{1}{m} \sum_{j=s}^m \frac{r_{t+s-j}^2}{h_{t+s-j}}. \end{aligned} \quad (2.24)$$

Per  $s \geq m$ , la previsione è la seguente

$$E[\tau_{t+s}|\mathcal{F}_t] = \lambda_0 + \left(\lambda_1 \frac{1}{m} + \lambda_2\right) E[\tau_{t+s-1}|\mathcal{F}_t] + \lambda_1 \frac{1}{m} \sum_{j=2}^m E[\tau_{t+s-j}|\mathcal{F}_t]. \quad (2.25)$$

Grazie a questi risultati, può essere descritta la varianza condizionata  $E[\sigma_{t+s}^2|\mathcal{F}_t]$ . Sotto le tre assunzioni del modello e l'equazione 2.16, è possibile individuare la previsione per la varianza condizionata in  $t + s$  per  $s \geq 1$

$$E[\sigma_{t+1}^2|\mathcal{F}_t] = h_{t+1}\tau_{t+1}. \quad (2.26)$$

Per  $s \geq 2$ , le previsioni possono essere calcolate ricorsivamente come

$$\begin{aligned} E[\sigma_{t+s}^2|\mathcal{F}_t] &= (1 - \phi)E[\tau_{t+s}|\mathcal{F}_t] + \lambda_0\phi E[h_{t+s-1}|\mathcal{F}_t] \\ &\quad + \left(\lambda_1 \frac{1}{m}\phi_k + \lambda_2\phi\right) E[\sigma_{t+s-1}^2|\mathcal{F}_t] \\ &\quad + \lambda_1\phi E[h_{t+s-1}|\mathcal{F}_t] \frac{1}{m} \sum_{j=s}^m \frac{r_{t+s-j}^2}{h_{t+s-j}} \\ &\quad + (1 - \phi)\lambda_1\phi \frac{1}{m} \sum_{j=2}^{s-1} E[\tau_{t+s-j}|\mathcal{F}_t] \left(1 + \sum_{k=1}^{j-2} \phi^k\right) \\ &\quad + \lambda_1\phi_k\phi \frac{1}{m} \sum_{j=2}^{s-1} \phi^{j-2} E[\sigma_{t+s-j}^2|\mathcal{F}_t]. \end{aligned} \quad (2.27)$$

Infine, per  $s \geq m$ , si applica la seguente formula ricorsiva

$$\begin{aligned} E[\sigma_{t+s}^2|\mathcal{F}_t] &= (1 - \phi)E[\tau_{t+s}|\mathcal{F}_t] + \lambda_0\phi E[h_{t+s-1}|\mathcal{F}_t] \\ &\quad + \left(\lambda_1 \frac{1}{m}\phi_k + \lambda_2\phi\right) E[\sigma_{t+s-1}^2|\mathcal{F}_t] \\ &\quad + (1 - \phi)\lambda_1\phi \frac{1}{m} \sum_{j=2}^m E[\tau_{t+s-j}|\mathcal{F}_t] \left(1 + \sum_{k=1}^{j-2} \phi^k\right) \\ &\quad + \lambda_1\phi_k\phi \frac{1}{m} \sum_{j=2}^m \phi^{j-2} E[\sigma_{t+s-j}^2|\mathcal{F}_t]. \end{aligned} \quad (2.28)$$

In generale, dai risultati emerge che nel breve termine la previsione di volatilità condizionata si avvicinerà alla previsione della componente a lungo termine prima di convergere alla volatilità incondizionata nel lungo periodo.

La struttura dinamica dell'MF2-GARCH, permettendo la costruzione di tali previsioni di volatilità multi-step, consente la stima di misure di rischio finanziario dinamiche su orizzonti temporali estesi. Sotto l'ipotesi che le innovazioni standardizzate  $Z_t$  seguano una distribuzione Normale con media 0

e varianza unitaria, il *Value at Risk* condizionato al tempo  $t$  per un orizzonte  $s$  e un livello di confidenza  $p$  può essere espresso in funzione della volatilità prevista

$$VaR_{p,t+s|t} = - \left( \mu_{t+s|t} + z_p \sqrt{E[\sigma_{t+s}^2 | \mathcal{F}_t]} \right), \quad \text{con } z_p = \Phi^{-1}(p), \quad (2.29)$$

dove  $z_p$  rappresenta il quantile della distribuzione dell'innovazione. Se si assume una distribuzione  $t$  di Student, il VaR è definito come

$$VaR_{p,t+s|t} = - \left( \mu_{t+s|t} + \frac{t_{\nu,p}}{\sqrt{\nu/(\nu-2)}} \sqrt{E[\sigma_{t+s}^2 | \mathcal{F}_t]} \right). \quad (2.30)$$

Analogamente, l'*Expected Shortfall*, che misura la perdita attesa condizionata al superamento del *Value at Risk*, beneficia della scomposizione a due fattori del modello MF2. Per una distribuzione Normale, si può definire l'*Expected Shortfall* a step  $s$  come segue

$$\begin{aligned} ES_{p,t+s|t} &= - \left( \mu_{t+s|t} + E[Z_{t+s} | Z_{t+s} \leq z_p] \sqrt{E[\sigma_{t+s}^2 | \mathcal{F}_t]} \right) \\ &= -\mu_{t+s|t} + \frac{\phi(z_p)}{p} \sqrt{E[\sigma_{t+s}^2 | \mathcal{F}_t]}, \end{aligned} \quad (2.31)$$

dove  $\phi(z_p)$  rappresenta la funzione di densità di probabilità della Normale standard. Nel caso in cui l'innovazione standardizzata  $Z_t$  segua una distribuzione  $t$  di Student con  $\nu$  gradi di libertà, l'*expected shortfall* al livello  $p$  viene definito in maniera analoga al caso Normale come la perdita attesa condizionata al superamento del VaR; in questo caso  $z_p = q_p / \sqrt{\nu/(\nu-2)}$ , dove  $q_p = t_v^{-1}(p)$  è il quantile utilizzato nella specificazione  $t$  di Student. In questo modo, l'*expected shortfall* risulta

$$ES_{p,t+s|t} = -\mu_{t+s|t} + \frac{1}{\sqrt{\nu/(\nu-2)}} \frac{\nu + q_p^2}{\nu - 1} \frac{f_\nu(q_p)}{p} \sqrt{E[\sigma_{t+s}^2 | \mathcal{F}_t]}, \quad (2.32)$$

dove  $f_\nu(\cdot)$  indica la densità della  $t_\nu$ .

Il vantaggio teorico del modello MF2 per il calcolo di *Value at Risk* ed *Expected Shortfall* risiede nella componente  $\tau_{t+s}$ , la quale rimane elevata in periodi di alta volatilità e consente di mantenere sia il VaR che l'ES su livelli elevati più a lungo evitando la sottostima del rischio. Nell'ultimo capitolo questi due aspetti verranno analizzati e testati empiricamente, valutando la capacità previsiva e l'accuratezza tramite procedure di backtesting.

## 2.4 Estensioni del modello

La struttura flessibile del modello di Conrad e Engle consente la creazione di diverse estensioni del modello, le quali saranno confrontate con il modello base *rolling-window* nell'analisi *in-sample* per valutarne le proprietà parametriche e la bontà di adattamento ai dati.

### 2.4.1 MF2-GARCH con pesi beta

Nella specificazione base,  $V_{t-1}^{(m)}$  è una media aritmetica degli errori passati. In questa specificazione del modello invece, ispirandosi a Ghysels et al. (2006), gli autori fanno sì che i pesi assegnati agli errori passati non siano più costanti ( $1/m$ ), ma seguano una funzione Beta decrescente, che consente agli errori passati di avere un maggiore impatto sulla componente di lungo periodo.

La nuova parametrizzazione prende il nome di MF2-GARCH-bw- $m$ , in cui “bw- $m$ ” non indica altro che “*beta weights*” di lunghezza  $m$ . La forma con la media ponderata è

$$V_{t-1}^{(m)} = \sum_{j=1}^m w_j(\omega) V_{t-j} = \sum_{j=1}^m w_j(\omega) \frac{r_{t-j}^2}{h_{t-j}}, \quad (2.33)$$

in cui i pesi sono forniti dallo schema di ponderazione Beta ristretto

$$w_j(\omega) = \frac{(1 - j/(m+1))^{\omega-1}}{\sum_{k=1}^m (1 - k/(m+1))^{\omega-1}}. \quad (2.34)$$

In questo nuovo schema, per costruzione, la somma dei pesi è uguale a 1. Inoltre, si impone che i pesi siano non crescenti e in base al valore di  $\omega$  differiscono gli output. Nel caso in cui  $\omega = 1$ , il modello convergerà al modello MF2 classico con media mobile semplice, in quanto i pesi risultano uguali in tutti i giorni e di conseguenza pari a  $1/m$ ; invece, per  $\omega > 1$ , i pesi sono decrescenti. In particolare, i pesi decrescono dal primo lag, il che fa intuire come dati meno recenti perdano importanza nel modello, e quest'ultimo assume con più rilevanza solamente i dati più recenti.

### 2.4.2 Componente di lungo periodo a bassa frequenza

La componente di lungo periodo del modello base ha la caratteristica di variare secondo una frequenza giornaliera. Nella seguente estensione del modello, è previsto che la componente a lungo termine vari a una frequenza minore rispet-

to a quella a breve. La parametrizzazione prende il nome di MF2-GARCH-lf- $n$ , in cui “lf” sta per “*low-frequency*” e  $n$  si riferisce alla scelta del periodo a bassa frequenza.

Per introdurla, è necessario introdurre una notazione per le frequenze miste: il periodo “*high-frequency*” è individuato da  $i$ , e rappresenta essenzialmente i giorni, mentre la notazione  $t$  individua il periodo “*low-frequency*” e può rappresentare una frequenza mensile, trimestrale o semestrale. In questo modo si può assumere che vi siano  $t = 1, \dots, T$  periodi, in cui in ognuno di questi vi siano  $n$  giorni, quindi  $i = 1, \dots, n$ .

Gli autori procedono con la denotazione del rendimento logaritmico nel giorno  $i$  del periodo  $t$  ( $r_{i,t}$ ) e del set informativo  $\mathcal{F}_{i,t}$ . Per garantire la continuità computazionale tra i periodi a bassa frequenza, si adotta per convenzione  $r_{0,t} = r_{n,t-1}$  e la coerenza informativa viene assicurata definendo  $\mathcal{F}_t := \mathcal{F}_{n,t}$ .

Nel seguito, si consideri che valga la prima assunzione per le innovazioni  $Z_{i,t}$ . La componente a breve si può definire

$$h_{i,t} = (1 - \phi) + \left( \alpha + \gamma \mathbf{1}_{\{r_{i-1,t} < 0\}} \right) \frac{r_{i-1,t}^2}{\tau_t} + \beta h_{i-1,t}, \quad (2.35)$$

per  $i = 2, \dots, n$  e  $h_{0,t} = h_{n,t-1}$ . Invece, nel momento in cui  $i = 1$ , la componente si scrive

$$h_{1,t} = (1 - \phi) + \left( \alpha + \gamma \mathbf{1}_{\{r_{n,t-1} < 0\}} \right) \frac{r_{n,t-1}^2}{\tau_{t-1}} + \beta h_{n,t-1}, \quad (2.36)$$

in modo tale che si possa considerare il periodo precedente quando si sceglie il primo giorno di un determinato periodo.

Per quanto riguarda la componente a lungo periodo, si assume valida la *seconda assunzione* e si definisce una specificazione MEM *low-frequency*. Innanzitutto, si procede con la media dei quadrati dei rendimenti deGARCHizzati nel periodo a bassa frequenza  $t$

$$V_t = \frac{1}{n} \sum_{i=1}^n \frac{r_{i,t}^2}{h_{i,t}} = \tau_t \frac{1}{n} \sum_{j=1}^n Z_{j,t}^2 = \tau_t \bar{Z}_t, \quad (2.37)$$

con  $E[\bar{Z}_t] = 1$  e  $\text{Var}(\bar{Z}_t) = (\kappa - 1)/n$ . La *prima assunzione* consente di scrivere la specificazione

$$\tau_t = \lambda_0 + \lambda_1 V_{t-1} + \lambda_2 \tau_{t-1}. \quad (2.38)$$

Dall'equazione di  $V_t$  si evince che la componente di lungo periodo *low-frequency* misura la volatilità in unità giornaliera, il che risulta essere un grande vantag-

gio in termini di interpretabilità, poiché consente un confronto diretto con la componente di breve periodo.

In maniera analoga all'MF2-GARCH base, se valgono la *prima* e la *terza assunzione*,  $V_t = \tau_t \bar{Z}_t$  è un MEM stazionario in covarianza. L'unico limite dettato da questa specificazione deriva dalla discontinuità delle varianze condizionate giornaliere, le quali implicano che i rendimenti giornalieri non siano più stazionari in covarianza.

## 2.5 Differenze con altri modelli

Per rafforzare il contributo apportato dal modello MF2-GARCH, è fondamentale confrontarlo con le principali alternative presenti in letteratura, evidenziando le differenze strutturali, vantaggi e limitazioni.

Un primo confronto può essere effettuato con i modelli classici GARCH e con l'estensione GJR in termini di *mean reversion*; ad esempio, un GARCH(1,1) risulta essere troppo rigido da questo punto di vista. Se si prende in considerazione un periodo molto turbolento con volatilità elevata, come la crisi del 2008, un GARCH(1,1) tenderà a prevedere un ritorno troppo rapido alla media storica bassa, sottostimando di conseguenza il rischio. Tale problema si verificherebbe anche nella situazione opposta, in quanto in periodi di calma prolungata potrebbe sovrastimare il rischio prevedendo un ritorno verso l'alto. Il problema si risolve con la componente  $\tau_t$  dell'MF2, che adatta localmente il livello di *mean reversion*: se la volatilità è persistentemente elevata,  $\tau_t$  aumenta, e la componente  $h_t$  fluttua attorno al nuovo livello anziché la media storica globale. Un ulteriore confronto può essere effettuato con lo Spline-GARCH di Engle & Rangel (2008): in questo modello la componente  $\tau_t$  è deterministica e funzione del tempo, utile per analisi ex-post ma problematica per previsioni ex-ante. Nell'MF2, la componente di lungo periodo è generata dinamicamente dagli shock passati, pertanto si presenta come un processo stocastico adattivo e non deterministico, il che lo rende ideale per analisi “*out-of-sample*”.

Un modello che si avvicina molto a quello di Conrad e Engle è il GARCH-MIDAS (Engle et al., 2013): in particolare, vi sono il GARCH-MIDAS-X (Asgharian et al., 2013) e il GARCH-MIDAS-RV (Wang & Ghysels, 2015) che mostrano alcuni limiti non presenti nell'MF2.

Rispettivamente, il primo modello utilizza variabili esogene (ad esempio, inflazione) per guidare la componente a lungo termine; quindi, presenta il principale limite dovuto alla scelta delle variabili corrette e della frequenza dei dati ma-

cro. L'MF2 risolve questa dinamica generando la propria variabile esplicativa  $V_{t-1}^{(m)}$  internamente ai rendimenti, e cattura direttamente l'impatto delle diverse condizioni economiche, senza che siano aggiunte ulteriori variabili; questo fa sì che il modello MF2 sia superiore a livello pratico rispetto al MIDAS-X. Il secondo modello si basa sull'utilizzo della volatilità realizzata su finestre mobili; in particolare, mentre nell'MF2  $\tau_t$  segue una specificazione MEM guidata dagli errori di previsione passati, nel GARCH-MIDAS-RV si assume una componente di lungo periodo che dipende da una varianza realizzata a finestra mobile e può essere scritta come

$$\tau_t^{GM} = c + \lambda_1 \sum_{j=1}^K w_j(\omega) RV_{t-j}^{rw}, \quad (2.39)$$

dove  $c$  corrisponde a  $\lambda_0$  nella tabella 4.1 e

$$RV_{t-1}^{rw} = \frac{1}{m} \sum_{s=1}^m r_{t-s}^2. \quad (2.40)$$

Lo schema di ponderazione beta segue l'equazione 2.34. Nel GARCH-MIDAS-RV il problema risiede nella stazionarietà, poiché è dimostrato a livello teorico che tale modello implica una varianza incondizionata infinita per i rendimenti, e questo risulta essere un grande ostacolo nell'applicazione empirica. L'MF2 invece è progettato in modo tale che i rendimenti siano stazionari in covarianza e che la varianza incondizionata sia finita; pertanto, a livello teorico risulta essere più solido del MIDAS-RV. In conclusione, la specificazione di Conrad & Engle presenta tutti i presupposti per essere un ottimo modello di previsione, con performance superiori e meno limiti rispetto ad altri modelli presenti in letteratura. Nel prossimo capitolo sarà introdotto il *dataset* principale oggetto dell'analisi su cui verrà valutata la capacità predittiva del modello.



# Capitolo 3

## Dataset

Questo capitolo presenta tutti i dati che verranno utilizzati nelle varie analisi, che includono il dataset relativo all'indice principale di riferimento, ossia l'S&P 500, e alla serie di volatilità realizzata, utile nelle analisi *out-of-sample*. Inoltre, si utilizzano anche indicatori di tipo macroeconomico, che assumono rilevanza per capire la composizione della componente a lungo termine.

### 3.1 S&P 500

In questa sezione viene illustrato il dataset principale sul quale sarà valutato il modello MF2. L'obiettivo è quello di confrontare la performance previsionale di quest'ultimo con i rispettivi modelli benchmark e con le estensioni dello stesso.

Il dataset è un'estensione del dataset originale utilizzato da Conrad & Engle, ed è costituito dai rendimenti giornalieri logaritmici dell'S&P 500. Esso è un indice azionario ponderato per la capitalizzazione di mercato che traccia la performance delle principali 500 società quotate nelle borse degli Stati Uniti e attualmente è riconosciuto come il miglior indicatore singolo delle azioni statunitensi large-cap. Conrad e Engle coprono un periodo che va da inizio gennaio 1971 fino alla fine di giugno 2023. Invece, in questo lavoro il dataset di riferimento è stato esteso fino alla fine di settembre 2025.

Questi dati sono stati estratti da YahooFinance; in particolare, sono stati scaricati i prezzi di chiusura per il periodo considerato, da cui sono stati ricavati i rendimenti logaritmici giornalieri.

$$r_t = 100(\log(P_t) - \log(P_{t-1})). \quad (3.1)$$

Valutare le performance di previsione è difficile a causa della natura latente della volatilità, che è inosservabile; dunque, è necessaria un'approssimazione per la volatilità realizzata. Gli autori costruiscono le varianze realizzate giornaliere utilizzando dati intraday forniti da TickData; nello specifico, definiscono le varianze realizzate giornaliere  $RV_t$  come la somma dei log-rendimenti intraday al quadrato più il log-rendimento overnight al quadrato.

Questo approccio richiede l'utilizzo di dati ad alta frequenza che, oltre ad essere difficilmente reperibili, rendono la stima della volatilità molto complessa; pertanto, è necessario trovare un altro benchmark per la volatilità.

Generalmente, nel caso in cui siano disponibili solamente i prezzi di chiusura giornalieri, una proxy più semplice della varianza giornaliera è data dal rendimento giornaliero al quadrato. Tuttavia, questa proxy risulta fortemente rumorosa, in quanto basata su una singola osservazione giornaliera che non consente una separazione accurata della componente sistematica della volatilità dalle fluttuazioni idiosincratich.

Per ovviare a questo problema, in questo lavoro sono utilizzate le stime di volatilità fornite da Da & Xiu (2021)<sup>1</sup>; tali stime sono calcolate mediante lo stimatore di Quasi-Massima Verosimiglianza (QMLE) basato su modelli a media mobile (MA(q)), utilizzando i rendimenti non nulli dei prezzi di transazione (o *mid-quote*, se disponibili) campionati alla massima frequenza disponibile, per i giorni con almeno 12 osservazioni. Poiché tali stime sono basate esclusivamente su dati intraday e non incorporano la componente overnight, nella sezione dedicata all'analisi *out-of-sample* verrà adottato un aggiustamento di scala volto a migliorare la comparabilità con la varianza giornaliera dei rendimenti dell'S&P 500. L'adozione dello stimatore di Da & Xiu (2021) e l'aggiustamento di scala per la componente overnight fornisce quindi una misura della volatilità realizzata robusta e sensibilmente meno rumorosa rispetto alla proxy dei rendimenti al quadrato.

---

<sup>1</sup>Nell'appendice è descritto il processo per l'ottenimento dei dati di volatilità.

### 3.2 Serie storica

La serie storica utilizzata in questa tesi, come già anticipato nella sezione precedente, include i prezzi e i rendimenti dell'indice S&P 500. Si considera in questa analisi come periodo di riferimento l'intervallo che va da gennaio 1971 al settembre 2025. Tale periodo temporale verrà utilizzato principalmente per le previsioni *in-sample*, mentre per le previsioni *out-of-sample* viene tagliata una soglia iniziale di dati, che implica un intervallo temporale che parte dagli anni 2000.




Figura 3.1: *Serie temporale dei prezzi logaritmici ( $p_t$ ).*

Dalla figura 3.1 si denota l'evidente crescita nel corso degli anni dell'indice, giustificata da un insieme di fattori strutturali ed economici. Si presenta un trend al rialzo caratterizzato da picchi negativi che catturano perfettamente le fasi di volatilità e le grandi crisi finanziarie. Questi effetti sono maggiormente visibili nella figura 3.2. Le principali fasi di instabilità si sono verificate intorno al 2001 e al 2002, a causa dello scoppio della bolla *Dot-com*, per poi ripresentarsi nel 2008 con la crisi del mercato immobiliare, e infine dopo il 2020, con le variazioni dei prezzi e dei consumi dovute alla pandemia. Attualmente, si possono notare prezzi abbastanza volatili a causa del boom dell'intelligenza artificiale. Una caratteristica fondamentale di queste serie di RV è la marcata persistenza di lungo periodo, ossia la memoria lunga, che risulta visibile nelle funzioni di autocorrelazione nella figura 3.3.




Figura 3.2: *Distribuzione della varianza realizzata e del logaritmo della varianza realizzata dell'indice S&P 500 nel periodo 2000–2025.*




Figura 3.3: *Autocorrelazione della varianza realizzata e del logaritmo della varianza realizzata dell'indice S&P 500 nel periodo 2000–2025.*

Dalla figura 3.3 emerge un calo netto per i primi ritardi, mentre successivamente la riduzione diventa più graduale, delineando un andamento di tipo iperbolico. Questo lento trend decrescente registra dei valori abbastanza elevati anche dopo ritardi maggiori di 100; tale evidenza suggerisce una possibile inadeguatezza dei modelli a memoria corta per descrivere la dinamica della volatilità, e giustifica l'impiego di modelli a più componenti, come l'MF2-GARCH, per migliorare le previsioni su orizzonti medio lunghi. Pertanto, in questa analisi, le serie di volatilità realizzata saranno utili in quanto sono alla base delle previsioni *out-of-sample*. L'importanza di questa tipologia di previsione deriva dalla mancata valutazione della gestione del rischio a lungo termine, e l'MF2-GARCH, essendo progettato per modellare tale componente, verrà testato per vedere se sarà in grado di migliorare le previsioni di volatilità a lungo termine.

### 3.3 Equity Market Volatility Tracker & WSJ Stock Jumps

Per comprendere in maniera più accurata i fattori economici che determinano la volatilità di lungo periodo del modello MF2-GARCH, è possibile mettere in relazione la componente di lungo periodo del modello MF2-GARCH con il tracker Equity Market Volatility (EMV).

I tracker EMV costruiti da Baker et al. (2019) sono degli indicatori che mettono in relazione la volatilità del mercato azionario, misurata tramite l'indice di volatilità implicita (VIX) o la volatilità realizzata, con le notizie inerenti la politica e l'economia. L'obiettivo del tracker è catturare le percezioni dei giornalisti riguardo a tutte le tipologie di fattori che possono guidare le fluttuazioni dei rendimenti, in modo tale da scomporre il tracker complessivo in sottocomponenti. I tracker EMV utilizzati in questo studio sono reperibili a partire dal 1985 nel database FRED gestito dalla Federal Reserve Bank di St. Louis; ogni tracker è disponibile per una frequenza massima pari a un mese. In particolare, nell'analisi sono utilizzati 6 tracker:

- *Overall*: è la misura generale dell'EMV, e quantifica quanto intensamente i giornali parlino di volatilità del mercato azionario.
- *Macro News & Outlook*: misura la componente dell'EMV legata a notizie sul quadro macroeconomico e sulle prospettive sull'economia reale, come crescita, recessione e mercato del lavoro. Questo tracker include temi presenti a loro volta in altre frazioni degli articoli EMV, pertanto tende

a muoversi in maniera molto simile all'EMV complessivo e al VIX (o alla volatilità realizzata) e mostra forti aumenti durante fasi di incertezza. Il tracker appare nel 72% degli articoli totali EMV.

- *Monetary Policy*: identifica la parte dell'EMV legata alle notizie su decisioni e strumenti di politica monetaria. Risulta quindi sensibile a episodi in cui la volatilità è ricondotta a nuove policy o cambi di regime monetario, che spostano le aspettative sui tassi futuri e influenzano la volatilità a lungo termine. Il tracker appare nel 30% degli articoli.
- *Fiscal Policy*: cattura le notizie EMV che collegano la volatilità a scelte di politica fiscale, quindi spesa pubblica, tasse e riforme fiscali. Questo tracker si mostra stabile per lunghi periodi, ma può impennarsi in episodi incerti, come durante la crisi del debt ceiling del 2011, dove il tracker ha mostrato il suo picco più marcato. La fiscal policy appare nel 35% degli articoli EMV.
- *Inflation*: il tracker dell'inflazione è una sottocomponente del tracker macro principale e misura quanto la volatilità viene attribuita alle notizie sulle dinamiche dei prezzi. L'inflazione ha la particolarità di influire sulla volatilità tramite più canali, risultando una delle componenti più informative.
- *Interest Rates*: il tracker dei tassi d'interesse, come quello precedente, è una sottocategoria del tracker macro. Per costruzione, la categoria risulta fortemente correlata al tracker di politica monetaria, ma nel lungo periodo le due serie presentano differenze informative.



Figura 3.4: Serie “Equity Market Volatility Tracker: Overall” (EMVOVERAL-LEMV). Fonte: Federal Reserve Bank of St. Louis, FRED.

I tracker anticipati in questa sezione saranno alla base della regressione che lega la componente a lungo termine dell’MF2-GARCH ai vari indicatori macroeconomici.

Oltre ai tracker, per comprendere l’impatto delle notizie macroeconomiche sulla volatilità, è necessario analizzare gli effetti istantanei e intermedi delle principali notizie di mercato. Pertanto, grazie ad un ulteriore dataset fornito da Baker et al. (2019), si esegue un’ulteriore analisi che prende in considerazione giorni con grandi movimentazioni dei rendimenti dell’indice S&P 500 (i cosiddetti *jumps*). Il dataset non include le grandi movimentazioni del mercato oltre il 2022, pertanto saranno esclusi gli ultimi anni di contrattazioni. Per questa tipologia di analisi, tale dataset è costruito considerando i giorni di contrattazione in cui il mercato ha presentato rendimenti pari o superiori al 2.5% in valore assoluto; a questi movimenti deve essere attribuita una causa, e di conseguenza viene analizzata la rassegna stampa del giorno successivo all’evento, prendendo in considerazione le principali testate giornalistiche statunitensi, ossia *Wall Street Journal*, *New York Times*, *Chicago Tribune*, *Washington Post* e *LA Times*. Dopodiché, degli analisti esaminano gli articoli e ne attribuiscono una causa categorica, primaria o secondaria, al movimento del mercato. Infine, sulla base delle assegnazioni fornite, vengono elaborati degli indicatori continui, che includono valori compresi tra 0 e 1, per 16 tipologie di eventi. Al fine di valutare l’impatto sulle previsioni del modello MF2-GARCH, nella sezione dedicata verrà stimata una regressione focalizzata su tre categorie di notizie, ossia *Macroeconomic News & Outlook*, *Corporate Earnings & Outlook* e *Monetary Policy & Central Banking*.

# Capitolo 4

## Analisi empirica

Il presente capitolo ha lo scopo di mettere alla prova il modello standard MF2-GARCH-rw con diversi modelli introdotti precedentemente. L'obiettivo è dunque comprendere in che modo il modello si adatti ai dati e definire quanto le sue previsioni siano accurate, soprattutto nel medio-lungo periodo, dove il modello dovrebbe performare meglio. La performance predittiva sarà misurata tramite funzioni di perdita che utilizzano come proxy del target previsivo la volatilità realizzata, e verrà effettuato un confronto di performance su due periodi differenti, per valutare come reagisce il modello a diversi cambiamenti di trend. Successivamente, sono presentati i risultati di una simulazione Monte Carlo, che consentono la valutazione del comportamento dello stimatore QMLE del modello MF2 in campioni finiti. Il capitolo prosegue con l'analisi di determinati fattori macroeconomici che possono influenzare diversamente la volatilità e la componente di lungo periodo. Infine, viene esaminata l'applicabilità delle previsioni del modello nel calcolo delle misure del VaR e dell'Expected Shortfall, e tramite procedure di backtesting e test congiunti, ne vengono analizzate la calibrazione e l'accuratezza previsiva. Per tutte le analisi effettuate in questo capitolo, è stato utilizzato Matlab.

### 4.1 Analisi in-sample

Nella tabella 4.1 sono presentate le stime dei parametri relative ai vari modelli, per l'intero periodo campionario da gennaio 1971 a settembre 2025. Innanzitutto, sono presenti le stime relative al GJR-GARCH; dai risultati è evidente una forte persistenza della componente GARCH ( $\alpha + \gamma/2 + \beta = 0.9791$ ). Successivamente, sono mostrate le stime per l'MF2-GARCH-rw- $m$ .



Per quanto riguarda il modello con finestra ottimale<sup>1</sup>, ossia  $m = 63$ , le stime della componente a lungo termine sono entrambe significative ( $\lambda_1$  e  $\lambda_2$ ) e la persistenza nella componente a lungo termine ( $\lambda_1 + \lambda_2 = 0.9811$ ) è maggiore di quella a breve termine ( $\alpha + \gamma/2 + \beta = 0.9259$ ). Una particolarità di quest'ultima componente è che, a causa dell'introduzione della componente di lungo periodo che varia nel tempo, la componente GJR dell'MF2-GARCH risulta meno persistente rispetto al GJR ad una componente. Se si confrontano i risultati della funzione log-verosimiglianza e del BIC dell'MF2-GARCH-rw-63 con gli altri modelli, il valore più alto di LLF e il più basso del BIC mostrano la potenziale superiorità predittiva del modello. Per illustrare le conseguenze della scelta di un  $m$  troppo piccolo o troppo grande, sono presentate le stime degli errori di previsione passati per una media mensile e semestrale (rispettivamente,  $m = 21$  e  $m = 126$ ). Per  $m = 21$ , il risultato più evidente è un incremento della persistenza notevole rispetto al modello trimestrale ( $\lambda_1 + \lambda_2 = 0.9947$ ). Questo dato deriva da un aumento di  $\lambda_2$  che smussa la componente di lungo periodo e contrasta l'effetto della diminuzione di  $m$ . Per  $m = 126$ , le stime risultano molto simili al modello trimestrale, soprattutto per la componente a lungo termine, ma in questo caso si denota un aumento degli errori standard (soprattutto per  $\lambda_1$ , che diventa non più significativo), che fa preferire il primo modello a finestra trimestrale.

Per la specificazione MF2-GARCH-bw- $m$  la specificazione ottimale rimane anche in questo caso quella a finestra trimestrale. Le stime sono estremamente simili alla controparte *rolling window*. Il valore di  $\omega$  pari a 1 lascia intuire uno schema di ponderazione piatto e che dunque richiama l'altro modello; i risultati sia in termini di coefficienti che di log-verosimiglianza indicano che impostare una ponderazione su queste previsioni con questo orizzonte temporale ha un impatto marginale. La vera differenza si può osservare con una finestra semestrale, quindi per  $m = 126$ . Rispetto al modello *rolling window*, gli errori standard per  $\lambda_1$  e  $\lambda_2$  sono molto più contenuti; inoltre i coefficienti sono significativi e la migliore capacità predittiva in questo contesto è confermata dal valore di log-verosimiglianza più elevato. Pertanto, il modello con schema di ponderazione *beta* supera la specificazione base, qualora si considerasse una finestra semestrale.

Per i modelli MF2-GARCH-lf- $n$ , sono mostrate le stime dei parametri per una componente a lungo termine trimestrale ( $n = 63$ ) e mensile ( $n = 21$ ). Per

---

<sup>1</sup>Come descritto nella sezione 2.3.2, il valore ottimale di  $m$  è ottenuto ristimando il modello standard e la sua estensione con pesi beta per valori di  $m$  fino a 160; il valore più basso del BIC si ottiene per  $m = 63$ .

la specificazione con finestra trimestrale, il parametro  $\lambda_2$  non è significativo. Questo implica che per  $n$  grande è sufficiente un MEM(0,1) per catturare l'aspettativa condizionata di  $V_t$ . La situazione cambia se si riduce la grandezza della finestra temporale: per  $n = 21$  i parametri diventano significativi e si preferisce un MEM(1,1). Anche in questo caso, la specificazione base rimane comunque superiore se si osservano i valori di  $BIC$  e log-verosimiglianza. Infine, viene stimato il GARCH-MIDAS-RV. Le finestre temporali considerate sono trimestrali e mensili, e il modello segue uno schema di ponderazione beta con  $K = 252$ . Nel MIDAS-RV,  $\lambda_1$  misura l'effetto della  $RV_t^{rw}$  sulla volatilità a lungo termine, che è stimato positivo. Tuttavia, anche in questo caso, i risultati del BIC favoriscono la specificazione base MF2 con finestra trimestrale.

Tabella 4.1: Risultati delle stime *in-sample* sull'S&P 500.

| $\tau_t$              | $\alpha$              | $\gamma$              | $\beta$               | $\lambda_0$           | $\lambda_1$           | $\lambda_2$           | $\omega$               | LLF         | BIC    |
|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|-----------------------|------------------------|-------------|--------|
| <b>GJR-GARCH</b>      |                       |                       |                       |                       |                       |                       |                        |             |        |
| Costante              | 0.0213***<br>(0.0033) | 0.1218***<br>(0.0042) | 0.8968***<br>(0.0070) |                       |                       |                       |                        | -17 488.644 | 2.5378 |
| <b>MF2-GARCH-rw-m</b> |                       |                       |                       |                       |                       |                       |                        |             |        |
| $m = 63$              | 0.0010<br>(0.0014)    | 0.1642***<br>(0.0189) | 0.8428***<br>(0.0178) | 0.0179<br>(0.0114)    | 0.1073*<br>(0.0605)   | 0.8738***<br>(0.0709) |                        | -17 411.820 | 2.5280 |
| $m = 21$              | 0.0000<br>(0.0000)    | 0.1756***<br>(0.0190) | 0.8180***<br>(0.0251) | 0.0050**<br>(0.0021)  | 0.0336***<br>(0.0118) | 0.9611***<br>(0.0133) |                        | -17 421.610 | 2.5300 |
| $m = 126$             | 0.0092<br>(0.0059)    | 0.1488***<br>(0.0204) | 0.8659***<br>(0.0235) | 0.0212<br>(0.0830)    | 0.1070<br>(0.4330)    | 0.8704*<br>(0.5202)   |                        | -17 435.040 | 2.5310 |
| <b>MF2-GARCH-bw-m</b> |                       |                       |                       |                       |                       |                       |                        |             |        |
| $m = 63$              | 0.0110<br>(0.0165)    | 0.1643***<br>(0.0513) | 0.8428***<br>(0.0942) | 0.0179<br>(0.0560)    | 0.1074<br>(0.2602)    | 0.8738***<br>(0.3139) | 1.0000<br>(3.5328)     | -17 411.820 | 2.5290 |
| $m = 126$             | 0.0000<br>(0.0770)    | 0.1697***<br>(0.2070) | 0.8284***<br>(0.0264) | 0.0086**<br>(0.0036)  | 0.0554**<br>(0.0227)  | 0.9356***<br>(0.0253) | 4.7980***<br>(1.1816)  | -17 419.520 | 2.5300 |
| <b>MF2-GARCH-lf-n</b> |                       |                       |                       |                       |                       |                       |                        |             |        |
| $n = 63$              | 0.0124**<br>(0.0055)  | 0.1481***<br>(0.0197) | 0.8660***<br>(0.0147) | 0.1692***<br>(0.0506) | 0.7615***<br>(0.1352) | 0.0604<br>(0.1494)    |                        | -17 426.620 | 2.5300 |
| $n = 21$              | 0.0055<br>(0.0065)    | 0.1664***<br>(0.0193) | 0.8295***<br>(0.0237) | 0.0677***<br>(0.0212) | 0.4057***<br>(0.0997) | 0.5236***<br>(0.1073) |                        | -17 423.580 | 2.5300 |
| <b>GARCH-MIDAS-RV</b> |                       |                       |                       |                       |                       |                       |                        |             |        |
| $m = 63$              | 0.0036<br>(0.0032)    | 0.1796***<br>(0.0194) | 0.8119***<br>(0.0079) | 0.3387***<br>(0.0074) | 0.5949***<br>(0.0004) |                       | 85.8780***<br>(3.9012) | -17 432.690 | 2.5310 |
| $m = 21$              | 0.0086<br>(0.0040)    | 0.1819***<br>(0.0139) | 0.8188***<br>(0.0046) | 0.3592***<br>(0.0202) | 0.5648***<br>(0.1468) |                       | 4.6433***<br>(0.1218)  | -17 433.887 | 2.5310 |

*Note:* La tabella riporta le stime per i vari modelli (per il GARCH-MIDAS-RV si considera  $K = 252$  e  $c = \lambda_0$ , come indicato nell'equazione 2.40). I modelli sono stati stimati utilizzando i rendimenti giornalieri dell'indice S&P 500 per il periodo compreso tra gennaio 1971 e settembre 2025. I numeri tra parentesi sono gli errori standard. \*\*\*, \*\* e \* indicano rispettivamente la significatività all'1%, al 5% e al 10%. LLF è il valore della funzione di verosimiglianza massimizzata e il BIC è il criterio informativo bayesiano.

La figura 4.1 consente di visualizzare il comportamento delle due componenti principali del modello MF2; in particolare, è presentata la volatilità condizionata annualizzata,  $\sqrt{h_t\tau_t}$ , e la volatilità a lungo termine,  $\sqrt{\tau_t}$ , ricavati dalle stime dell'MF2-GARCH-rw-63 sui rendimenti giornalieri dell'S&P 500 della tabella 4.1.




Figura 4.1: La figura mostra la volatilità condizionata stimata,  $\sqrt{h_t\tau_t}$ , e la volatilità a lungo termine,  $\sqrt{\tau_t}$ , ottenute dal modello MF2-GARCH-rw-63 per i rendimenti giornalieri dell'S&P 500 riportati nella tabella 4.1. I valori sono espressi su base annualizzata.

L'andamento di  $\sqrt{\tau_t}$  riflette l'andamento dell'errore standardizzato medio del modello GJR-GARCH riportato nella figura 2.1. Inoltre,  $\sqrt{\tau_t}$  evolve in modo più regolare e riesce a cogliere i movimenti ciclici della volatilità di fondo. La volatilità condizionata  $\sqrt{h_t\tau_t}$  riflette le varie fasi del mercato, cogliendo gli shock elevati mediante picchi pronunciati nelle fasi turbolente. In questo modo, è possibile vedere la scomposizione del modello tra una componente di breve periodo, volta ad assorbire le variazioni improvvise, e una componente di lungo periodo, che riflette il regime di volatilità prevalente. Si osserva una volatilità di lungo periodo che rimane elevata in corrispondenza del crollo del 1987, della crisi del 2008 e della pandemia del 2020, in linea con l'ipotesi di cicli persistenti. Nella sezione 4.5 verrà descritto anche in che modo le diverse tipologie di notizie guidano la componente a lungo termine.

La figura 4.2 considera il sottoperiodo della pandemia e permette di interpretare più accuratamente i risultati della tabella 4.1. All'inizio della pandemia, la volatilità condizionata aumenta in entrambi i modelli, ma si denota una differenza nel momento in cui essa si riduce; la volatilità dell'MF2 deca-

de più velocemente rispetto al modello GJR, a causa non solo della diversa persistenza dei modelli, ma anche al modo con cui la volatilità condizionata risponde agli shock. Dalla figura emerge anche una crescita nel tempo della componente di lungo periodo, dovuta alla transizione da tempi normali, con minori errori di previsione, a tempi eccezionali, che presentano errori elevati. Di fatto, tale evidenza implica che la curva dell'MF2 si piazza sopra la curva del GJR nel lungo periodo, segnalando rischi più elevati.




Figura 4.2: Sulla base delle stime della tabella 4.1, si osserva il periodo incluso tra gennaio 2020 e giugno 2021. La figura riporta la volatilità condizionata stimata del modello MF2-GARCH-rw-63,  $\sqrt{h_t \tau_t}$ , la sua componente di lungo periodo,  $\sqrt{\tau_t}$ , e la volatilità condizionata del modello GJR-GARCH,  $\sqrt{\sigma_t^2}$ .

Le stesse conclusioni si possono trarre anche prendendo in considerazione tempi più recenti. In particolare, si presenta una grande crescita della volatilità di entrambi i modelli in corrispondenza dell'annuncio dei dati da parte dell'amministrazione Trump. Anche qui, pur osservando un picco decisamente inferiore a quello del Covid, si osservano gli stessi effetti: un decadimento più rapido per l'MF2, affiancato ad un valore più elevato sia della componente a lungo termine che della volatilità condizionata nei periodi successivi, segnalando un rischio maggiore rispetto al secondo modello.




Figura 4.3: Sulla base delle stime della tabella 4.1, si osserva il periodo incluso tra gennaio 2025 e settembre 2025. Si guardino le note della figura 4.2.

## 4.2 Implicazioni per la previsione della volatilità

La sezione presenta il comportamento delle previsioni della volatilità dell'MF2-GARCH-rw- $m$ ; in particolare è possibile analizzare le differenze tra le previsioni di quest'ultimo e quelle di un GJR-GARCH, sfruttando i dati ottenuti nella tabella 4.1. La figura 4.4 illustra tale confronto: i pannelli sulla sinistra mostrano la volatilità condizionata e la componente di lungo periodo del modello MF2 per due sottocampioni, mentre i pannelli a destra mostrano la volatilità condizionata del modello GJR. Inoltre, viene presentata la volatilità condizionata per l'intero periodo campionario, da gennaio 1971 fino a settembre 2025, per confrontare le previsioni con la dinamica effettiva della volatilità; le previsioni *out-of-sample* sono ottenute ristimando il modello fino al giorno precedente l'origine considerata. Le origini delle previsioni corrispondono al 10 agosto 2011, al 14 settembre 2016 e al 13 marzo 2020, le quali sono state scelte per descrivere determinati scenari utili per il confronto: il primo periodo considerato è uno scenario di crisi e alta volatilità, dovuto a un aumento del debito sovrano europeo e a un declassamento del rating creditizio degli Stati Uniti da parte di Standard & Poor's. Il secondo periodo considerato è caratterizzato da un trend stabile a bassa volatilità con un picco temporaneo, dovuto al timore associato ad un possibile rialzo dei tassi di interesse da parte della Federal Reserve. L'ultimo periodo rappresenta uno scenario di volatilità

estrema, dovuto allo scoppio della pandemia.




Figura 4.4: Sulla sinistra, le previsioni MF2-GARCH-rw-63 e, sulla destra, le previsioni GJR-GARCH, indicate dalla linea blu. Ogni riga descrive un periodo temporale differente. La linea rossa indica la componente di lungo periodo  $\tau$  e la relativa previsione è individuata dalla linea rossa tratteggiata. La linea nera rappresenta la volatilità condizionata e la linea grigia tratteggiata indica la volatilità incondizionata. Le rispettive previsioni dei modelli sono individuate dalla linea nera tratteggiata.

Per le previsioni della figura 4.4, si assume che i due modelli abbiano la medesima volatilità condizionata nel punto di origine della previsione e la stessa volatilità incondizionata. I dati sono annualizzati.

Nel primo periodo la volatilità condizionata e la componente di lungo periodo si trovano al di sotto della volatilità incondizionata finché non si verifica il salto della volatilità nel punto di origine considerato. La previsione del GJR-GARCH sovrastima la volatilità a seguito dello shock, e ciò è spiegato dalla persistenza elevata della componente a breve termine. Le previsioni del modello MF2, invece, rispecchiano l'andamento effettivo della volatilità condizionata, grazie alla minore persistenza della componente a breve.

Nel secondo periodo i pannelli mostrano che, per un certo periodo, la volatilità condizionata è rimasta al di sotto della volatilità incondizionata. Questo implica che, all'origine della previsione, la componente di lungo periodo sia

anch'essa al di sotto della volatilità incondizionata. Tuttavia, il trend stabile viene "rotto" da uno shock improvviso, che causa un rialzo della volatilità condizionata poco prima dell'origine della previsione, e quest'ultima, come nel caso precedente, è ancora al di sopra della volatilità incondizionata nel punto di origine della previsione. I risultati per il GJR mostrano una convergenza verso la volatilità incondizionata, mentre per l'MF2 si può descrivere una previsione che converge alla previsione di  $\tau$ . Si può dedurre che la previsione MF2-GARCH convergerà verso la volatilità incondizionata solamente nel lunghissimo periodo.

Nel terzo periodo, il modello GJR prevede che, dopo il picco all'origine della previsione, la volatilità rimanga su livelli abbastanza elevati per i mesi successivi. Pertanto, analogamente al primo periodo, emerge il limite legato all'eccessiva persistenza derivante dalla singola componente del modello. Quest'ultimo interpreta lo shock del Covid come un cambiamento strutturale quasi permanente, che porta ad una sovrastima della volatilità. Il modello MF2 mostra invece un comportamento più realistico, con una previsione che scende più rapidamente. Tale comportamento deriva dalla capacità del modello di attribuire gran parte dello shock alla componente a breve termine; inoltre, l'MF2, pur registrando un aumento di  $\tau$ , riconosce la natura temporanea del picco di volatilità, e fa convergere la previsione verso la componente a lungo termine. Tali risultati dimostrano il fatto che il modello MF2-GARCH cattura l'osservazione empirica per cui esistano dei movimenti ciclici persistenti attorno alla volatilità incondizionata.

### 4.3 Previsioni Out-of-Sample

Per validare con successo un modello di previsione, è necessario distinguere tra la capacità del modello stesso di adattarsi ai dati storici e la sua capacità di prevedere valori futuri ancora non osservati. Per questo motivo, la letteratura accademica concorda sul fatto che l'accuratezza di un modello di previsione debba essere valutata mediante test *out-of-sample*, piuttosto che solo sulla bontà di adattamento ai dati passati. L'utilizzo esclusivo di test *in-sample* presenta alcune limitazioni: gli errori calcolati nel campione tendono a sovrastimare l'errore di previsione reale, in quanto le procedure di stima e di selezione del modello sono progettate per calibrare i parametri sulla specifica storia dei dati disponibili. Tuttavia, le dinamiche del passato non persistono necessariamente nel futuro, e quelle future potrebbero non essersi manifestate

nei dati storici. Inoltre, un modello selezionato esclusivamente per il suo eccellente adattamento ai dati passati non garantisce le migliori performance per i dati futuri.

Tale distinzione metodologica assume una certa rilevanza nella gestione del rischio finanziario, dove l'attenzione si è concentrata molto spesso su previsioni a breve termine, trascurando la stabilità delle stime su orizzonti estesi. L'importanza di questi ultimi è discussa in diversi studi: Christoffersen & Diebold (2000) ribadiscono l'importanza di integrare sia previsioni a breve che a lungo termine, ciascuna con la propria utilità in base al contesto in cui viene adottata. Engle (2009) ribadisce che la pratica del risk management si è storicamente fondata su metriche di breve periodo, spesso applicate anche alla valutazione di posizioni mantenute su orizzonti molto estesi. Tale approccio può risultare problematico, poiché le misure di rischio vengono proiettate su scadenze più lunghe sotto l'assunzione che il rischio rimanga invariato nel tempo. Pertanto, Engle introduce il concetto secondo cui “c'è il rischio che il rischio cambi”: su orizzonti temporali estesi le condizioni macroeconomiche e di mercato variano profondamente, e ignorare la natura dinamica della volatilità assumendo un rischio costante può portare ad una sottostima del rischio di portafoglio, come emerso durante la crisi del 2008. Infine, Ederington & Guan (2010) sottolineano che i modelli di pricing di opzioni e i modelli di *Value-at-Risk* a lungo termine richiedono previsioni di volatilità su periodi più lunghi rispetto alla frequenza dei dati. Il fallimento della gestione del rischio durante la crisi finanziaria è stato, in parte, attribuito proprio alla maggiore attenzione sulla componente a breve. A seguito di queste considerazioni, la seguente sezione si propone di analizzare la volatilità a lungo termine, in particolare sarà valutata l'efficacia del modello MF2 tramite l'approccio *out-of-sample* nel migliorare l'accuratezza delle previsioni su orizzonti temporali lunghi per rispondere alla necessità dell'adozione di strumenti più robusti per la gestione del rischio di lungo periodo.

### 4.3.1 Valutazione pre-covid

Le prime previsioni *out-of-sample* vengono effettuate nel periodo tra gennaio 2010 e dicembre 2019, prima dello scoppio della pandemia. La scelta di questo sottocampione risponde all'esigenza di valutare le capacità predittive dei modelli in un contesto più regolare, privo di shock estremi che potrebbero dominare le funzioni di perdita. Il campione esteso a settembre 2025, che sarà analizzato nella sezione successiva, consente invece di testare la robustezza dei



modelli in presenza di un contesto più irregolare, caratterizzato dalla pandemia nel 2020 e dal ciclo di rialzo dei tassi nel 2022.

Per testare la validità dell'MF2-GARCH, si utilizza la specificazione standard basata sullo schema di ponderazione a finestra mobile. L'analisi *out-of-sample* viene condotta confrontando le sue performance con altri modelli discussi precedentemente: il GJR-GARCH e il GARCH-MIDAS-RV. In particolare, per l'MF2-GARCH e per il GARCH-MIDAS-RV si considerano per la lunghezza della finestra  $m = 21$  e  $m = 63$ . Inoltre, nel MIDAS-RV si fissa  $k = 252^2$ , in modo tale da includere circa un anno di informazione passata nella componente a lungo termine.

Per valutare correttamente la qualità delle previsioni della volatilità condizionata da parte dei modelli, sono necessarie le funzioni di perdita. In questo caso si sono considerate due funzioni: l'RMSE e la QLIKE. Il Root Mean Square Error è la radice quadrata della media degli scarti quadratici tra la varianza realizzata, utilizzata come proxy della vera varianza condizionata, e la varianza predetta dal modello, ossia la varianza condizionata; la funzione penalizza maggiormente gli errori di ampia entità. La Quasi-likelihood loss deriva dalla funzione di quasi-verosimiglianza gaussiana; tale versione robusta viene descritta da Patton (2011) e appartiene alla classe delle funzioni di perdita robuste alla sostituzione della varianza vera con una proxy rumorosa. A differenza dell'RMSE, che penalizza simmetricamente gli episodi di sottostima e sovrastima della varianza, la QLIKE si comporta in maniera asimmetrica e attribuisce un peso maggiore agli episodi di sottostima, rendendo le due funzioni complementari nell'analisi proposta.

Una volta stabilite le funzioni di perdita da utilizzare, si può descrivere il processo per l'ottenimento delle previsioni *out-of-sample* seguendo uno schema a media mobile e delle perdite per ogni orizzonte considerato. Innanzitutto, si dispone dei rendimenti logaritmici giornalieri per il periodo considerato e della volatilità realizzata annualizzata di Da & Xiu (2021), che viene convertita in varianza giornaliera per poter funzionare come proxy del processo

$$RV_t = \frac{(\sigma_t^{ann})^2}{252},$$

dove 252 corrisponde al numero dei giorni di negoziazione in un anno. Per ogni data di origine  $t$  nel periodo OOS considerato, si costruisce una finestra

---

<sup>2</sup>Nel GARCH-MIDAS-RV,  $k$  indica il numero di lag della volatilità realizzata inclusi nella componente di lungo periodo.

di stima rolling di 10 anni

$$W_t = \{t - 2520, \dots, t - 1\}.$$

A differenza di Conrad e Engle, che utilizzano la volatilità realizzata basata su dati intraday ricavati da Tick Data, nell'analisi seguente si utilizza la volatilità realizzata costruita da Da & Xiu (2021). Come già anticipato nel terzo capitolo, i dati intraday sono difficili da reperire, e si potrebbe valutare come alternativa l'utilizzo dei rendimenti giornalieri al quadrato come proxy della volatilità; tuttavia, Patton (2011) evidenzia come l'utilizzo di un dataset di volatilità realizzata risulti più affidabile rispetto ad una proxy costruita sui rendimenti al quadrato. Andersen & Bollerslev (1998) mostrano infatti come i rendimenti al quadrato costituiscano uno stimatore non distorto della varianza condizionata latente, poiché se si assume  $r_t = \sigma_t z_t$ , si ha  $E_{t-1}[r_t^2] = \sigma_t^2$ . Tuttavia, poiché  $r_t^2 = \sigma_t^2 z_t^2$ , il termine idiosincratico  $z_t^2$  introduce un errore di misurazione: l'elevata variabilità di questa componente implica che la frazione di varianza attribuibile alla volatilità sia molto bassa, rendendo i rendimenti al quadrato una misura ex post molto rumorosa, che può condurre a valutazioni inaccurate delle previsioni di volatilità. Per quanto riguarda la componente overnight, Conrad e Engle aggiungono ai dati di intraday i log-rendimenti al quadrato overnight. Poiché il dataset di Da e Xiu fornisce solamente osservazioni per i giorni in cui si sono verificati almeno 12 rendimenti non nulli dei prezzi di transazione, nel periodo temporale considerato non sono presenti osservazioni per tutti i giorni di negoziazione<sup>3</sup>. Pertanto, risulterebbe inappropriato aggiungere i log-rendimenti al quadrato overnight: qualora mancasse un giorno nel dataset, il rendimento *close-to-open* coprirebbe un intervallo superiore a una notte, rendendo l'intervallo temporale non omogeneo rispetto alle altre osservazioni. Per questo motivo, si estende la misura limitata alle sole ore di contrattazione ad un orizzonte di 24 ore, in maniera analoga a Ahoniemi & Lanne (2010) e Hansen & Lunde (2005), ricorrendo a un fattore di scala  $\hat{c}$  stimato sul periodo pre-OOS (2000-2009). Esso è ottenuto come segue

$$\hat{c} = \frac{\sum_{t \in \mathcal{S}} r_t^2}{\sum_{t \in \mathcal{S}} RV_t}, \quad (4.1)$$

dove  $\mathcal{S}$  corrisponde al periodo *in-sample*. Una volta ottenuto il fattore, si

---

<sup>3</sup>Nel dataset di volatilità realizzata, nel campione completo dal 2000 al 2025 mancano 27 osservazioni giornaliere, pari a circa lo 0.42% del campione. Le stime e le previsioni sono eseguite sul campione allineato alle date disponibili di Da e Xiu.

definisce la proxy scalata

$$RV_t^{SC} = \hat{c} \cdot RV_t. \quad (4.2)$$

Per questioni di praticità, la varianza realizzata giornaliera scalata sarà indicata con  $RV_t$ , pertanto si pone  $RV_t := RV_t^{sc}$ .

Dopodiché, i parametri dei modelli vengono ristimati ogni 21 giorni, e si utilizzano gli stessi parametri per i giorni successivi fino al prossimo aggiornamento. In ogni giorno OOS si producono previsioni per la varianza a breve termine (1 giorno, 1 settimana) e a medio-lungo termine (da 1 a 8 mesi), ossia la *varianza forward* a  $s$ -mesi con  $s \in \{1, \dots, 8\}$ .

In generale, le previsioni multi-periodo della varianza sono ottenute aggregando le previsioni giornaliere della varianza condizionata sull'intervallo forward di interesse. Considerando  $\hat{\sigma}_{t+j|t}^2$  come la previsione a  $j$  passi della varianza condizionata prodotta all'origine  $t$ , la previsione sull'intervallo  $[t+a, t+b]$  è

$$\hat{\sigma}_{t+a_s, t+b_s|t}^2 = \sum_{j=a_s}^{b_s} \hat{\sigma}_{t+j|t}^2, \quad (4.3)$$

dove  $s = 1, \dots, 8$ ,  $a_s = (s-1) \cdot 21 + 1$  e  $b_s = s \cdot 21$ . Ad esempio, la previsione MF2 della varianza forward a 2 mesi è

$$\hat{\sigma}_{t+22, t+42|t}^2 = \sum_{j=22}^{42} \hat{\sigma}_{t+j|t}^2.$$

In maniera analoga, il target della varianza realizzata forward sull'intervallo  $[t+a, t+b]$  è costruito come somma delle varianze realizzate giornaliere

$$RV_{t+a_s, t+b_s} = \sum_{j=a_s}^{b_s} RV_{t+j}. \quad (4.4)$$

Per una previsione OOS più accurata, è importante definire un benchmark storico, che prevede la varianza realizzata forward come media passata della varianza realizzata giornaliera calcolata sulla finestra di 10 anni antecedente l'origine  $t$

$$\mu_{RV,t} = \frac{1}{2520} \sum_{i \in W_t} RV_i. \quad (4.5)$$

In questo modo, il benchmark storico sull'intervallo forward  $[t+a, t+b]$  è definito

$$\widehat{RV}_{t+a_s, t+b_s|t}^{\text{Hist}} = \mu_{RV,t} (b_s - a_s + 1). \quad (4.6)$$

Tale formula rappresenta la previsione proporzionale alla lunghezza dell'oriz-

zonte  $(b_s - a_s + 1)$ , il quale, per gli orizzonti mensili, è pari a 21, mentre per gli orizzonti Day e Week valgono rispettivamente 1 e 5.

Una volta definite le variabili, è possibile individuare le funzioni di perdita. Sia  $RV_{t+a_s, t+b_s}$  il target della varianza realizzata definito nell'equazione 4.4 e sia  $\hat{\sigma}_{t+a_s, t+b_s|t}^2$  la previsione del modello definita nell'equazione 4.3; per ogni modello e su ogni orizzonte vengono calcolate le perdite giornaliere nel periodo OOS e vengono aggregate tramite media campionaria.

Il Root Mean Square Error sull'intervallo forward per il modello è

$$RMSE^{\text{Mod}} = \sqrt{\frac{1}{N} \sum_{t \in \text{OOS}} \left( RV_{t+a_s, t+b_s} - \hat{\sigma}_{t+a_s, t+b_s|t}^2 \right)^2}, \quad (4.7)$$

dove  $N$  è il numero di origini OOS per cui sono disponibili le informazioni fino a  $t + b_s$ . In maniera analoga, si consideri  $\widehat{RV}_{t+a_s, t+b_s|t}^{\text{Hist}}$ , definita nell'equazione 4.6, come la previsione della varianza realizzata; l'RMSE per il benchmark è

$$RMSE^{\text{Hist}} = \sqrt{\frac{1}{N} \sum_{t \in \text{OOS}} \left( RV_{t+a_s, t+b_s} - \widehat{RV}_{t+a_s, t+b_s|t}^{\text{Hist}} \right)^2}. \quad (4.8)$$

La Quasi-likelihood segue la formulazione descritta da Patton (2011); per il modello principale e per il benchmark, le specificazioni per i vari intervalli sono le seguenti

$$QLIKE^{\text{Mod}} = \frac{1}{N} \sum_{t \in \text{OOS}} \left[ \frac{RV_{t+a_s, t+b_s}}{\hat{\sigma}_{t+a_s, t+b_s|t}^2} - \log \left( \frac{RV_{t+a_s, t+b_s}}{\hat{\sigma}_{t+a_s, t+b_s|t}^2} \right) - 1 \right], \quad (4.9)$$

e

$$QLIKE^{\text{Hist}} = \frac{1}{N} \sum_{t \in \text{OOS}} \left[ \frac{RV_{t+a_s, t+b_s}}{\widehat{RV}_{t+a_s, t+b_s|t}^{\text{Hist}}} - \log \left( \frac{RV_{t+a_s, t+b_s}}{\widehat{RV}_{t+a_s, t+b_s|t}^{\text{Hist}}} \right) - 1 \right]. \quad (4.10)$$

Per migliorare la leggibilità dei dati e la comparabilità tra i vari orizzonti, si utilizzano le misure relative rispetto al benchmark storico:

$$RelRMSE = \frac{RMSE^{\text{Mod}}}{RMSE^{\text{Hist}}}, \quad RelQLIKE = \frac{QLIKE^{\text{Mod}}}{QLIKE^{\text{Hist}}}. \quad (4.11)$$

Nel pannello A, il modello MF2-GARCH-rw-63 risulta il più performante sulla maggior parte degli orizzonti temporali; in particolare, all'aumentare dell'orizzonte temporale, il modello risulta sovraperformare nel lungo periodo, se paragonato agli altri. A seguire, il modello MF2-GARCH-rw-21 offre risulta-

Tabella 4.2: Out-of-sample forecasting: S&amp;P 500 – pre-Covid-19.

|                                | Orizzonte di previsione |       |       |       |       |       |       |       |       |       |
|--------------------------------|-------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
|                                | Day                     | Week  | 1 m   | 2 m   | 3 m   | 4 m   | 5 m   | 6 m   | 7 m   | 8 m   |
| <b>Panel A: Relative RMSE</b>  |                         |       |       |       |       |       |       |       |       |       |
| Historical forecast            | 1.000                   | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 |
| GJR-GARCH                      | 0.693                   | 0.713 | 0.774 | 0.840 | 0.894 | 0.904 | 0.875 | 0.853 | 0.837 | 0.824 |
| MF2-GARCH-rw-63                | 0.677                   | 0.694 | 0.720 | 0.758 | 0.797 | 0.799 | 0.771 | 0.751 | 0.737 | 0.730 |
| MF2-GARCH-rw-21                | 0.686                   | 0.702 | 0.736 | 0.772 | 0.807 | 0.811 | 0.787 | 0.765 | 0.754 | 0.740 |
| GARCH-MIDAS $m = 63$           | 0.747                   | 0.733 | 0.710 | 0.798 | 0.855 | 0.879 | 0.860 | 0.850 | 0.838 | 0.835 |
| GARCH-MIDAS $m = 21$           | 0.736                   | 0.718 | 0.695 | 0.790 | 0.840 | 0.856 | 0.830 | 0.813 | 0.804 | 0.798 |
| <b>Panel B: Relative QLIKE</b> |                         |       |       |       |       |       |       |       |       |       |
| Historical forecast            | 1.000                   | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 |
| GJR-GARCH                      | 0.313                   | 0.324 | 0.466 | 0.697 | 0.792 | 0.841 | 0.833 | 0.830 | 0.828 | 0.821 |
| MF2-GARCH-rw-63                | 0.296                   | 0.308 | 0.446 | 0.660 | 0.755 | 0.784 | 0.755 | 0.737 | 0.716 | 0.707 |
| MF2-GARCH-rw-21                | 0.312                   | 0.328 | 0.469 | 0.674 | 0.740 | 0.774 | 0.762 | 0.752 | 0.743 | 0.725 |
| GARCH-MIDAS $m = 63$           | 0.333                   | 0.343 | 0.468 | 0.694 | 0.773 | 0.790 | 0.756 | 0.757 | 0.737 | 0.744 |
| GARCH-MIDAS $m = 21$           | 0.334                   | 0.343 | 0.460 | 0.686 | 0.765 | 0.787 | 0.755 | 0.740 | 0.730 | 0.729 |

*Note:* Il periodo *out-of-sample* considerato va da gennaio 2010 a dicembre 2019, mentre il periodo *in-sample* termina a dicembre 2009. Tutti i modelli vengono ristimati su base mensile (21 giorni) seguendo uno schema a finestra mobile. Gli orizzonti considerati sono un giorno, una settimana e i mesi dal primo all’ottavo. L’equazione 4.11 implica che il benchmark sia pari a 1 su tutti gli orizzonti.

ti simili alla versione con  $m = 63$ , ma comunque migliori rispetto ai modelli concorrenti. Per quanto riguarda il GJR e il MIDAS, entrambi battono il benchmark storico e, nel breve termine, risultano entrambi molto competitivi. Il GJR presenta valori simili all’MF2 nel breve periodo, per poi peggiorare nel medio termine, riflettendo il fatto che il modello a una sola componente converge alla varianza incondizionata e non è in grado di catturare la dinamica persistente dei cicli di volatilità. Il MIDAS, per entrambe le specificazioni, ottiene risultati interessanti all’orizzonte di 1 mese, dove ottiene un RMSE relativo inferiore all’MF2. Il risultato si può tradurre in una componente a lungo termine con filtro MIDAS applicato alla RV con enorme potere predittivo. Tuttavia, l’approssimazione non beneficia di mean-reversion e nel lungo periodo perde efficacia, le previsioni rimangono ancorate al livello recente della varianza realizzata senza tornare verso una varianza incondizionata finita (come descritto da Wang & Ghysels (2015), la varianza incondizionata del modello GARCH-MIDAS-RV è infinita).

Nel pannello B, i risultati confermano la superiorità del modello MF2 per gli orizzonti lunghi. Dall’orizzonte di 3 mesi in poi, l’MF2 presenta il ratio più basso, mentre i modelli concorrenti presentano risultati competitivi nel breve

periodo. I ratio più elevati del MIDAS confermano quanto osservato negli RMSE relativi.

### 4.3.2 Valutazione sul periodo completo

La tabella 4.3 estende la valutazione *out-of-sample* al periodo completo fino a settembre 2025. A differenza del caso precedente, è stato adottato un meccanismo di trattamento degli outlier di volatilità, basato sull'identificazione dei giorni in cui la varianza realizzata giornaliera supera il 99esimo percentile della distribuzione empirica *out-of-sample*: se il blocco target contiene almeno un giorno outlier, non viene eseguito il calcolo della funzione di perdita e il blocco non viene considerato nell'aggregazione delle misure di perdita. Dunque, la media delle perdite viene calcolata esclusivamente sulle coppie origine-orizzonte ammissibili per cui nessun giorno del blocco considerato supera la soglia del 99esimo percentile. Questa procedura consente di limitare l'eccessiva influenza di un basso numero di episodi che possono dominare notevolmente le misure di perdita e alterare il confronto tra i modelli; nello specifico, l'analisi ha rivelato che i giorni caratterizzati da valori estremi di volatilità si concentrano a marzo 2020, in corrispondenza dell'inizio della pandemia. Pertanto, l'utilizzo di tale meccanismo equivale a omettere questo breve periodo di instabilità dal campione di valutazione. In questo modo, la tabella risulta più informativa per misurare la capacità predittiva media dei diversi modelli. Per supportare tale scelta metodologica, durante la fase di stima delle previsioni sono stati testati i modelli anche senza il trattamento degli outlier. I risultati ottenuti in questo contesto hanno mostrato valori di RMSE e QLIKE notevolmente più elevati per tutti i modelli, con le misure di perdita dominate quasi interamente dai blocchi target corrispondenti al periodo della pandemia, rendendo il confronto delle capacità predittive dei modelli poco informativo.

I risultati mostrano un pattern simile al campione ristretto del caso precedente. Indipendentemente dalla funzione di perdita considerata, il modello MF2-GARCH rimane il più performante per tutti gli orizzonti considerati. Nei periodi più brevi, sia il GJR che il MIDAS presentano caratteristiche molto simili all'MF2, grazie alla composizione stessa del GJR utilizzato per gestire la componente a breve e grazie al driver di volatilità realizzata del MIDAS, che gli fornisce un vantaggio informativo. Tuttavia, come accade nel sottocampione, i modelli competitor perdono informazione all'aumentare dell'orizzonte, mentre il modello MF2 rimane stabile.

Tabella 4.3: Out-of-sample forecasting: S&amp;P 500 – Full OOS.

|                                | Orizzonte di previsione |       |       |       |       |       |       |       |       |       |
|--------------------------------|-------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
|                                | Day                     | Week  | 1 m   | 2 m   | 3 m   | 4 m   | 5 m   | 6 m   | 7 m   | 8 m   |
| <b>Panel A: Relative RMSE</b>  |                         |       |       |       |       |       |       |       |       |       |
| Historical forecast            | 1.000                   | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 |
| GJR-GARCH                      | 0.826                   | 0.795 | 0.828 | 1.328 | 1.034 | 0.979 | 0.964 | 0.939 | 0.931 | 0.921 |
| MF2-GARCH-rw-63                | 0.744                   | 0.736 | 0.738 | 0.884 | 0.841 | 0.857 | 0.866 | 0.868 | 0.867 | 0.859 |
| MF2-GARCH-rw-21                | 0.755                   | 0.742 | 0.751 | 0.934 | 0.857 | 0.872 | 0.880 | 0.876 | 0.875 | 0.871 |
| GARCH-MIDAS $m = 63$           | 0.913                   | 0.816 | 0.800 | 1.031 | 1.032 | 1.155 | 1.252 | 1.324 | 1.427 | 1.545 |
| GARCH-MIDAS $m = 21$           | 0.963                   | 0.821 | 0.804 | 1.042 | 1.034 | 1.140 | 1.216 | 1.280 | 1.383 | 1.496 |
| <b>Panel B: Relative QLIKE</b> |                         |       |       |       |       |       |       |       |       |       |
| Historical forecast            | 1.000                   | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 | 1.000 |
| GJR-GARCH                      | 0.351                   | 0.361 | 0.452 | 0.731 | 0.837 | 0.891 | 0.911 | 0.907 | 0.908 | 0.902 |
| MF2-GARCH-rw-63                | 0.332                   | 0.340 | 0.418 | 0.643 | 0.738 | 0.787 | 0.802 | 0.811 | 0.809 | 0.808 |
| MF2-GARCH-rw-21                | 0.349                   | 0.368 | 0.450 | 0.665 | 0.733 | 0.777 | 0.797 | 0.800 | 0.801 | 0.799 |
| GARCH-MIDAS $m = 63$           | 0.369                   | 0.363 | 0.453 | 0.708 | 0.791 | 0.833 | 0.849 | 0.848 | 0.868 | 0.885 |
| GARCH-MIDAS $m = 21$           | 0.369                   | 0.362 | 0.446 | 0.703 | 0.790 | 0.837 | 0.851 | 0.850 | 0.865 | 0.883 |

*Note:* Il periodo *out-of-sample* considerato va da gennaio 2010 a settembre 2025, mentre il periodo *in-sample* termina a dicembre 2009. Si vedano le note riportate nella Tabella 4.2.

La figura 4.5 consente di osservare le performance di previsione del modello MF2-GARCH-rw-63, del GJR-GARCH e del benchmark di riferimento tramite la funzione di perdita quadratica (SE) e la QLIKE. In questo caso, le funzioni di perdita non sono utilizzate nella loro forma aggregata come per le tabelle 4.2 e 4.3, ma come perdite puntuali associate ad ogni origine previsionale e per ogni orizzonte considerato. Il grafico mostra quindi, oltre alle performance dei modelli considerati, anche la dinamica con cui le perdite si accumulano nel campione *out-of-sample*. Entrambe le funzioni di perdita vengono dunque costruite sulle origini di previsione in ogni intervallo considerato; per un modello generico, la QLIKE è costruita come

$$QLIKE^{\text{Mod}} = \frac{RV_{t+a_s, t+b_s}}{\widehat{\sigma}_{t+a_s, t+b_s|t}^2} - \log\left(\frac{RV_{t+a_s, t+b_s}}{\widehat{\sigma}_{t+a_s, t+b_s|t}^2}\right) - 1, \quad (4.12)$$

mentre l'errore quadratico è

$$SE^{\text{Mod}} = \left(RV_{t+a_s, t+b_s} - \widehat{\sigma}_{t+a_s, t+b_s|t}^2\right)^2. \quad (4.13)$$

Analogamente, per il benchmark la QLIKE è

$$QLIKE^{\text{Hist}} = \frac{RV_{t+a_s, t+b_s}}{\widehat{RV}_{t+a_s, t+b_s|t}} - \log\left(\frac{RV_{t+a_s, t+b_s}}{\widehat{RV}_{t+a_s, t+b_s|t}}\right) - 1, \quad (4.14)$$

mentre l'SE è

$$SE^{\text{Hist}} = \left( RV_{t+a_s, t+b_s} - \widehat{RV}_{t+a_s, t+b_s|t} \right)^2. \quad (4.15)$$

Una volta ottenute le perdite puntuali, il confronto grafico viene effettuato sulle funzioni di perdita cumulate. Si definiscono  $\ell_{m,t_j}(s)$  come la perdita puntuale generica di un modello  $m$ , nella  $j$ -esima origine di previsione valida  $t_j$  e per l'orizzonte di previsione  $s$ .  $T_s$ <sup>4</sup> indica il numero di origini di previsione utilizzabili per l'orizzonte  $s$ ; la perdita cumulata  $CL$  di un modello  $m$  associata ad una funzione di perdita  $\ell \in \{SE, QLIKE\}$  fino alla  $k$ -esima origine per un orizzonte  $s$  è definita

$$CL_m^\ell(k, s) = \sum_{j=1}^k \ell_{m,t_j}(s), \quad k = 1, \dots, T_s. \quad (4.16)$$

Per rendere le performance dei modelli comparabili, le perdite cumulate sono normalizzate rispetto alla perdita cumulata finale del benchmark storico, in modo che la curva del benchmark raggiunga valore pari a 1 nell'ultima origine disponibile. Di conseguenza, le curve nel grafico sono individuate da

$$\widetilde{CL}_m^\ell(k, s) = \frac{CL_m^\ell(k, s)}{CL_{\text{Hist}}^\ell(T_s, s)}. \quad (4.17)$$

Curve più basse indicano una perdita cumulata minore fino a quell'origine, e la distanza verticale tra le curve misura un vantaggio relativo di un modello rispetto a un altro in ogni punto del campione.

---

<sup>4</sup>L'introduzione del meccanismo di rimozione dei blocchi di previsione con almeno un outlier implica che per ogni orizzonte considerato il numero di origini effettivamente disponibile differisca.






Figura 4.5: *Perdite cumulative per gli orizzonti di previsione di un mese, quattro mesi e otto mesi per SE (sulla sinistra) e QLIKE (sulla destra). Le perdite sono normalizzate con la perdita cumulata della previsione storica alla fine del periodo out-of-sample.*

I risultati che emergono dalla figura 4.5 confermano quanto osservato nella tabella 4.3: l'MF2-GARCH continua a mantenere una performance predittiva superiore, accumulando perdite sistematicamente inferiori rispetto al GJR-GARCH. Tuttavia, nel pannello relativo all'errore quadratico per l'orizzonte a 8 mesi, si può individuare un sottoperiodo in cui il modello GJR presenta perdite temporaneamente inferiori al modello MF2. Tale episodio è attribuibile all'interazione tra la specifica funzione di perdita considerata e la diversa velocità di *mean reversion* dei due modelli. Nel caso in questione, la funzione SE penalizza in modo quadratico gli errori di previsione; di conseguenza, se in un determinato sottoperiodo la componente a lungo termine  $\tau_t$  viene riassorbita più lentamente della varianza realizzata, il modello può mantenere una previsione elevata, generando un peggioramento locale della perdita cumulata. Il GJR-GARCH invece converge più rapidamente verso la sua varianza incondizionata, e nello stesso tempo si avvicina al target della varianza realiz-

zata. Tale vantaggio si riflette solamente per quello specifico sottoperiodo e non deriva da una migliore rappresentazione strutturale della persistenza del modello. A conferma di ciò, le curve individuate nei pannelli della QLIKE mostrano come il modello MF2 rimanga al di sotto del suo competitor su tutti i periodi, confermando la superiorità strutturale dell'MF2 indipendentemente dall'orizzonte considerato.

## 4.4 Simulazione Monte Carlo

A complemento dell'analisi sui dati reali, nella seguente sezione, per valutare le proprietà in campioni finiti dello stimatore quasi-verosimiglianza (QMLE) del modello MF2-GARCH, viene condotta una simulazione Monte Carlo. Tale procedura prevede la generazione di un numero elevato di replicazioni indipendenti ( $R$ ) del processo generatore dei dati, identificato dall'MF2-GARCH- $rw-m$ , fissando a priori il vettore dei parametri  $\theta^5$ . Per ogni replicazione, le innovazioni  $Z_t$  vengono generate da una distribuzione specificata e utilizzate per simulare una serie di rendimenti secondo il processo generatore dei dati. Per ogni campione, il modello viene stimato tramite QMLE, e viene prodotta una stima  $\hat{\theta}^{(r)}$  del vettore dei parametri. Quest'ultima è effettuata, sotto i vincoli di stazionarietà del modello, tramite un'ottimizzazione numerica della funzione di log-verosimiglianza e, una volta che il processo è stato ripetuto per il numero di replicazioni  $R$  fissato, si ottiene la distribuzione empirica dello stimatore che consente di valutare quantitativamente il Bias, l'errore quadratico medio (RMSE) e la deviazione standard asintotica dei parametri stimati (ASE).

Tali misure vengono utilizzate per analizzare la precisione e l'accuratezza dello stimatore QMLE in un contesto di campioni con dimensioni realistiche. Il Bias misura la deviazione media dello stimatore rispetto al vero valore del parametro. Valori prossimi allo zero suggeriscono uno stimatore non distorto

$$\text{Bias}(\hat{\theta}) = \frac{1}{R} \sum_{r=1}^R (\hat{\theta}^{(r)} - \theta). \quad (4.18)$$

L'RMSE sintetizza l'accuratezza dello stimatore. Valori più bassi indicano una

---

<sup>5</sup>Si vedano i vettori dei parametri delle componenti di breve e lungo periodo nella sezione 2.2.3.

maggior precisione delle stime.

$$\text{RMSE}(\hat{\theta}) = \sqrt{\frac{1}{R} \sum_{r=1}^R (\hat{\theta}^{(r)} - \theta)^2}. \quad (4.19)$$

L'ASE è la radice quadrata della media (attraverso le  $R$  repliche) della varianza asintotica di ciascun parametro. La varianza asintotica è calcolata sulla base di derivate numeriche.

In questo studio, si fissano i seguenti parametri<sup>6</sup> per il processo generatore dei dati:  $\alpha_0 = 0.02$ ,  $\gamma_0 = 0.10$ ,  $\beta_0 = 0.8$ ,  $\lambda_{00} = 0.02$ ,  $\lambda_{01} = 0.05$  e  $\lambda_{02} = 0.94$ ; la scelta di questi determinati valori riflette valori tipici stimati sui rendimenti azionari, garantendo stazionarietà e una forte persistenza sulla componente a lungo termine. Il numero di repliche viene fissato a 1000 ( $R = 1000$ ). La tabella 4.4 è divisa in due pannelli: nel primo vengono presentati i risultati della simulazione per  $Z_t$  con distribuzione Normale standard, mentre nel secondo  $Z_t$  segue una distribuzione  $t$  di Student con cinque gradi di libertà; inoltre, i risultati sono presentati per  $m = 21$  e  $m = 63$  e per dimensioni campionarie  $T = 5000$  e  $T = 10000$ , che corrispondono approssimativamente a 20 e 40 anni di osservazioni giornaliere.

Nel pannello A i risultati mostrano delle stime sostanzialmente non distorte per tutti i parametri e nelle rispettive specificazioni di  $m$ . In entrambi i casi, i bias di tutti i parametri oscillano attorno allo zero, sebbene si presentino dei valori leggermente più alti delle componenti di lungo periodo ( $\lambda_0, \lambda_1, \lambda_2$ ) quando  $m = 63$ . L'incremento di questi valori è giustificato dal fatto che la componente di lungo periodo dipende dalla somma di 63 errori di previsione ritardati della componente di breve periodo, rendendo di conseguenza più complessa l'ottimizzazione. Per quanto riguarda l'RMSE e L'ASE, si osservano dei valori molto simili tra di loro, soprattutto per  $m = 21$ : questo indica che le formule asintotiche forniscono una buona approssimazione della dispersione campionaria, e che l'inferenza basata sul QMLE risulta affidabile in campioni finiti. All'aumentare della dimensione campionaria, si osserva una diminuzione drastica di RMSE e ASE, che conferma la consistenza dello stimatore. Per  $m = 63$ , la situazione differisce, in quanto aumentano sia il divario tra i valori di RMSE e ASE, in particolare per le componenti a lungo termine, che i valori stessi. Il motivo è lo stesso per cui si nota l'aumento dell'RMSE.

Nel pannello B, come nel precedente, le stime rimangono non distorte in

---

<sup>6</sup>Gli stessi parametri ottimali sono stati utilizzati anche per la costruzione della figura 2.2, nella sezione 2.3.2.

tutte le specificazioni. Anche qui i bias rimangono vicini allo zero e non mostrano dei trend sistematici, confermando la robustezza del QMLE. La differenza rispetto al pannello precedente risiede nell'RMSE e nell'ASE, che mostrano un aumento generalizzato dei valori per tutti i parametri. Tale aumento è dovuto alla sostituzione della distribuzione Normale con la  $t$  di Student; la varianza asintotica delle stime è infatti amplificata dal momento quarto di  $Z_t$  che, con cinque gradi di libertà, è pari  $k = 9^7$ . In maniera analoga al caso gaussiano, anche nel seguente si osserva una diminuzione dei valori all'aumentare di  $T$  e una penalizzazione della precisione delle stime per la componente a lungo termine all'aumentare di  $m$ .

---

<sup>7</sup>Nel pannello B si assume  $Z_t \sim t(\nu)$  standardizzata a varianza unitaria con  $\nu = 5$ ; pertanto si ottiene  $\kappa = \frac{3(\nu-2)}{\nu-4} = \frac{3(5-2)}{5-4} = 9$ . Il valore  $\kappa = 9$ , superiore al caso gaussiano ( $\kappa = 3$ ), riflette la presenza di code più pesanti e implica una maggiore varianza asintotica dello stimatore QMLE, con conseguente aumento di RMSE e ASE.

Tabella 4.4: Stime dei parametri tramite simulazioni Monte Carlo.

|                                                         | $\alpha$ | $\gamma$ | $\beta$  | $\lambda_0$ | $\lambda_1$ | $\lambda_2$ |
|---------------------------------------------------------|----------|----------|----------|-------------|-------------|-------------|
| <i>True</i>                                             | 0.02     | 0.10     | 0.8      | 0.02        | 0.05        | 0.94        |
| <b>Panel A: <math>Z_t \sim \mathcal{N}(0, 1)</math></b> |          |          |          |             |             |             |
| $m = 21, T = 5,000$                                     |          |          |          |             |             |             |
| Bias                                                    | -0.0011  | 0.0011   | -0.0061  | 0.0062      | 0.0019      | -0.0053     |
| RMSE                                                    | {0.0120} | {0.0199} | {0.0423} | {0.0200}    | {0.0188}    | {0.0269}    |
| ASE                                                     | (0.0187) | (0.0238) | (0.0511) | (0.0219)    | (0.0243)    | (0.0339)    |
| $m = 21, T = 10,000$                                    |          |          |          |             |             |             |
| Bias                                                    | -0.0008  | 0.0008   | -0.0031  | 0.0030      | 0.0011      | -0.0028     |
| RMSE                                                    | {0.0079} | {0.0138} | {0.0267} | {0.0090}    | {0.0111}    | {0.0145}    |
| ASE                                                     | (0.0328) | (0.0249) | (0.0512) | (0.0149)    | (0.0205)    | (0.0275)    |
| $m = 63, T = 5,000$                                     |          |          |          |             |             |             |
| Bias                                                    | -0.0024  | 0.0011   | -0.0068  | 0.0487      | 0.0618      | -0.087      |
| RMSE                                                    | {0.0121} | {0.0200} | {0.0406} | {0.1318}    | {0.1765}    | {0.2375}    |
| ASE                                                     | (0.0248) | (0.0310) | (0.0568) | (0.0988)    | (0.1243)    | (0.1660)    |
| $m = 63, T = 10,000$                                    |          |          |          |             |             |             |
| Bias                                                    | -0.0011  | 0.0010   | -0.0029  | 0.0168      | 0.0201      | -0.0286     |
| RMSE                                                    | {0.0080} | {0.0138} | {0.0250} | {0.0720}    | {0.0955}    | {0.1299}    |
| ASE                                                     | (0.0209) | (0.0227) | (0.0477) | (0.0666)    | (0.1002)    | (0.1288)    |
| <b>Panel B: <math>Z_t \sim t(5)</math></b>              |          |          |          |             |             |             |
| $m = 21, T = 5,000$                                     |          |          |          |             |             |             |
| Bias                                                    | 0.0001   | 0.0018   | -0.0124  | 0.0074      | 0.0058      | -0.0102     |
| RMSE                                                    | {0.0165} | {0.0322} | {0.0666} | {0.0298}    | {0.0414}    | {0.0540}    |
| ASE                                                     | (0.0204) | (0.0356) | (0.0796) | (0.0335)    | (0.0434)    | (0.0585)    |
| $m = 21, T = 10,000$                                    |          |          |          |             |             |             |
| Bias                                                    | -0.0005  | 0.0008   | -0.0048  | 0.0032      | 0.0023      | -0.0042     |
| RMSE                                                    | {0.0110} | {0.0228} | {0.0437} | {0.0114}    | {0.0196}    | {0.0234}    |
| ASE                                                     | (0.0170) | (0.0253) | (0.0633) | (0.0154)    | (0.0289)    | (0.0346)    |
| $m = 63, T = 5,000$                                     |          |          |          |             |             |             |
| Bias                                                    | -0.0019  | 0.0039   | -0.0143  | 0.0536      | 0.0736      | -0.1028     |
| RMSE                                                    | {0.0195} | {0.0349} | {0.0685} | {0.1353}    | {0.1978}    | {0.2608}    |
| ASE                                                     | (0.0279) | (0.0415) | (0.0663) | (0.0892)    | (0.1089)    | (0.1433)    |
| $m = 63, T = 10,000$                                    |          |          |          |             |             |             |
| Bias                                                    | -0.0013  | 0.0010   | -0.0058  | 0.0216      | 0.0343      | 0.0462      |
| RMSE                                                    | {0.0110} | {0.0243} | {0.0399} | {0.0763}    | {0.1309}    | {0.1688}    |
| ASE                                                     | (0.0164) | (0.0266) | (0.0496) | (0.0533)    | (0.0876)    | (0.1093)    |

*Note:* La tabella mostra il Bias, l'errore quadratico medio (RMSE) e la deviazione standard asintotica (ASE) per ogni parametro del modello MF2-GARCH-rw- $m$  su  $R = 1,000$  replicazioni Monte Carlo. I valori RMSE sono riportati tra parentesi graffe, mentre i valori ASE tra parentesi tonde.

## 4.5 Componente di lungo periodo e tracker EMV

Sulla base di quanto detto nel capitolo 4, è possibile mettere in relazione la componente di lungo termine del modello MF2-GARCH-rw-63 ai tracker EMV.

Per l'analisi, si utilizzano i risultati ottenuti per l'MF2-GARCH-rw-63 nella tabella 4.1; si applica la conversione in volatilità annualizzata per ogni  $\tau$  stimato

$$\tau_t^{ann} = \sqrt{\tau_t \cdot 252}. \quad (4.20)$$

Si definisce  $\tau_{n,t}$  come la volatilità a lungo termine annualizzata osservata all'ultimo giorno di contrattazione del mese  $m$ . La variabile dipendente  $y_t$  della regressione è la differenza tra il mese corrente e il mese precedente

$$y_t = \Delta\tau_{n,m} = \tau_{n,m}^{ann} - \tau_{n,m-1}^{ann}. \quad (4.21)$$

Per quanto riguarda il tracker, si definisce  $x_{j,m}$  come il valore osservato del tracker  $j$  nel mese  $m$  (dove  $j = Overall, Macro\ News, Monetary\ Policy, Fiscal\ Policy, Inflation, Interest\ Rates$ ). Per migliorare l'interpretabilità dei dati, ogni regressore viene standardizzato tramite lo  $z$ -score

$$x_{j,m}^{(z)} = \frac{x_{j,m} - \bar{x}_j}{s_{x_j}}, \quad (4.22)$$

dove

$$\bar{x}_j = \frac{1}{M_j} \sum_{m \in \mathcal{M}_j} x_{j,m} \quad (4.23)$$

è la media campionaria del tracker  $j$  calcolata sull'insieme  $\mathcal{M}_j$  dei mesi per cui  $x_{j,m}$  è disponibile. La deviazione standard campionaria corrispondente è data da

$$s_{x_j} = \sqrt{\frac{1}{M_j - 1} \sum_{m \in \mathcal{M}_j} (x_{j,m} - \bar{x}_j)^2}. \quad (4.24)$$

Nella tabella 4.5 vengono presentati tre modelli:

$$\begin{aligned} y_t &= \beta_0 + \beta_1 Overall_t^{(z)} + u_t, \\ y_t &= \beta_0 + \beta_1 Macro_t^{(z)} + \beta_2 MonPol_t^{(z)} + \beta_3 FisPol_t^{(z)} + u_t, \\ y_t &= \beta_0 + \beta_1 Infl_t^{(z)} + \beta_2 IR_t^{(z)} + u_t. \end{aligned} \quad (4.25)$$

L'inferenza basata sull'OLS in questa tipologia di regressione risulta inaffidabile per diverse ragioni: la variabile dipendente presenta infatti variazioni di  $\tau_{n,t}$  sistematicamente più ampie durante periodi di incertezza, generando eteroschedasticità dei residui. Inoltre, la componente a lungo termine segue un processo MEM caratterizzato da un parametro di persistenza elevato (nella tabella 4.1,  $\lambda_2 = 0.8738$ ) che, per costruzione, può indurre autocorrelazione seriale nei residui. Questa riflette la dipendenza seriale in  $y_t$ ; per tenerne conto, si potrebbero includere i valori ritardati di  $y_t$  tra le variabili esplicative. Tuttavia, al fine di rendere comparabili in modo coerente i risultati di questa analisi con quelli di Conrad e Engle, viene adottato lo stesso approccio empirico basato sullo stimatore HAC di Newey & West (1987), il quale produce errori robusti sia all'eteroschedasticità che all'autocorrelazione. Si definisce  $x_t$  come il vettore colonna delle variabili esplicative al tempo  $t$  di dimensione  $K \times 1$ , inclusa la costante, e  $X$  come la matrice  $T \times K$  che raccoglie per riga i valori trasposti  $x_t^\top$  per il periodo campionario. Nella notazione,  $T$  indica il numero totale di osservazioni temporali e  $K$  il numero dei regressori del modello. Fissando  $L = 12$  lag mensili e pesi di Bartlett  $w_\ell = 1 - \ell/(L + 1)$  con  $\ell = 1, 2, \dots, L$ , la matrice di covarianza è

$$\hat{V}_{\text{HAC}} = (X^\top X)^{-1} \hat{S} (X^\top X)^{-1}, \quad (4.26)$$

dove

$$\hat{S} = \sum_{t=1}^T \hat{\varepsilon}_t^2 x_t x_t^\top + \sum_{\ell=1}^L w_\ell \sum_{t=\ell+1}^T \hat{\varepsilon}_t \hat{\varepsilon}_{t-\ell} (x_t x_{t-\ell}^\top + x_{t-\ell} x_t^\top). \quad (4.27)$$

I t-stat e i p-value sono calcolati come

$$t_j = \frac{\hat{\beta}_j}{\sqrt{\hat{V}_{\text{HAC},jj}}} \quad \text{e} \quad p_j = 2(1 - \Phi(|t_j|)). \quad (4.28)$$

I risultati nella tabella 4.5 del modello (1) mostrano una forte relazione positiva tra il cambio mensile della componente a lungo termine e il tracker 'Overall'. Allo stesso modo, i risultati della colonna (2) mostrano una significatività solo per i tracker 'Macro News' e 'Monetary Policy', dimostrando il grande impatto sulla volatilità strutturale, a differenza del tracker 'Fiscal Policy'. Questo implica che le notizie fiscali, pur avendo un determinato impatto nel breve periodo, non hanno grandi effetti sulla volatilità a lungo termine. L'ultimo modello, che include le sottocomponenti 'Inflation' e 'Interest Rates', ha effetti rilevanti; in particolare, il tracker dei tassi presenta l'effetto in valore assoluto più elevato

tra il modello (2) e (3), suggerendo che l'incertezza sui tassi futuri è il canale più efficace per la trasmissione degli effetti sulla volatilità. Tali valori confermano come la volatilità a lungo termine del modello MF2-GARCH sia guidata da diverse tipologie di notizie; un approccio di tipo GARCH-MIDAS-X presenterebbe diversi problemi, in quanto caratterizzato da una singola variabile esplicativa che non riuscirebbe a catturare in modo completo la dinamica di  $\tau_{n,m}$ . Inoltre, utilizzando una singola variabile, si dovrebbe assumere che tutta l'informazione inclusa in quella variabile sia rilevante. Pertanto, il vantaggio dell'approccio MF2-GARCH è che non necessita di esplicitare una singola variabile macroeconomica che guidi la componente di lungo periodo, in quanto  $\tau_{n,m}$  viene ottenuto tramite la struttura dei rendimenti attraverso la stima QMLE e, solo successivamente, comparato con variabili esterne che possono essere più rilevanti o meno.

Tabella 4.5: Fattori determinanti della volatilità a lungo termine.

|                              | Variabile dipendente: $\tau_{n,t} - \tau_{n,t-1}$ |                     |                     |
|------------------------------|---------------------------------------------------|---------------------|---------------------|
|                              | (1)                                               | (2)                 | (3)                 |
| Overall <sub>t</sub>         | 0.492***<br>(0.056)                               |                     |                     |
| Macro News <sub>t</sub>      |                                                   | 0.262**<br>(0.122)  |                     |
| Monetary Policy <sub>t</sub> |                                                   | 0.254***<br>(0.084) |                     |
| Fiscal Policy <sub>t</sub>   |                                                   | 0.034<br>(0.108)    |                     |
| Inflation <sub>t</sub>       |                                                   |                     | 0.190***<br>(0.072) |
| Interest Rates <sub>t</sub>  |                                                   |                     | 0.333***<br>(0.089) |
| adj. $R^2$                   | 0.210                                             | 0.235               | 0.214               |

*Note:* Le regressioni includono il periodo dal 1985 al 2025. La componente a lungo termine è ottenuta dalle stime del modello MF2-GARCH-rw-63 per i rendimenti giornalieri dell'S&P 500 della tabella 4.1. I numeri rappresentano le stime dei coefficienti e i numeri tra parentesi indicano gli errori standard HAC. Ogni tracker è stato standardizzato in modo tale che i coefficienti stimati misurano l'effetto del cambio di una deviazione standard nel rispettivo tracker. Il simbolo \*\*\* denota una significatività all'1%, \*\* al 5%, e \* al 10%.

Da un punto di vista economico, i risultati dei coefficienti sono molto simili a quelli ottenuti da Conrad e Engle, che hanno utilizzato un dataset limitato al 2023, ma emergono alcune differenze per i tracker di 'Macro News' e 'Monetary Policy', che mostrano in questo studio un impatto più marcato e una



maggior significatività statistica. Rispettivamente, per i due tracker, si ottiene significatività al 5% e all'1%, contro il 10% e il 5% dello studio originale. Una possibile spiegazione risiede nella fase di incertezza economica dell'ultimo biennio che ha assunto un ruolo ancora più rilevante nella formazione delle aspettative di mercato: anche eventi recenti di incertezza commerciale, come l'annuncio dei dazi dell'aprile 2025, possono aver aumentato il contenuto informativo dei due tracker, generando una maggiore variazione nella componente a lungo termine del modello MF2.

## 4.6 Effetto immediato e intermedio delle notizie

L'introduzione del dataset di Baker et al. (2019) nel capitolo precedente permette di quantificare l'impatto delle notizie sulla volatilità condizionata del modello MF2-GARCH-rw-63 e, per effettuare un confronto, anche del modello GJR-GARCH. Nello studio, viene stimata una regressione in cui la variabile dipendente è la radice quadrata della varianza media futura calcolata su un orizzonte di  $S$  giorni

$$\begin{aligned} \sqrt{\frac{1}{S} \sum_{s=1}^S \sigma_{t+s}^2} = & \beta_1 + \beta_2 \text{Macro}_t \mathbf{1}_{\{r_t > 0\}} + \beta_3 \text{Macro}_t \mathbf{1}_{\{r_t < 0\}} \\ & + \beta_4 \text{CorpEarn}_t \mathbf{1}_{\{r_t > 0\}} + \beta_5 \text{CorpEarn}_t \mathbf{1}_{\{r_t < 0\}} \\ & + \beta_6 \text{MonPol}_t \mathbf{1}_{\{r_t > 0\}} + \beta_7 \text{MonPol}_t \mathbf{1}_{\{r_t < 0\}} \\ & + \beta_8 \sqrt{\sigma_t^2} + u_t. \end{aligned} \quad (4.29)$$

La struttura della regressione risulta particolarmente informativa, in quanto le variabili macroeconomiche considerate interagiscono in modo moltiplicativo con le variabili indicatrici direzionali, che si attivano rispettivamente per i giorni con rendimenti positivi e nei giorni con rendimenti negativi; tale struttura consente di catturare l'effetto asimmetrico che le notizie di segno opposto applicano sulla volatilità futura. L'ultimo termine della regressione opera come variabile di controllo, ossia sconta il livello della volatilità condizionata presente al tempo  $t$  e permette ai coefficienti di misurare l'impatto marginale sulla volatilità apportato dalle news.

L'inferenza si basa anche in questo caso sullo stimatore HAC di Newey & West (1987), necessario per ottenere un'inferenza robusta. Tale correzione consente di applicare il metodo delle 'Local Projections' di Jordà (2005), utile

per tracciare graficamente l'impatto marginale delle diverse tipologie di notizie sulla volatilità per i 15 giorni successivi all'evento.




Figura 4.6: *Effetto di Macro News (in alto) e di Monetary News (in basso) sulla volatilità condizionata. Il dataset WSJ di Baker et al. (2019) include i giorni con rendimenti elevati in valore assoluto dal 1985 al 2022. I pannelli a sinistra e a destra illustrano rispettivamente l'impatto delle notizie positive e delle notizie negative. Le stime mettono a confronto le dinamiche catturate dal modello GJR-GARCH (in rosso) e dal modello MF2-GARCH (in blu). L'impatto marginale sulla volatilità percentuale annualizzata è tracciato per i 15 giorni seguenti l'evento, con le relative bande di confidenza al 95%.*

L'analisi sui pannelli per *Macro News* mostra un trend molto simile tra i due modelli e poche differenze nel momento in cui si verificano *bad news*; per quanto riguarda i pannelli di sinistra, emergono delle differenze sostanziali che evidenziano i limiti strutturali delle specificazioni tradizionali. Nel GJR-GARCH una buona notizia porta a stimare un lieve aumento per la volatilità nel giorno successivo, seguito poi da un calo. Siccome il modello è caratterizzato da un'unica equazione per la varianza, il GARCH fatica a compensare l'ampiezza assoluta del rendimento azionario, e si trova di fatto a dover interpretare il balzo positivo dei prezzi come un aumento di turbolenza nei mercati; di conseguenza i risultati non sono significativi. Per l'MF2-GARCH la situazione cambia poiché nel giorno successivo si presenta un calo statisticamente significativo della volatilità che persiste nei giorni successivi, anche se con una persistenza minore rispetto alle *bad news*. Tale evidenza è giustificata dalla natura moltiplicativa del modello MF2: di fronte a un grande shock positivo, la componente a lungo termine mostra un graduale aumento per riflettere le dinamiche del mercato, mentre la componente a breve reagisce in maniera asimmetrica e si riduce quando si verificano *good news*. Il risultato è quindi realistico, l'assorbimento di una *good news* stabilizza il mercato, e la stessa dinamica è confermata nella pratica finanziaria sia dalle metriche di volatilità ad alta frequenza (volatilità realizzata), che vedono le oscillazioni intraday ridursi, sia dalle aspettative degli investitori misurate tramite la volatilità implicita delle opzioni, in quanto si riduce la necessità degli investitori di proteggersi dal rischio, causando una riduzione della volatilità.

La dinamica appena descritta risulta coerente anche nei pannelli che descrivono l'impatto della variabile 'Monetary News', ma con una distinzione ancora più marcata tra notizie positive dei due modelli. Quando si verifica una 'Monetary News' positiva, il GJR-GARCH, a causa della sua rigidità strutturale, continua a interpretare lo sbalzo positivo dei prezzi come un aumento della turbolenza del mercato, che si traduce in un aumento lieve e non significativo della volatilità. Invece, l'MF2-GARCH incorpora correttamente le notizie positive con una riduzione iniziale della volatilità e un calo statisticamente significativo della volatilità già dal giorno successivo.

La tabella 4.6 riporta i risultati della regressione per alcuni orizzonti e conferma quanto osservato nelle figure. In particolare, l'impatto delle notizie negative risulta elevato e statisticamente significativo per entrambi i modelli, mentre le 'Corporate News', pur essendo persistenti negli orizzonti, influiscono con meno rilevanza.

Tabella 4.6: Impatto delle notizie macroeconomiche, corporate e monetarie sulla volatilità condizionata.

| Variabile                         | Orizzonte di previsione ( $S$ ) |                      |                      |                     |                     |
|-----------------------------------|---------------------------------|----------------------|----------------------|---------------------|---------------------|
|                                   | $S = 1$                         | $S = 2$              | $S = 5$              | $S = 10$            | $S = 15$            |
| <b>Panel A: Modello MF2</b>       |                                 |                      |                      |                     |                     |
| Intercept                         | 0.693***<br>(0.091)             | 0.925***<br>(0.126)  | 1.663***<br>(0.227)  | 2.763***<br>(0.375) | 3.719***<br>(0.478) |
| Macro (Good)                      | -0.644***<br>(0.151)            | -1.123***<br>(0.241) | -1.381***<br>(0.467) | -1.285*<br>(0.735)  | -1.028<br>(0.840)   |
| Macro (Bad)                       | 10.628***<br>(1.119)            | 10.352***<br>(1.321) | 10.680***<br>(2.327) | 9.905***<br>(2.578) | 8.973***<br>(2.484) |
| Corporate (Good)                  | -0.607***<br>(0.126)            | -0.794***<br>(0.231) | -0.739<br>(0.546)    | -0.559<br>(0.769)   | -0.103<br>(0.959)   |
| Corporate (Bad)                   | 8.848***<br>(1.246)             | 8.246***<br>(1.321)  | 7.966***<br>(1.604)  | 7.815***<br>(1.796) | 8.269***<br>(1.962) |
| Monetary (Good)                   | -0.808***<br>(0.204)            | -0.602**<br>(0.305)  | -0.694<br>(0.483)    | -0.298<br>(0.930)   | 0.037<br>(1.488)    |
| Monetary (Bad)                    | 11.061***<br>(1.365)            | 10.382***<br>(1.383) | 8.958***<br>(1.632)  | 7.376***<br>(1.457) | 7.070***<br>(1.338) |
| Control Vol ( $t$ )               | 0.949***<br>(0.006)             | 0.935***<br>(0.009)  | 0.891***<br>(0.016)  | 0.824***<br>(0.026) | 0.766***<br>(0.033) |
| Adj. $R^2$                        | 0.951                           | 0.930                | 0.861                | 0.758               | 0.673               |
| <b>Panel B: Modello GJR-GARCH</b> |                                 |                      |                      |                     |                     |
| Intercept                         | 0.507***<br>(0.063)             | 0.658***<br>(0.095)  | 1.171***<br>(0.178)  | 2.006***<br>(0.288) | 2.810***<br>(0.363) |
| Macro (Good)                      | 0.469***<br>(0.160)             | -0.013<br>(0.213)    | -0.494<br>(0.358)    | -0.877<br>(0.577)   | -1.012<br>(0.689)   |
| Macro (Bad)                       | 8.592***<br>(0.960)             | 8.567***<br>(1.124)  | 9.265***<br>(1.950)  | 9.061***<br>(2.184) | 8.549***<br>(2.144) |
| Corporate (Good)                  | 0.542***<br>(0.130)             | 0.262<br>(0.213)     | 0.037<br>(0.466)     | -0.127<br>(0.629)   | -0.003<br>(0.825)   |
| Corporate (Bad)                   | 7.098***<br>(1.043)             | 6.717***<br>(1.112)  | 6.982***<br>(1.398)  | 7.557***<br>(1.656) | 8.301***<br>(1.899) |
| Monetary (Good)                   | 0.595***<br>(0.187)             | 0.658**<br>(0.266)   | 0.413<br>(0.409)     | 0.651<br>(0.848)    | 0.906<br>(1.427)    |
| Monetary (Bad)                    | 9.296***<br>(1.277)             | 8.852***<br>(1.300)  | 7.969***<br>(1.516)  | 7.094***<br>(1.430) | 6.998***<br>(1.388) |
| Control Vol ( $t$ )               | 0.962***<br>(0.004)             | 0.953***<br>(0.007)  | 0.922***<br>(0.013)  | 0.872***<br>(0.020) | 0.823***<br>(0.025) |
| Adj. $R^2$                        | 0.969                           | 0.955                | 0.909                | 0.831               | 0.757               |

Note: I numeri tra parentesi riportano gli errori standard robusti. Il simbolo \*\*\* denota una significatività all'1%, \*\* al 5%, e \* al 10%.

Per quanto riguarda le notizie positive, il GJR-GARCH, come detto precedentemente, nell'orizzonte immediato fatica nella distinzione tra un movimento positivo dei prezzi e un aumento della turbolenza, mentre l'MF2-GARCH restituisce una dinamica più realistica.

In generale, l'analisi svolta finora nel capitolo risulta coerente con le evidenze ottenute da Conrad e Engle. Nonostante l'estensione del periodo campionario, le dinamiche della volatilità trovano conferma, sia nella maggiore accuratezza delle previsioni su orizzonti lunghi, sia nella risposta della volatilità condizionata del modello ai vari driver macroeconomici. Appurata la solidità del modello, nella sezione successiva sarà valutato in che modo l'MF2-GARCH sia in grado di gestire e stimare le misure di rischio.

## 4.7 Value at Risk & Expected Shortfall

Conrad & Engle descrivono come il modello MF2-GARCH sia adatto per applicazioni che richiedono previsioni a lungo termine della volatilità. Per questo motivo, la seguente sezione si concentra sulle previsioni di Value at Risk (VaR) e Expected Shortfall per diversi livelli di confidenza e per MF2 con  $m = 21$  e  $m = 63$ . Tali misure di rischio, essendo molto utilizzate in ambito operativo, richiedono una certa affidabilità. Pertanto, nella letteratura economico finanziaria sono nate le cosiddette procedure di *backtesting*, mirate a valutare la capacità previsionale delle misure di rischio e a garantirne la loro validità e accuratezza. Esistono diverse tipologie di backtesting, e le stime del VaR saranno valutate in particolare mediante due test specifici basati sul Likelihood Ratio.

Il test di Kupiec (1995) dell'*Unconditional Coverage*, trattato anche da Christoffersen (1998), serve a verificare se il modello sbaglia troppo spesso o troppo raramente rispetto alla probabilità  $p$ . In altri termini, si sottopone a verifica empirica se la frequenza empirica delle violazioni realizzate,  $\hat{\pi}$ , è significativamente diversa da quella teorica  $p$  (con  $p = \alpha$  nel caso del VaR). Si consideri  $T$  la dimensione del campione e  $\{I_t\}_{t=1}^T$  la variabile indicatrice delle violazioni, che assume valore 1 se si verifica una violazione del VaR, o valore 0 altrimenti. Pertanto,  $T = n_0 + n_1$ , dove  $n_0$  e  $n_1$  indicano rispettivamente un'osservazione per cui  $I_t = 0$  o  $I_t = 1$ . L'ipotesi nulla  $E[I_t] = p$  va testata contro l'alternativa  $E[I_t] \neq p$ . La likelihood sotto l'ipotesi nulla è data da

$$L(p; I_1, \dots, I_T) = (1 - p)^{n_0} p^{n_1}, \quad (4.30)$$

e sotto l'ipotesi alternativa

$$L(\pi; I_1, \dots, I_T) = (1 - \pi)^{n_0} \pi^{n_1}. \quad (4.31)$$

La statistica LR è data da

$$\begin{aligned} LR_{uc} &= -2 \log \left[ \frac{L(p; I_1, I_2, \dots, I_T)}{L(\hat{\pi}; I_1, I_2, \dots, I_T)} \right] \\ &= -2 \left[ n_0 \log \frac{1-p}{1-\hat{\pi}} + n_1 \log \frac{p}{\hat{\pi}} \right]. \end{aligned} \quad (4.32)$$

dove  $\hat{\pi} = n_1/(n_0 + n_1)$  è la stima di massima verosimiglianza di  $\pi$  e  $s = 2$  è il numero massimo di esiti possibili della sequenza. Il valore asintotico del likelihood ratio si distribuisce secondo una chi quadro con un grado di libertà:

$$LR_{uc} \xrightarrow{\text{asy}} \chi^2(s-1) = \chi^2(1), \quad (4.33)$$

Christoffersen sottolinea che, anche nel caso in cui vi sia copertura incondizionata corretta, le violazioni si potrebbero verificare durante fasi di turbolenza, rendendo dunque necessario affiancare i prossimi test.

Christoffersen (1998) propone un altro test volto a valutare se un modello sia caratterizzato o meno da una *Conditional Coverage*, ossia se la probabilità che si verifichi la violazione in un determinato giorno sia indipendente dal fatto che nel giorno precedente si sia verificata o meno una violazione. La statistica corrispondente è data dalla somma di due likelihood ratio

$$LR_{cc} = LR_{uc} + LR_{ind}, \quad (4.34)$$

dove  $LR_{ind}$  corrisponde al test d'indipendenza, che richiede di essere verificato. Christoffersen (1998) verifica l'indipendenza mediante un confronto su una catena di Markov di primo ordine<sup>8</sup>. Si considera una catena binaria di primo ordine di Markov  $\{I_t\}$  con matrice di transizione

$$\Pi_1 = \begin{pmatrix} 1 - \pi_{01} & \pi_{01} \\ 1 - \pi_{11} & \pi_{11} \end{pmatrix}. \quad (4.35)$$

dove  $\pi_{ij} = \Pr(I_t = j \mid I_{t-1} = i)$  corrisponde alla probabilità che l'indicatore assuma valore  $j$  il giorno  $t$  condizionatamente al fatto che il giorno precedente

---

<sup>8</sup>Si tratta di un processo stocastico che descrive una sequenza di eventi in cui la probabilità di passare a uno stato futuro dipende esclusivamente dallo stato presente, ignorando quelli passati.

abbia assunto valore  $i$ . La funzione di verosimiglianza del processo è

$$L(\Pi_1; I_1, I_2, \dots, I_T) = (1 - \pi_{01})^{n_{00}} \pi_{01}^{n_{01}} (1 - \pi_{11})^{n_{10}} \pi_{11}^{n_{11}}, \quad (4.36)$$

con  $n_{ij}$  pari al numero di volte in cui si osserva una transizione da  $i$  a  $j$ . Condizionando sulla prima osservazione, la stima di massima verosimiglianza dei parametri della matrice di transizione è data dai rapporti dei conteggi delle celle appropriate:

$$\hat{\Pi}_1 = \begin{pmatrix} \frac{n_{00}}{n_{00} + n_{01}} & \frac{n_{01}}{n_{00} + n_{01}} \\ \frac{n_{10}}{n_{10} + n_{11}} & \frac{n_{11}}{n_{10} + n_{11}} \end{pmatrix}. \quad (4.37)$$

Si considera ora la sequenza in uscita  $\{I_t\}$  proveniente da un modello d'intervallo. Dopodiché Christoffersen stima sulla sequenza un modello a catena di Markov di primo ordine e testa l'ipotesi che la sequenza sia indipendente osservando che

$$\Pi_2 = \begin{pmatrix} 1 - \pi_2 & \pi_2 \\ 1 - \pi_2 & \pi_2 \end{pmatrix} \quad (4.38)$$

corrisponde all'indipendenza. La verosimiglianza sotto l'ipotesi nulla diventa

$$L(\Pi_2; I_1, I_2, \dots, I_T) = (1 - \pi_2)^{(n_{00} + n_{10})} \pi_2^{(n_{01} + n_{11})}, \quad (4.39)$$

e lo stimatore di massima verosimiglianza è  $\hat{\Pi}_2 = \hat{\pi}_2 = (n_{01} + n_{11}) / (n_{00} + n_{10} + n_{01} + n_{11})$ . A questo punto, il rapporto di verosimiglianza per testare l'ipotesi nulla di indipendenza si può costruire come

$$LR_{ind} = -2 \log \left[ \frac{L(\hat{\Pi}_2; I_1, I_2, \dots, I_T)}{L(\hat{\Pi}_1; I_1, I_2, \dots, I_T)} \right] \xrightarrow{\text{asy}} \chi^2((s-1)^2) = \chi^2(1). \quad (4.40)$$

Dunque, per ottenere un test completo di conditional coverage, è necessario combinare i due test, in modo tale da far verificare congiuntamente l'ipotesi che vi sia il numero corretto di violazioni e che esse siano indipendenti

$$LR_{cc} = -2 \log \left[ \frac{L(p; I_1, I_2, \dots, I_T)}{L(\hat{\Pi}_1; I_1, I_2, \dots, I_T)} \right] \xrightarrow{\text{asy}} \chi^2(s(s-1)) = \chi^2(2). \quad (4.41)$$

In generale, l'introduzione del conditional coverage test ha permesso di superare i limiti della versione di Kupiec, che si basa esclusivamente sulla corretta frequenza del numero di violazioni rispetto al livello di confidenza scelto, a discapito della distribuzione temporale delle violazioni; questo fa sì che, dal

punto di vista statistico, vi sia un'alta probabilità di accettare l'ipotesi nulla quando quest'ultima dovrebbe essere rifiutata, e tale probabilità aumenta all'incremento del livello di confidenza e a quanto più piccola sia la dimensione campionaria. Invece, il test proposto da Christoffersen risulta più completo in quanto combina le due dinamiche risolvendo di fatto il problema legato all'indipendenza.

Stabiliti i test da utilizzare per la valutazione dell'accuratezza del VaR, è possibile procedere alla stima del VaR<sup>9</sup>. Inoltre, verranno effettuati i rispettivi test su due diversi periodi temporali utilizzati anche nelle sezioni precedenti, ossia il periodo *in-sample* dal 2000 al 2010 e il periodo *out-of-sample* dal 2010 al 2025, e saranno confrontate le specificazioni standard MF2-GARCH-rw per  $m = 63$  e  $m = 21$ . Sulla base dei risultati, fissato il livello di significatività al 5%, si rifiuta l'ipotesi nulla dei test quando il p-value è inferiore a 0.05, che si traduce in un rifiuto dell'accettabilità del VaR rispetto a una determinata proprietà. Pertanto, il test dell'Unconditional Coverage verifica se la frequenza delle violazioni è coerente con  $p$ , il test d'indipendenza assicura l'assenza di clustering tra le violazioni e il Conditional Coverage combina entrambe le dimensioni.

---

<sup>9</sup>Le formule per il calcolo del Value at Risk per un MF2-GARCH sono state introdotte nella sezione 2.3.3.






Figura 4.7: *Value at Risk* nel periodo *in-sample* per distribuzione Normale e *t* di Student.

In generale, confrontando le finestre a parità di distribuzione della figura 4.7, le bande del VaR risultano più reattive per una finestra rolling più breve ( $m = 21$ ); durante la crisi del 2008, il rientro risulta più immediato a seguito di un grande allargamento, denotando una soglia molto vicina ai movimenti del mercato. Per  $m = 63$  si denota una maggiore stabilità, pertanto meno oscillamenti delle soglie durante le fasi di calma e rientri più gradualmente a seguito di grandi shock. Confrontando invece le stime a parità di  $m$ , la differenza risulta più marcata nelle code: infatti, il VaR all'1% mostra un effetto ancora più negativo per la distribuzione  $t$  rispetto alla Normale, soprattutto nelle fasi turbolente, mentre per il VaR al 5% le differenze sono minime, essendo un quantile meno estremo.

Tabella 4.7: Confronto Backtest VaR:  $m = 21$  vs  $m = 63$  (*in-sample*).

| Metric               | $m = 21$ |        |              |        | $m = 63$ |        |              |        |
|----------------------|----------|--------|--------------|--------|----------|--------|--------------|--------|
|                      | Normal   |        | Student- $t$ |        | Normal   |        | Student- $t$ |        |
|                      | LR       | p-val  | LR           | p-val  | LR       | p-val  | LR           | p-val  |
| <i>VaR 1%</i>        |          |        |              |        |          |        |              |        |
| UC (Kupiec)          | 4.92     | 0.0265 | 0.13         | 0.7141 | 3.47     | 0.0624 | 0.42         | 0.5189 |
| IND (Christoffersen) | 1.11     | 0.2931 | 0.59         | 0.4439 | 0.99     | 0.3201 | 0.39         | 0.5331 |
| CC (Cond. coverage)  | 6.03     | 0.0490 | 0.72         | 0.6975 | 4.46     | 0.1074 | 0.80         | 0.6688 |
| <i>VaR 5%</i>        |          |        |              |        |          |        |              |        |
| UC (Kupiec)          | 1.88     | 0.1707 | 3.59         | 0.0580 | 1.22     | 0.2695 | 1.88         | 0.1707 |
| IND (Christoffersen) | 2.60     | 0.1070 | 0.35         | 0.5518 | 2.24     | 0.1343 | 2.60         | 0.1070 |
| CC (Cond. coverage)  | 4.47     | 0.1068 | 3.95         | 0.1389 | 3.46     | 0.1772 | 4.47         | 0.1068 |

*Note:* LR indica la statistica Likelihood Ratio. p-val indica il p-value associato. Fissato un livello di significatività del 5%, l'ipotesi nulla è rifiutata quando  $p\text{-val} < 0.05$ .

Il campione *in-sample* presenta risultati generalmente favorevoli alla distribuzione  $t$  di Student per entrambe le finestre, poiché i p-value risultano al di sopra della soglia e i vari test non vengono rifiutati. Sotto l'ipotesi di normalità, emergono delle differenze tra le due finestre rolling, in particolare nei backtest per il VaR all'1%: con una finestra  $m = 21$  si osserva un rifiuto del test UC e, di conseguenza, anche del test CC, mentre il test sull'indipendenza non viene rifiutato. Dunque, la criticità principale è associata alla corretta determinazione della soglia del VaR piuttosto che alla presenza di clustering nelle violazioni. Invece, per  $m = 63$ , i test non sono rifiutati per ogni VaR stimato anche sotto l'ipotesi di normalità, suggerendo una maggiore stabilità del modello MF2-rw-63 per entrambe le distribuzioni nel periodo considerato. L'evidenza porta a favorire la distribuzione  $t$  di Student per assorbire la non-normalità delle code e rendere i backtest più coerenti per entrambe le  $m$ .




Figura 4.8: *Value at Risk nel periodo out-of-sample per distribuzione Normale e  $t$  di Student.*

In maniera analoga all'analisi della figura 4.7, si possono trarre delle conclusioni simili; a parità di distribuzione il modello con finestra rolling  $m = 21$  presenta delle soglie più reattive rispetto alla controparte, mentre quest'ultima risulta più stabile grazie ad una maggiore filtrazione del rumore. A parità di  $m$  la distribuzione  $t$  continua a presentare soglie più severe rispetto alla distribuzione Normale, come è possibile notare anche graficamente nel periodo del Covid.

I test per il periodo *out-of-sample* risultano molto differenti rispetto al caso precedente, in quanto nella maggior parte dei test UC e CC l'ipotesi nulla viene rifiutata, evidenziando una calibrazione errata del tasso delle violazioni. Nel dettaglio, emerge per  $m = 21$ , sia per la distribuzione Normale che  $t$  di Student, il rifiuto dell'ipotesi nulla per i due test principali, sottolineando una frequenza non propriamente compatibile con il livello teorico dell'1%. Nel caso di  $m = 21$ , si evince un comportamento migliore per la distribuzione Normale, soprattutto per il VaR al 5%, che non vede rifiutato alcun test, a differenza del caso Normale per  $m = 63$ . Sebbene i due test principali vengano rifiutati, l'elevato valore del p-value per il test d'indipendenza conferma l'assenza di forme di dipendenza seriale tra le violazioni; pertanto, la prima violazione non

Tabella 4.8: Confronto Backtest VaR:  $m = 21$  vs  $m = 63$  (*out-of-sample*).

| Metric               | $m = 21$ |        |              |        | $m = 63$ |        |              |        |
|----------------------|----------|--------|--------------|--------|----------|--------|--------------|--------|
|                      | Normal   |        | Student- $t$ |        | Normal   |        | Student- $t$ |        |
|                      | LR       | p-val  | LR           | p-val  | LR       | p-val  | LR           | p-val  |
| <i>VaR 1%</i>        |          |        |              |        |          |        |              |        |
| UC (Kupiec)          | 30.74    | 0.0001 | 12.81        | 0.0003 | 30.74    | 0.0001 | 11.85        | 0.0006 |
| IND (Christoffersen) | 0.11     | 0.7410 | 0.74         | 0.3912 | 0.11     | 0.7410 | 0.80         | 0.3712 |
| CC (Cond. coverage)  | 30.84    | 0.0001 | 13.55        | 0.0011 | 30.84    | 0.0001 | 12.65        | 0.0018 |
| <i>VaR 5%</i>        |          |        |              |        |          |        |              |        |
| UC (Kupiec)          | 3.73     | 0.0533 | 9.66         | 0.0019 | 5.20     | 0.0225 | 13.35        | 0.0003 |
| IND (Christoffersen) | 0.06     | 0.8130 | 0.11         | 0.7418 | 1.04     | 0.3088 | 0.70         | 0.4017 |
| CC (Cond. coverage)  | 3.79     | 0.1503 | 9.77         | 0.0075 | 6.24     | 0.0442 | 14.05        | 0.0009 |

*Note:* LR indica la statistica Likelihood Ratio. p-val indica il p-value associato. Fissato un livello di significatività del 5%, l'ipotesi nulla è rifiutata quando  $p\text{-val} < 0.05$ .

influisce sulla successiva e viceversa.

Prima di affermare con certezza se il modello MF2 sia adeguato o meno per questa tipologia di analisi, è doveroso interrogarsi su quale possa essere la causa principale del fallimento sistematico su ogni test e per ogni distribuzione analizzata. Il periodo *out-of-sample* utilizzato comprende molteplici episodi con grandi sbalzi di volatilità, tra cui quello legato alla pandemia nel 2020 e successivamente ai rialzi della Fed nel 2022, i quali hanno generato una volatilità persistente che risultava piuttosto inusuale rispetto al mercato degli anni precedenti. In questi contesti, una specificazione stabile parametricamente e stimata su una finestra storica finita può riscontrare difficoltà nel riprodurre in maniera immediata la nuova distribuzione condizionata dei rendimenti. Di conseguenza, l'adeguamento della componente di lungo periodo può avvenire in ritardo rispetto alla realizzazione delle perdite estreme, contribuendo all'eccesso del violation rate.

Per quanto riguarda l'Expected Shortfall, esso, preso singolarmente, non ammette una funzione di scoring strettamente consistente. Per superare questo ostacolo, viene condotta una valutazione empirica della qualità previsionale congiuntamente per il VaR e l'ES; in questo modo il confronto tra i modelli assume robustezza. Le procedure utilizzate nell'analisi si articolano in tre componenti: test di calibrazione dinamica, funzioni di perdita per la valutazione *out-of-sample* e test di Diebold-Mariano per confrontare l'accuratezza predittiva.

Per effettuare tali test il focus principale si sposta sul periodo *out-of-sample* piuttosto che sulla valutazione anche del periodo *in-sample*. Oltre alle spe-

cificazioni MF2-GARCH utilizzate precedentemente nell'analisi del Value at Risk, vengono presi in considerazione la Historical Simulation (HS) come benchmark non parametrico e il GJR-GARCH, con innovazioni sia Normali che  $t$  di Student.

Il benchmark dell'Historical Simulation costruisce le misure di rischio direttamente partendo dalla distribuzione empirica dei rendimenti, in particolare per ogni origine  $t$ , le previsioni sono ottenute utilizzando una finestra rolling con ampiezza fissa  $W = 252$  osservazioni, e per ciascuna data del campione *out-of-sample* viene utilizzata solamente l'informazione disponibile fino al giorno precedente. Il VaR storico è definito come il quantile empirico della coda di sinistra della distribuzione dei rendimenti, mentre l'ES è ottenuto come media dei rendimenti inferiori o uguali a tale quantile.

Per fornire un quadro completo, sono presentati dei test di calibrazione dinamica delle due misure di rischio, Joint Scoring Performance tramite funzioni di perdita rispetto ad HS e test di Diebold-Mariano.

I test di calibrazione dinamica hanno lo scopo principale di verificare se le previsioni di VaR e ES risultino coerenti con l'informazione disponibile al momento della previsione. A tal fine, vengono applicati i test del Dynamic Quantile (DQ) per il VaR, introdotto da Engle & Manganelli (2004), e del Dynamic Expected Shortfall (DES), proposto da Patton et al. (2019). Entrambi i test si basano sull'utilizzo di residui generalizzati, ottenuti tramite derivate parziali sulla funzione di perdita  $L_{FZ0}$  di Patton et al. (2019), appartenente al framework di funzioni di scoring di Fissler & Ziegel (2016). Per mitigare l'impatto della correlazione seriale (indotta dalla persistenza di  $v_t$  e  $e_t$ ) vengono utilizzate versioni standardizzate dei residui

$$\lambda_{v,t}^s = \mathbf{1}\{r_t \leq v_t\} - \alpha, \quad (4.42)$$

$$\lambda_{e,t}^s = \frac{1}{\alpha} \mathbf{1}\{r_t \leq v_t\} \frac{r_t}{e_t} - 1, \quad (4.43)$$

con  $r_t$  pari al rendimento osservato, mentre  $v_t$  e  $e_t$  indicano rispettivamente il VaR e l'ES previsti al tempo  $t$ . La calibrazione dinamica delle due misure di rischio viene valutata dai test DQ e DES con una regressione dei residui su un set di informazioni disponibile al tempo  $t - 1$

$$\lambda_{v,t}^s = a_0 + a_1 \lambda_{v,t-1}^s + a_2 v_t + u_{v,t}, \quad (4.44)$$

$$\lambda_{e,t}^s = b_0 + b_1 \lambda_{e,t-1}^s + b_2 e_t + u_{e,t}, \quad (4.45)$$

dove  $a_i$  e  $b_i$  sono i parametri da stimare. La verifica dell'ipotesi nulla di corretta calibrazione dinamica richiede che tutti i coefficienti siano simultaneamente nulli. Inoltre, le statistiche test sono distribuite asintoticamente come una  $\chi^2$  con errori robusti HAC.

Successivamente, per la valutazione congiunta delle misure di rischio vengono utilizzate due diverse funzioni di scoring, impiegate come funzioni di perdita da minimizzare nella valutazione *out-of-sample*: la funzione Asymmetric Laplace (AL) e la funzione FZ0. La prima funzione è stata formalizzata da Taylor (2019), che ha dimostrato come la funzione di log-verosimiglianza negativa della distribuzione asimmetrica di Laplace<sup>10</sup> corrisponda a una funzione di perdita congiunta per il VaR e l'ES. Nello specifico, la funzione AL penalizza gli errori di previsione considerando sia il superamento del quantile sia l'entità della perdita nella coda. Per una singola osservazione al tempo  $t$ , la funzione è definita

$$L(r_t, v_t, e_t, \alpha) = -\ln\left(\frac{\alpha - 1}{e_t}\right) - \frac{(r_t - v_t)(\alpha - I(r_t \leq v_t))}{\alpha e_t}. \quad (4.46)$$

L'appartenza di tale funzione alla classe delle funzioni di scoring di Fissler & Ziegel (2016) garantisce che la sua minimizzazione restituisca congiuntamente il VaR e l'ES, superando l'ostacolo legato alla non elicitabilità dell'Expected Shortfall considerato singolarmente. In questo modo, è possibile confrontare i modelli sulla base del valore medio della perdita, per cui valori più bassi indicano migliori performance predittive.

La seconda metrica è lo score FZ0 trattato da Patton et al. (2019), appartenente alla classe di funzioni di scoring consistenti di Fissler & Ziegel (2016). La funzione di perdita assume come ipotesi rilevante che  $v_t$  e  $e_t$  siano strettamente negativi, e presenta la proprietà per cui il differenziale della perdita media dei modelli è omogeneo di grado zero, pertanto invariante rispetto a trasformazioni di scala<sup>11</sup>. Questa proprietà, in maniera analoga alla funzione QLIKE utilizzata per le previsioni *out-of-sample* nelle sezioni precedenti, riduce la dipendenza del confronto dalla scala delle osservazioni e favorisce una comparazione più efficace e robusta in periodi turbolenti dei mercati. La

<sup>10</sup>La distribuzione asimmetrica di Laplace è una distribuzione di probabilità continua che estende la distribuzione di Laplace basata sull'utilizzo di due distribuzioni esponenziali con velocità di decadimento differenti a sinistra e a destra della moda. Le due code consentono il trattamento di fenomeni asimmetrici.

<sup>11</sup>L'omogeneità di grado zero implica che gli errori previsionali vengano valutati in termini relativi piuttosto che assoluti. Nell'equazione 4.46, sia i rendimenti che il VaR sono rapportati all'Expected Shortfall; di conseguenza, l'elevata magnitudo delle perdite viene divisa per un ES altrettanto elevato, neutralizzando l'effetto di scala dei dati.

funzione di perdita FZ0 è definita

$$L_{FZ0}(r_t, v_t, e_t; \alpha) = -\frac{1}{\alpha e_t} \mathbf{1}\{r_t \leq v_t\} (v_t - r_t) + \frac{v_t}{e_t} + \log(-e_t) - 1. \quad (4.47)$$

Nel momento in cui si verifica una violazione del VaR, rimane il primo termine e viene aggiunta una penalizzazione crescente nella distanza tra il rendimento realizzato e il VaR previsto. Come per la funzione precedente, il criterio di confronto si basa sul valore medio più basso della perdita nel campione *out-of-sample*.

Per concludere l'analisi congiunta sulle due misure di rischio, vengono effettuati i test di Diebold-Mariano, ossia dei test che permettono di confrontare l'accuratezza predittiva di due modelli sulla base di una generica funzione di perdita. Nel presente lavoro, il confronto viene effettuato separatamente per le due funzioni di perdita introdotte, per ciascun livello di rischio  $\alpha$  e per ogni specificazione MF2 rispetto a due benchmark, ossia l'Historical Simulation e il GJR-GARCH. Il differenziale al tempo  $t$  è definito

$$d_t^{(L)} = L_t^{\text{MF2}} - L_t^{\text{Benchmark}}. \quad (4.48)$$

Per costruzione, valori negativi di  $d_t^{(L)}$  implicano una performance migliore rispetto al benchmark. La statistica DM viene costruita come

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}}, \quad (4.49)$$

dove  $\bar{d} = 1/T \sum_{t=1}^T d_t^{(L)}$  e la varianza della media campionaria è costruita con uno stimatore HAC. Il test verifica l'ipotesi nulla di uguale accuratezza previsionalmente contro l'ipotesi alternativa *one-sided*  $H_1 : E[d_t^{(L)}] < 0$  secondo cui il modello MF2 performa meglio del benchmark considerato.

La tabella 4.9 mostra i risultati principali per l'MF2-GARCH e il GJR-GARCH; in particolare sono confrontate le performance *out-of-sample* rispetto al benchmark Historical Simulation utilizzando le due funzioni di scoring interpretate come funzioni di loss, e affiancando i p-value dei test di calibrazione dinamica DQ e DES. Inoltre, per entrambe le funzioni di perdita viene riportata una misura percentuale di performance relativa rispetto al benchmark. Essa è ottenuta come  $100(1 - \bar{L}_{\text{Modello}}/\bar{L}_{\text{Benchmark}})$ , con  $\bar{L}$  che indica la perdita media. A valori più elevati corrisponde una maggiore riduzione percentuale della perdita media rispetto al benchmark.

Tabella 4.9: Performance congiunte *out-of-sample* relative all'Historical Simulation: MF2-GARCH e GJR-GARCH.

| Modello                                   | $m$ | Distribuzione | AL     | AL Skill (%) | FZ0    | FZ0 Skill (%) | DQ p   | DES p  |
|-------------------------------------------|-----|---------------|--------|--------------|--------|---------------|--------|--------|
| <i>Panel A: <math>\alpha = 1\%</math></i> |     |               |        |              |        |               |        |        |
| <i>MF2-GARCH</i>                          |     |               |        |              |        |               |        |        |
| MF2                                       | 21  | Normal        | 2.3982 | 6.2936       | 1.3710 | 10.8000       | 0.0000 | 0.0000 |
| MF2                                       | 21  | Student- $t$  | 2.2631 | 11.5740      | 1.2390 | 19.3890       | 0.0087 | 0.0053 |
| MF2                                       | 63  | Normal        | 2.3774 | 7.1072       | 1.3500 | 12.1680       | 0.0001 | 0.0000 |
| MF2                                       | 63  | Student- $t$  | 2.2466 | 12.2200      | 1.2223 | 20.4790       | 0.0134 | 0.0078 |
| <i>GJR-GARCH</i>                          |     |               |        |              |        |               |        |        |
| GJR                                       | –   | Normal        | 2.4090 | 5.8712       | 1.3819 | 10.0960       | 0.0000 | 0.0000 |
| GJR                                       | –   | Student- $t$  | 2.2693 | 11.3320      | 1.2451 | 18.9970       | 0.0032 | 0.0020 |
| <i>Panel B: <math>\alpha = 5\%</math></i> |     |               |        |              |        |               |        |        |
| <i>MF2-GARCH</i>                          |     |               |        |              |        |               |        |        |
| MF2                                       | 21  | Normal        | 1.8500 | 9.7514       | 0.7764 | 20.8300       | 0.3446 | 0.0067 |
| MF2                                       | 21  | Student- $t$  | 1.8412 | 10.1780      | 0.7691 | 21.5740       | 0.0412 | 0.0073 |
| MF2                                       | 63  | Normal        | 1.8404 | 10.2190      | 0.7666 | 21.8350       | 0.1596 | 0.0032 |
| MF2                                       | 63  | Student- $t$  | 1.8324 | 10.6080      | 0.7601 | 22.5000       | 0.0099 | 0.0025 |
| <i>GJR-GARCH</i>                          |     |               |        |              |        |               |        |        |
| GJR                                       | –   | Normal        | 1.8554 | 9.4840       | 0.7820 | 20.2680       | 0.0853 | 0.0009 |
| GJR                                       | –   | Student- $t$  | 1.8469 | 9.9023       | 0.7748 | 21.0010       | 0.0196 | 0.0027 |

*Note:* La tabella riporta le medie delle perdite *out-of-sample* per le previsioni congiunte di VaR ed ES basate sulle funzioni di scoring Asymmetric Laplace (AL) e FZ0 per le specifiche MF2-GARCH e GJR-GARCH, insieme ai  $p$ -value dei test di calibrazione dinamica DQ e DES. Le performance dei modelli sono valutate rispetto al benchmark Historical Simulation (HS). Valori più bassi delle medie AL e FZ0 indicano una migliore performance previsiva, mentre valori più elevati degli skill score indicano un miglioramento relativo rispetto al benchmark. Per tutte le specifiche, il periodo di valutazione è gennaio 2010 – settembre 2025.

Dal punto di vista della Joint Scoring Performance, emerge, per entrambe le soglie di rischio all'1% e al 5%, che le specificazioni  $t$  di Student presentano valori di perdita media inferiori rispetto alle specificazioni Normali, sia per il GJR che per l'MF2. Le innovazioni  $t$  di Student, essendo caratterizzate da code più pesanti, riescono a rappresentare con più accuratezza la probabilità e la severità degli eventi estremi, apportando migliorie alla previsione congiunta di VaR e ES. Per quanto riguarda il confronto tra i casi dell'MF2, le differenze risultano abbastanza contenute, ma leggermente favorevoli a  $m = 63$ , di conseguenza l'MF2-GARCH-rw-63 con innovazioni  $t$  di Student si mostra come il più performante in termini di scoring congiunto. Confrontando quest'ultimo con il GJR-GARCH, anche in questo caso l'MF2 mantiene un vantaggio in termini di perdita media, coerentemente con la maggiore flessibilità del modello MF2 nel rappresentare la componente di lungo periodo. Nell'analisi della calibrazione dinamica, emerge una situazione non molto favorevole, in quanto i  $p$ -value dei due test DQ e DES sono molto bassi, quasi nulli, segnalando rifiuti dell'ipotesi nulla di corretta calibrazione dinamica. Si può notare un lieve miglioramento



nei test DQ per  $\alpha = 5\%$ , mentre i test DES mantengono i medesimi problemi. Tali risultati suggeriscono che, anche in presenza di performance valide in termini di perdita media, la dinamica congiunta delle due misure di rischio non risulta ben specificata. Tuttavia, è importante sottolineare che il frequente rifiuto dei due test non è un'anomalia nel contesto analizzato: Patton et al. (2019) valutano infatti diversi modelli sui rendimenti dell'S&P 500, ottenendo a loro volta valori sfavorevoli nei test di bontà d'adattamento, che mostrano p-value molto bassi. Quindi, tale evidenza può essere in parte ricondotta alla struttura dei rendimenti dell'S&P 500, caratterizzata da molti episodi di turbolenza dei mercati che vanno a complicare la calibrazione dinamica congiunta su *out-of-sample* ampi.

In generale, le medie delle perdite risultano molto utili per comprendere le performance predittive *out-of-sample*, ma non dimostrano se i guadagni siano statisticamente significativi. Per questo motivo, la tabella 4.10 mostra le statistiche Diebold-Mariano sulle differenze delle perdite, che indicano una migliore performance del modello MF2 per valori negativi della statistica DM, con il relativo p-value che indica se il miglioramento è statisticamente significativo o meno. Come benchmark, vengono utilizzati l'Historical Simulation e il GJR-GARCH con distribuzione Normale e  $t$  di Student.

Tabella 4.10: Diebold–Mariano test per l'MF2-GARCH sui benchmark HS, GJR- $t$ , e GJR-Normal.

| $m$                     | Distribuzione | Historical Simulation |            |         |            | GJR- $t$ |            |         |            | GJR-Normal |            |         |            |
|-------------------------|---------------|-----------------------|------------|---------|------------|----------|------------|---------|------------|------------|------------|---------|------------|
|                         |               | AL                    |            | FZ0     |            | AL       |            | FZ0     |            | AL         |            | FZ0     |            |
|                         |               | DM                    | $p$ -value | DM      | $p$ -value | DM       | $p$ -value | DM      | $p$ -value | DM         | $p$ -value | DM      | $p$ -value |
| Panel A: $\alpha = 1\%$ |               |                       |            |         |            |          |            |         |            |            |            |         |            |
| 21                      | Normal        | -1.1234               | 0.1306     | -1.1482 | 0.1255     | 3.7684   | 0.9999     | 3.6325  | 0.9998     | -0.6329    | 0.2634     | -0.6262 | 0.2656     |
| 21                      | Student- $t$  | -2.2174               | 0.0133     | -2.2113 | 0.0135     | -0.4553  | 0.3244     | -0.4389 | 0.3303     | -4.0863    | 0.0000     | -3.9394 | 0.0000     |
| 63                      | Normal        | -1.3013               | 0.0966     | -1.3265 | 0.0923     | 3.0286   | 0.9987     | 2.8955  | 0.9981     | -1.2132    | 0.1125     | -1.2121 | 0.1127     |
| 63                      | Student- $t$  | -2.3848               | 0.0085     | -2.3788 | 0.0087     | -1.1260  | 0.1300     | -1.1194 | 0.1314     | -3.9729    | 0.0000     | -3.8588 | 0.0000     |
| Panel B: $\alpha = 5\%$ |               |                       |            |         |            |          |            |         |            |            |            |         |            |
| 21                      | Normal        | -3.5942               | 0.0002     | -3.5534 | 0.0002     | 0.5147   | 0.6966     | 0.2668  | 0.6051     | -0.9718    | 0.1655     | -0.9225 | 0.1781     |
| 21                      | Student- $t$  | -3.8001               | 0.0001     | -3.7238 | 0.0001     | -1.0350  | 0.1503     | -0.9713 | 0.1657     | -2.4085    | 0.0080     | -2.0485 | 0.0202     |
| 63                      | Normal        | -3.8834               | 0.0001     | -3.8401 | 0.0001     | -0.8445  | 0.1991     | -1.0131 | 0.1555     | -1.9363    | 0.0264     | -1.8843 | 0.0297     |
| 63                      | Student- $t$  | -4.0751               | 0.0000     | -3.9960 | 0.0000     | -1.9577  | 0.0251     | -1.8967 | 0.0289     | -2.8609    | 0.0021     | -2.6090 | 0.0045     |

*Note:* La tabella riporta i test di Diebold–Mariano (DM) che confrontano le previsioni MF2-GARCH con tre benchmark utilizzando gli score congiunti VaR-ES AL e FZ0: Historical Simulation (HS), GJR-GARCH-Normale e GJR-GARCH- $t$ . Il differenziale di perdita è definito come  $d_t = L_t^{MF2} - L_t^B$ , dove  $B$  denota il benchmark; pertanto, statistiche DM negative indicano una perdita inferiore (prestazione migliore) per MF2. I p-value riportati sono a una coda e corrispondono all'ipotesi alternativa  $H_1 : E[d_t] < 0$  (MF2 supera il benchmark). Per tutte le specifiche, il periodo di valutazione è da gennaio 2010 a settembre 2025.

I risultati del pannello A mostrano un vantaggio per l'MF2-GARCH sull'Historical Simulation per la maggior parte delle specificazioni, soprattutto per

le specificazioni  $t$  di Student che presentano i p-value più bassi. Le statistiche DM negative sottolineano i valori medi di perdita inferiori per il modello principale. I modelli con innovazioni Normali presentano invece un vantaggio più debole; per  $m = 63$  il vantaggio è significativo al 10%, mentre per  $m = 21$  il vantaggio non è statisticamente significativo. Se si assume come riferimento il GJR-GARCH- $t$ , i p-value per gli MF2 con distribuzione Normale sono coerenti con una performance migliore del benchmark. A parità di distribuzione le differenze risultano negative, quindi a favore del modello MF2, ma i p-value non mostrano evidenza statistica di superiorità. Se si considera come benchmark un GJR-GARCH-Normale, le specificazioni MF2 con  $t$  di Student risultano superiori, anche con evidenza statistica, mentre l'MF2 con distribuzione Normale non presenta differenze statisticamente significative. Nel pannello B, i risultati favoriscono maggiormente MF2. I test DM sull'Historical Simulation mostrano un netto vantaggio del modello MF2, poiché le differenze risultano estremamente negative e il p-value quasi nullo su tutte le specificazioni conferma il risultato. Tale aspetto non si verifica nel confronto con il GJR- $t$ : assumendo distribuzione Normale, sia per  $m = 21$  che  $m = 63$  non c'è evidenza significativa di superiorità delle performance, mentre la specificazione MF2  $t$  di Student con  $m = 63$  presenta una differenza statisticamente significativa per entrambi i test. Infine, rispetto al GJR con distribuzione Normale, la superiorità è significativa per entrambe le specificazioni  $t$  di Student e per la specificazione Normale con  $m = 63$ , mentre l'MF2-Normale con  $m = 21$  non si distingue dal benchmark.

Complessivamente, il modello MF2-GARCH si presta in modo naturale alla costruzione delle misure di rischio dinamiche come il VaR e l'ES. Tuttavia, l'analisi *out-of-sample* nel periodo considerato, e per il dataset considerato, rappresenta un test molto severo per la maggior parte dei modelli a finestra mobile stimati a lunghezza fissa. Le ipotesi rifiutate nei backtest per il VaR e nei test congiunti con l'ES derivano in parte dalla complessità strutturale di un dataset dinamico come l'S&P 500, caratterizzato da cambi di regime, code estreme e fasi di stress che persistono. In questo contesto, i confronti basati sulle funzioni di perdita vanno intesi come una misura relativa della capacità dei modelli di adattarsi a un ambiente di mercato instabile. Di conseguenza, diventa difficile individuare con evidenza statistica il modello migliore. Inoltre, Taylor (2019, 2020) documenta che la presenza o l'esclusione di periodi di volatilità elevata influenzano notevolmente l'accuratezza delle previsioni. In particolare, notano che la prima parte del periodo *out-of-sample* più vicino

alla crisi del 2008 è decisamente più volatile della parte successiva, rafforzando l'idea che una parte delle performance risulta attribuibile al regime del mercato piuttosto che a un limite del modello.




Figura 4.9: *Previsione Value at Risk e Expected Shortfall nel sottoperiodo da gennaio 2019 a dicembre 2023. I modelli sono un MF2-GARCH-rw-21 con  $t$  di Student e un GJR-GARCH- $t$ .*

La figura 4.9 consente di completare l'analisi sul VaR e l'ES, in quanto permette di osservare il comportamento dei modelli in un sottoperiodo del campione principale. Si osserva uno scostamento brusco nelle fasi di massimo stress nel 2020, con un ridimensionamento graduale nei periodi successivi. Sul piano grafico, le previsioni fornite dai due modelli risultano molto simili, confermando quanto osservato nei test precedenti, ossia la difficoltà nell'evidenziare la netta superiorità di un modello rispetto a un altro. Di conseguenza, la figura mostra come, in un contesto caratterizzato da elevata instabilità dei rendimenti e frequenti cambi di regime, la calibrazione dinamica di VaR e ES risulti problematica per entrambi gli approcci.

# Conclusioni

La ricerca e lo studio condotti in questo elaborato risultano coerenti con l'evidenza di Conrad e Engle; il modello MF2 si mostra molto stabile nel lungo periodo presentando caratteristiche migliori rispetto sia ai modelli tradizionali che ad altri competitor come il MIDAS. Tra i vari modelli introdotti, il modello GJR-GARCH è stato il più utilizzato per il confronto con il modello principale, in modo da verificare in che modo essi reagiscano alle dinamiche di mercato. Oltre a questo, anche il MIDAS-RV ha avuto un ruolo importante nell'analisi; appartenendo alla stessa famiglia del modello MF2, consente un confronto di lungo periodo più robusto.

L'analisi *in-sample* ha mostrato come la specificazione standard si adatti meglio rispetto sia alle estensioni dell'MF2 che ai modelli concorrenti, mostrando i valori di BIC più bassi e di log-verosimiglianza più alti. Le figure ottenute dalle stime *in-sample* mostrano come la scomposizione del modello principale consenta di isolare i picchi di volatilità temporanei, come il collasso del 1987 o lo shock del 2020, dal livello di rischio sistemico di fondo, garantendo una valutazione più realistica della persistenza degli shock.

Dopodiché, è stato mostrato come l'MF2-GARCH presenti performance predittive molto valide per orizzonti di previsione *forward* molto lunghi. L'analisi ha mostrato che, sebbene il GJR e il MIDAS risultino molto competitivi per orizzonti brevi, l'MF2-GARCH emerge come strumento più accurato e robusto a medio-lungo termine. Tali risultati emergono sia nel sottocampione che nel periodo completo; la struttura dell'MF2 evita una convergenza prematura verso la varianza incondizionata tipica del modello GJR, e si distacca dal MIDAS-RV convergente ad una varianza infinita.

La simulazione Monte Carlo è stata effettuata per descrivere e confermare le proprietà asintotiche dello stimatore QMLE anche in campioni finiti di dimensioni realistiche: la corrispondenza tra RMSE e ASE indica la buona approssimazione delle formule asintotiche; le due funzioni di perdita si riducono all'aumentare della dimensione campionaria, confermando la consisten-

za dello stimatore. Tuttavia, all'aumentare della finestra  $m$ , le funzioni di perdita subiscono un aumento sensibile, dovuto ad una maggiore complessità dell'ottimizzazione che penalizza la precisione delle stime.

Le regressioni sui tracker EMV hanno messo in evidenza una relazione positiva e statisticamente significativa tra le variazioni della volatilità a lungo termine e l'insieme delle notizie macroeconomiche, sottolineando come la volatilità di fondo sia sensibile all'incertezza macro-finanziaria. Tale caratteristica ribadisce la superiorità del modello MF2 nell'incorporare informazioni rispetto a un MIDAS che richiede una specifica variabile esogena. L'MF2-GARCH si è mostrato anche in grado di elaborare in maniera realistica e asimmetrica l'impatto delle notizie, in particolare delle *good news*, con un'ottima capacità di distinzione dei diversi canali di trasmissione delle notizie.

Infine, la valutazione sulle misure di rischio ha mostrato alcune limitazioni anche del modello principale, se applicato al nostro dataset di riferimento. Nell'analisi del VaR *out-of-sample*, la maggior parte dei test rifiuta l'ipotesi nulla, evidenziando una difficoltà nel tradurre la previsione in soglie di rischio estreme ben calibrate. D'altra parte, nella valutazione congiunta del VaR e dell'ES, la maggior parte dei risultati risulta a favore dell'MF2, senza però evidenti conferme di significatività statistica, soprattutto se confrontato con un modello GJR. La motivazione principale di questi risultati è da ricercare nel dataset utilizzato, poiché anche la letteratura econometrica mostra come valutazioni del VaR sull'S&P 500 mostrino problematiche nella corretta interpretazione delle violazioni.

In conclusione si può affermare che in ambito previsionale il modello risulti molto efficace nel cogliere i cicli persistenti della volatilità. In generale, il modello fornisce un quadro informativo stabile e completo, particolarmente utile nell'ambito dell'asset allocation, risultando particolarmente robusto nel lungo periodo, mentre richiede maggiore prudenza quando applicato nel campo della gestione del rischio. L'analisi svolta si è mostrata coerente con le evidenze riportate da Conrad e Engle, fornendo ulteriore supporto alla validità empirica del modello.

# Appendice

## Dati della volatilità di Da & Xiu

Per evitare distorsioni causate da *microstructure noise*, si sceglie di utilizzare i dati di volatilità ottenuti da Da & Xiu (2021).

L'approccio presentato da Xiu (2010) parte dall'assunzione secondo cui il log-prezzo osservato, individuato con  $X_{\tau_i}$ , sia contaminato dal rumore, indicato con  $U_{\tau_i}$ , tale per cui

$$\tilde{X}_{\tau_i} = X_{\tau_i} + U_{\tau_i}, \quad (\text{A.1})$$

dove  $\tilde{X}_{\tau_i}$  è il prezzo latente efficiente e  $U_{\tau_i}$  è i.i.d. con media zero e varianza  $a^2$ . Di conseguenza, i rendimenti osservati  $Y_i$  non sono indipendenti, ma seguono una struttura MA(1). Il rendimento logaritmico osservato per l' $i$ -esimo intervallo è definito come

$$Y_i = \tilde{X}_{\tau_i} - \tilde{X}_{\tau_{i-1}} = \sigma(W_{\tau_i} - W_{\tau_{i-1}}) + (U_{\tau_i} - U_{\tau_{i-1}}), \quad (\text{A.2})$$

dove  $(W_{\tau_i} - W_{\tau_{i-1}})$  rappresenta l'incremento del moto browniano standard. Lo stimatore QMLE prevede la costruzione della funzione di verosimiglianza sotto l'ipotesi di volatilità  $(\sigma_t)$  costante nella finestra di stima e di rumore Gaussiano. Da & Xiu (2021) dimostra che lo stimatore mantiene le proprietà di consistenza ed efficienza asintotica ottimale anche in presenza di volatilità stocastica; quindi, dimostra che massimizzare la verosimiglianza sull'ipotesi di volatilità stocastica produce stime di volatilità integrata efficienti. I parametri  $\sigma^2$  e  $a^2$  vengono stimati massimizzando la seguente funzione di quasi-verosimiglianza

$$l(\sigma^2, a^2) = -\frac{1}{2} \log \det(\Omega) - \frac{n}{2} \log(2\pi) - \frac{1}{2} Y' \Omega^{-1} Y, \quad (\text{A.3})$$

dove  $Y$  è il vettore dei rendimenti osservati e  $\Omega$  matrice di varianza-covarianza che incorpora la struttura di autocorrelazione indotta dal rumore. Assumendo che le osservazioni siano equispaziate con passo  $\Delta$ ,  $\Omega$  è una matrice  $n \times n$

definita come

$$\Omega = \begin{pmatrix} \sigma^2\Delta + 2a^2 & -a^2 & 0 & \cdots & 0 \\ -a^2 & \sigma^2\Delta + 2a^2 & -a^2 & \ddots & \vdots \\ 0 & -a^2 & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & \sigma^2\Delta + 2a^2 & -a^2 \\ 0 & \cdots & 0 & -a^2 & \sigma^2\Delta + 2a^2 \end{pmatrix}, \quad (\text{A.4})$$

dove gli elementi della diagonale indicano la varianza del singolo rendimento osservato, composta dalla varianza del prezzo efficiente per più il doppio della varianza del rumore, mentre i termini fuori dalla diagonale catturano l'auto-correlazione negativa di primo tipo tipica del *bid-ask bounce*. Tale configurazione, costituita da valori non nulli esclusivamente sulla diagonale principale e sulle due diagonali adiacenti, riflette la struttura di un processo a media mobile di ordine 1, MA(1), che caratterizza i rendimenti osservati in presenza di rumore microstrutturale i.i.d..

## Dichiarazione sull'utilizzo di intelligenza artificiale

Nell'elaborazione della tesi sono stati utilizzati diversi strumenti di IA generativa, quali Claude, Gemini e ChatGPT, per attività di supporto alla ricerca bibliografica, alla revisione critica del testo e alla scrittura del codice. In particolare, i codici relativi all'analisi empirica svolta nel quarto capitolo sono stati sviluppati con il supporto di tali strumenti, ma successivamente controllati, corretti e adattati in modo autonomo. L'utilizzo di tali strumenti ha avuto un ruolo esclusivamente di supporto, senza mai sostituire il ragionamento, le scelte metodologiche e il lavoro intellettuale. Tutte le interpretazioni e i risultati presentati sono stati integralmente verificati; mi assumo la responsabilità dei contenuti presentati nel lavoro.

# Codice Matlab

```
1 %% =====
2 %% CODICI PRINCIPALI PER LA STIMA E LA PREVISIONE
3 %% DEL MODELLO MF2-GARCH
4 %
5 %% I blocchi seguenti sono script indipendenti, riportati in forma
6 %% compatta per illustrare i passaggi principali dell'analisi empirica.
7 %% Per l'implementazione del modello MF2-GARCH sono state utilizzate
8 %% le funzioni del toolbox ufficiale di Conrad & Engle (2025):
9 %% https://github.com/juliustheodor/mf2garch.git
10 %% =====
11 %% =====
12 %% SCRIPT A - STIMA IN-SAMPLE DEL MODELLO MF2-GARCH-rw-m
13 %% =====
14
15 %% 1. DATI IN INPUT
16 Prices = readtable('Prezzi1971_2025.xlsx');
17
18 P      = Prices.GSPCAdjusted;
19 dates  = Prices.Date(2:end);
20 y      = 100 * diff(log(P));
21
22 %% 2. SPECIFICAZIONE DEL MODELLO
23 foptions.m = 63; % ad esempio: MF2-GARCH-rw-63
24
25 %% 3. STIMA IN-SAMPLE
26 [coeff, qmle_se, p_value_qmle, Z, h, tau, sigma_annual, tau_annual, ...
27   annual_unconditional_vola, foptions] = mf2_garch_estimation(y, foptions);
28
29 %% ----- 4. OUTPUT PRINCIPALI -----
30 % coeff          -> vettore dei parametri stimati
31 % qmle_se        -> errori standard QMLE
32 % p_value_qmle   -> p-value associati alle stime
33 % h, tau         -> componenti short-run e long-run
34 % sigma_annual   -> volatilita condizionata annualizzata
35 % tau_annual     -> componente di lungo periodo annualizzata
36 % annual_unconditional_vola -> volatilita incondizionata annualizzata
37
38 %% =====
39 %% SCRIPT B - PREVISIONI OUT-OF-SAMPLE DELLA VARIANZA CONDIZIONATA
40 %% =====
41
42 %% 1. CONFIGURAZIONE GENERALE
43 dataFile = 'Prezzi_e_Volatilita_Realizzata_1996_2025.xlsx';
44 dateCol  = 'Date';
45 priceCol = 'GSPCAdjusted';
46 rvCol    = 'VolatilityQUOTE';
47
48 evalStart = datetime(2010,1,1);
49 evalEnd   = datetime(2025,9,29); % per il sottocampione: datetime
50                                     (2019,12,31)
51
52 winLen = 2520; % finestra rolling di stima (circa 10 anni)
53 reEstep = 21; % ri-stima dei parametri ogni 21 giorni
54 mFix    = 63; % specificazione MF2-GARCH-rw-m
```



```

54
55 scaleMode = 'fixed';           % 'none' oppure 'fixed' (per entrambi i
56 calStart  = datetime(2000,1,1); % periodi e' stato utilizzato 'fixed'
57 calEnd    = datetime(2009,12,31);
58
59 excludeOutlierBlocks = true;
60 outlierPct = 99;
61
62 epsPos = 1e-12;
63
64 %% 2. CARICAMENTO E PREPARAZIONE DEI DATI
65 T = readtable(dataFile);
66
67 d = T.(dateCol);
68 P = T.(priceCol);
69 rv = T.(rvCol);
70
71 y = 100 * diff(log(P));
72 d = d(2:end);
73 rv = rv(2:end);
74
75 % Realized variance giornaliera annualizzata riportata a frequenza daily
76 RVO = (100 * rv).^2 / 252;
77
78 %% 3. DEFINIZIONE DEGLI ORIZZONTI DI PREVISIONE
79 H = [];
80 % Orizzonte a 1 giorno
81 H(1).name = 'Day'; H(1).a = 1; H(1).b = 1; H(1).L = 1;
82 % Orizzonte a 1 settimana
83 H(2).name = 'Week'; H(2).a = 1; H(2).b = 5; H(2).L = 5;
84 % Blocchi mensili non cumulativi: 1m, ..., 8m
85 for s = 1:8
86     i = s + 2;
87     H(i).name = sprintf('%dm', s);
88     H(i).a = (s-1)*21 + 1;
89     H(i).b = s*21;
90     H(i).L = 21;
91 end
92 nH = length(H);
93 Smax = max([H.b]);
94
95 %% 4. DEFINIZIONE DEGLI ORIGIN OUT-OF-SAMPLE
96 iLastEval = find(d <= evalEnd, 1, 'last');
97 iFirstEval = find(d >= evalStart, 1, 'first');
98
99 % Primo origin utilizzabile: devo avere almeno winLen osservazioni passate
100 i0_min = max(winLen, iFirstEval - 1);
101
102 % Ultimo origin ammissibile per ciascun orizzonte
103 i0_max_h = arrayfun(@(hh) iLastEval - H(hh).b, 1:nH);
104
105 % Gli origin vengono generati fino al massimo ammissibile per l'orizzonte Day;
106 % i vincoli dei restanti orizzonti sono verificati nel loop principale.
107 i0_max_day = i0_max_h(1);
108 originsAll = i0_min : i0_max_day;
109 n0 = numel(originsAll);
110

```

```

111 %% 5. IDENTIFICAZIONE ED ESCLUSIONE DEGLI OUTLIER
112 % Inizializzazione: nessun giorno e' outlier
113 isOutlierDay = false(size(RV0));
114
115 if excludeOutlierBlocks
116     % Giorni appartenenti al periodo out-of-sample
117     idxOOS = (d >= evalStart) & (d <= evalEnd);
118     % Soglia outlier: percentile scelto della RV nel solo periodo OOS
119     thrOut = prctile(RV0(idxOOS), outlierPct);
120     % Un giorno e' outlier se e' in OOS e supera la soglia
121     isOutlierDay = idxOOS & (RV0 >= thrOut);
122 end
123 % Somma cumulata per verificare rapidamente se un blocco contiene outlier
124 outCum = [0; cumsum(isOutlierDay)];
125
126 %% 6. CALCOLO DEL FATTORE DI SCALA
127 c0 = 1.0;
128
129 idxCal = (d >= calStart) & (d <= calEnd);
130 num = mean(y(idxCal).^2, 'omitnan');
131 den = mean(RV0(idxCal), 'omitnan');
132 c0 = num / max(den, epsPos);
133
134 %% 7. PRE-ALLOCAZIONE DELLE VARIABILI
135 SE_mf2 = nan(n0, nH);
136 SE_hist = nan(n0, nH);
137 QL_mf2 = nan(n0, nH);
138 QL_hist = nan(n0, nH);
139 m_used = nan(n0,1);
140 c_used = nan(n0,1);
141 coeffCurr = [];
142 mCurr      = mFix;
143
144 %% 8. CICLO PRINCIPALE DI STIMA E PREVISIONE
145 for j = 1:n0
146     % Origin corrente t
147     i0 = originsAll(j);
148     % Finestra rolling di stima
149     iStart = i0 - winLen + 1;
150     yWin    = y(iStart:i0);
151     RVWin0  = RV0(iStart:i0);
152
153     % ----- 8.1 Fattore di scala -----
154     if strcmpi(scaleMode, 'none')
155         c = 1.0;
156     elseif strcmpi(scaleMode, 'fixed')
157         c = c0;
158     end
159     c_used(j) = c;
160
161     % ----- 8.2 Ri-stima dei parametri -----
162     if mod(j-1, reEstep) == 0 || isempty(coeffCurr)
163         foptE = struct();
164         foptE.choice = 'fix';
165         foptE.m      = mFix;
166         evalc('[coeffCurr,~,~,~,~,~,~,~,~,foptE] = mf2_garch_estimation(yWin,
167             foptE);');

```

```

167     end
168     mCurr = mFix;
169     m_used(j) = mCurr;
170
171     % ----- 8.3 Filtraggio delle componenti latenti -----
172     [Z, h, tau, ~] = mf2_garch_core(coeffCurr, yWin, mCurr);
173
174     % Numero massimo di passi previsti senza uscire da evalEnd
175     S_here = min(Smax, iLastEval - i0);
176
177     % ----- 8.4 Forecast della varianza condizionata -----
178     foptF = struct('m', mCurr, 'S', S_here);
179     evalc('[~, sigma2_all, ~, ~, ~, ~] = mf2_garch_forecasting(yWin, Z, h, tau
180         , coeffCurr, foptF);');
181     tZ = length(Z);
182     sigma2_fc = sigma2_all(tZ+1 : tZ+S_here);
183
184     % ----- 8.5 Benchmark storico -----
185     muRV = c * mean(RVWin0, 'omitnan');
186
187     % ----- 8.6 Calcolo delle loss per ciascun orizzonte -----
188     for hh = 1:nH
189         a = H(hh).a;
190         b = H(hh).b;
191         L = H(hh).L;
192         % Verifica fattibilit  dell'orizzonte
193         if i0 > i0_max_h(hh), continue; end
194         if b > S_here, continue; end
195         % Esclusione dei blocchi contenenti outlier
196         if excludeOutlierBlocks
197             nOut = outCum(i0+b+1) - outCum(i0+a);
198             if nOut > 0
199                 continue;
200             end
201         end
202         % Target: forward realized variance sul blocco
203         Hreal = c * sum(RV0(i0+a : i0+b), 'omitnan');
204         % Forecast MF2
205         Fmf2 = sum(sigma2_fc(a:b), 'omitnan');
206         % Forecast benchmark storico
207         Fhist = muRV * L;
208         % Floor numerico
209         Hpos = max(Hreal, epsPos);
210         Fmf2 = max(Fmf2, epsPos);
211         Fhist = max(Fhist, epsPos);
212         % Squared Error
213         SE_mf2(j,hh) = (Hreal - Fmf2)^2;
214         SE_hist(j,hh) = (Hreal - Fhist)^2;
215         % QLIKE (Patton 2011)
216         r_m = Hpos / Fmf2;
217         r_h = Hpos / Fhist;
218         QL_mf2(j,hh) = r_m - log(r_m) - 1;
219         QL_hist(j,hh) = r_h - log(r_h) - 1;
220     end
221
222 %% 9. CALCOLO DELLE MISURE DI PERFORMANCE

```

```

223 RMSE_mf2 = sqrt(mean(SE_mf2, 1, 'omitnan'));
224 RMSE_hist = sqrt(mean(SE_hist, 1, 'omitnan'));
225 QLIKE_mf2 = mean(QL_mf2, 1, 'omitnan');
226 QLIKE_hist = mean(QL_hist, 1, 'omitnan');
227 RMSE_rel = RMSE_mf2 ./ RMSE_hist;
228 QLIKE_rel = QLIKE_mf2 ./ QLIKE_hist;
229 N_h = sum(~isnan(SE_mf2), 1)';
230
231 %% 10. COSTRUZIONE DELLA TABELLA RIASSUNTIVA
232 tStart = strings(nH,1);
233 tEnd = strings(nH,1);
234 for hh = 1:nH
235     idx = find(~isnan(SE_mf2(:,hh)));
236     if isempty(idx), continue; end
237
238     j1 = idx(1);
239     jL = idx(end);
240     i01 = originsAll(j1);
241     i0L = originsAll(jL);
242
243     tStart(hh) = string(d(i01 + H(hh).a), 'yyyy-MM-dd');
244     tEnd(hh) = string(d(i0L + H(hh).b), 'yyyy-MM-dd');
245 end
246 RES = table(string({H.name})', N_h, tStart, tEnd, ...
247     RMSE_mf2', RMSE_hist', RMSE_rel', ...
248     QLIKE_mf2', QLIKE_hist', QLIKE_rel', ...
249     'VariableNames', {'Horizon','N','TargetStart','TargetEnd', ...
250         'RMSE_mf2','RMSE_hist','RMSE_rel', ...
251         'QLIKE_mf2','QLIKE_hist','QLIKE_rel'});
252 disp(RES);
253
254 %% =====
255 %% SCRIPT C - PREVISIONI OUT-OF-SAMPLE DI VaR ED ES A 1 GIORNO
256 %% =====
257
258 %% 1. CONFIGURAZIONE E DATI
259 Prices = readtable('S&P500_prices2025.xlsx');
260
261 Date = datetime(Prices.Date);
262 P = Prices.GSPCAdjusted(:);
263
264 y = 100 * diff(log(P));
265 dates = Date(2:end);
266
267 ok = isfinite(y) & isfinite(dates);
268 y = y(ok);
269 dates = dates(ok);
270
271 oosStartDate = datetime(2010,1,1);
272 oosEndDate = datetime(2025,9,29);
273
274 i00S1 = find(dates >= oosStartDate, 1, 'first');
275 i00SN = find(dates <= oosEndDate, 1, 'last');
276
277 rollingLen = 2520;
278 reestEvery = 21;
279 mFix = 21;

```

```

280
281 alpha1 = 0.01;
282 alpha5 = 0.05;
283
284 hsMatFile = 'hs_oos_results.mat';
285
286 %% 2. QUANTILI TEORICI E PRE-ALLOCAZIONE
287 % Quantili teorici sotto ipotesi di normalita standard
288 q1_N = norminv(alpha1);
289 ESZ1_N = -normpdf(q1_N) / alpha1;
290
291 q5_N = norminv(alpha5);
292 ESZ5_N = -normpdf(q5_N) / alpha5;
293
294 nOOS = iOOSN - iOOS1 + 1;
295
296 [VaR1_N, VaR5_N, ES1_N, ES5_N] = deal(NaN(nOOS,1));
297 [VaR1_T, VaR5_T, ES1_T, ES5_T] = deal(NaN(nOOS,1));
298 [Ret1, Sig2_1] = deal(NaN(nOOS,1));
299
300 %% 3. CICLO ROLLING DI STIMA E FORECAST
301 blockStart = iOOS1;
302
303 while blockStart <= iOOSN
304     blockEnd = min(blockStart + reestEvery - 1, iOOSN);
305     estEnd = blockStart - 1;
306     estStart = estEnd - rollingLen + 1;
307     yEst = y(estStart:estEnd);
308
309     % ----- 3.1 Stima del modello MF2-GARCH -----
310     foptE = struct('choice', 'fix', 'm', mFix, 'S', 1);
311     evalc('[coeff,~,~,Z_est,h_est,tau_est,~,~,~,foptE] = mf2_garch_estimation(
312         yEst, foptE);');
313     muHat = coeff(1);
314
315     % ----- 3.2 Stima dei gradi di liberta della Student-t -----
316     % Standardizzazione dei rendimenti tramite la volatilita stimata dal
317     % modello; si stima quindi il parametro nu della t standardizzata
318     sigZ_est = sqrt(h_est(:) .* tau_est(:));
319     zHat = (yEst(end-length(Z_est)+1:end) - muHat) ./ sigZ_est;
320     nuHat = estimate_nu_t_standardized(zHat, 2.1, 200);
321
322     % ----- 3.3 Quantili e Expected Shortfall sotto Student-t -----
323     s = sqrt(nuHat / (nuHat - 2));
324     qU1 = tinv(alpha1, nuHat);
325     q1_T = qU1 / s;
326     qU5 = tinv(alpha5, nuHat);
327     q5_T = qU5 / s;
328     ESZ1_T = -((nuHat + qU1^2) / (nuHat - 1)) * (tpdf(qU1, nuHat) / alpha1) /
329         s;
330     ESZ5_T = -((nuHat + qU5^2) / (nuHat - 1)) * (tpdf(qU5, nuHat) / alpha5) /
331         s;
332
333     % ----- 3.4 Forecast giornaliero entro il blocco di ri-stima -----
334     for tIdx = blockStart:blockEnd
335         yFilt = y(estStart:tIdx-1);
336         [Z, h, tau, ~] = mf2_garch_core(coeff, yFilt, mFix);

```

```

334     foptF = struct('m', mFix, 'S', 1);
335     evalc('[~, forecast] = mf2_garch_forecasting(yFilt, Z, h, tau, coeff,
336           foptF);');
337
338     sig1 = sqrt(forecast(end)); % d.s. prevista a 1 giorno
339     k     = tIdx - iOOS1 + 1;   % indice locale dell'osservazione
340                                   % nel campione OOS
341     Ret1(k) = y(tIdx);
342     Sig2_1(k) = forecast(end);
343
344     % Previsioni sotto Normalita
345     VaR1_N(k) = muHat + sig1 * q1_N;
346     ES1_N(k) = muHat + sig1 * ESZ1_N;
347
348     VaR5_N(k) = muHat + sig1 * q5_N;
349     ES5_N(k) = muHat + sig1 * ESZ5_N;
350
351     % Previsioni sotto Student-t
352     VaR1_T(k) = muHat + sig1 * q1_T;
353     ES1_T(k) = muHat + sig1 * ESZ1_T;
354
355     VaR5_T(k) = muHat + sig1 * q5_T;
356     ES5_T(k) = muHat + sig1 * ESZ5_T;
357
358     end
359
360     blockStart = blockEnd + 1;
361 end
362
363 %% 4. BACKTEST E CONFRONTO CON HISTORICAL SIMULATION
364 % Caricamento dei risultati del benchmark 'Historical Simulation'
365 % utilizzato come termine di confronto per le funzioni AL e FZO
366 load(hsMatFile, 'THS_OOS');
367
368 % Definizione delle quattro specificazioni da valutare
369 specs = {
370     'Normal_1', alpha1, VaR1_N, ES1_N, 'AL1_HS', 'FZ01_HS';
371     'Normal_5', alpha5, VaR5_N, ES5_N, 'AL5_HS', 'FZ05_HS';
372     'StudentT_1', alpha1, VaR1_T, ES1_T, 'AL1_HS', 'FZ01_HS';
373     'StudentT_5', alpha5, VaR5_T, ES5_T, 'AL5_HS', 'FZ05_HS'
374 };
375
376 BacktestResults = struct();
377 for i = 1:size(specs, 1)
378     modName = specs{i,1}; % nome della specificazione
379     a       = specs{i,2}; % livello di rischio
380     v       = specs{i,3}; % serie prevista del VaR
381     e       = specs{i,4}; % serie prevista dell'ES
382
383     % Sequenza di violazioni : vale 1 in caso di violazione del VaR
384     hit = double(Ret1 <= v);
385     hit_clean = hit(~isnan(hit));
386
387     % ----- 4.1 Test di Christoffersen -----
388     [LRuc, puc, LRind, pind, LRcc, pcc] = christoffersen_tests(hit_clean, a);
389
390     % ----- 4.2 Joint scoring functions -----
391     [AL_score, FZO_score] = joint_scores_al_fz0_core(Ret1, v, e, a);

```

```

390
391 % ----- 4.3 Test di calibrazione dinamica -----
392 outDQ = dq_test_core(Ret1, v, a);
393 outDES = des_test_core(Ret1, v, e, a);
394
395 % ----- 4.4 Salvataggio risultati -----
396 BacktestResults.(modName).Violations_Pct = 100 * mean(hit_clean);
397 BacktestResults.(modName).LR_UC = LRuc;
398 BacktestResults.(modName).UC_pval = puc;
399 BacktestResults.(modName).LR_IND = LRind;
400 BacktestResults.(modName).IND_pval = pind;
401 BacktestResults.(modName).LR_CC = LRcc;
402 BacktestResults.(modName).CC_pval = pcc;
403 BacktestResults.(modName).DQ_Stat = outDQ.Stat;
404 BacktestResults.(modName).DQ_pval = outDQ.pValue;
405 BacktestResults.(modName).DES_Stat = outDES.Stat;
406 BacktestResults.(modName).DES_pval = outDES.pValue;
407 BacktestResults.(modName).Mean_AL = mean(AL_score, 'omitnan');
408 BacktestResults.(modName).Mean_FZO = mean(FZO_score, 'omitnan');
409
410 % Score medi del benchmark storico
411 hs_AL_mean = mean(THS_OOS.(specs{i,5}), 'omitnan');
412 hs_FZO_mean = mean(THS_OOS.(specs{i,6}), 'omitnan');
413 % Skill percentuale rispetto al benchmark
414 BacktestResults.(modName).Skill_AL = skill_from_losses_pct(
    BacktestResults.(modName).Mean_AL, hs_AL_mean);
415 BacktestResults.(modName).Skill_FZO = skill_from_losses_pct(
    BacktestResults.(modName).Mean_FZO, hs_FZO_mean);
416 end
417
418 %% =====
419 %% SCRIPT D - TEST DI DIEBOLD-MARIANO
420 %% =====
421
422 %% 1. CONFIGURAZIONE DEL TEST
423 mKey = 'm21'; % specificazione MF2: 'm21' oppure 'm63'
424 altOneSided = 'less'; % ipotesi alternativa del test DM (qui one-sided)
425 benchType = 'GJR_T'; % benchmark: 'HS', 'GJR_N', 'GJR_T'
426
427 %% 2. CARICAMENTO E ALLINEAMENTO DEI DATI
428 S1 = load('mf2_oos_results.mat'); RES = S1.RES;
429 S2 = load('hs_oos_results.mat'); THS_OOS = S2.THs_OOS;
430 S3 = load('gjr_oos_results.mat');
431 if isfield(S3, 'TGJR_OOS')
432     TGJR_OOS = S3.TGJR_OOS;
433 else
434     TGJR_OOS = S3.GJR_OOS;
435 end
436
437 % Selezione della tabella benchmark in base alla specificazione scelta
438 if strcmp(benchType, 'HS')
439     BenchTab = THS_OOS;
440     bSuff = '_HS';
441 elseif strcmp(benchType, 'GJR_N')
442     BenchTab = TGJR_OOS;
443     bSuff = '_N';
444 elseif strcmp(benchType, 'GJR_T')

```

```

445     BenchTab = TGJR_OOS;
446     bSuff     = '_T';
447 end
448
449 % Allineamento delle osservazioni MF2 e benchmark sulle date comuni
450 [~, iMF2, iBench] = intersect(RES.(mKey).TVaR_ES_OOS.Date, BenchTab.Date);
451
452 %% 3. ESECUZIONE DEL TEST DM
453 % Per ciascuna specificazione si confrontano le loss series del modello MF2
454 % e del benchmark mediante il test DM applicato agli score AL e FZ0.
455 specs = {
456     'Normal_1',    'AL1_N', 'FZ01_N', '1';
457     'Normal_5',    'AL5_N', 'FZ05_N', '5';
458     'StudentT_1',  'AL1_T', 'FZ01_T', '1';
459     'StudentT_5',  'AL5_T', 'FZ05_T', '5'
460 };
461 DMResults = struct();
462 for i = 1:size(specs, 1)
463     modName = specs{i,1};
464     lvl     = specs{i,4};
465
466     % Loss MF2
467     mf2_al = RES.(mKey).TVaR_ES_OOS.(specs{i,2})(iMF2);
468     mf2_fz = RES.(mKey).TVaR_ES_OOS.(specs{i,3})(iMF2);
469
470     % Loss benchmark
471     bCol_AL = ['AL', lvl, bSuff];
472     bCol_FZ = ['FZ0', lvl, bSuff];
473     bench_al = BenchTab.(bCol_AL)(iBench);
474     bench_fz = BenchTab.(bCol_FZ)(iBench);
475
476     % Test DM
477     out_AL = dm_test_core(mf2_al, bench_al, altOneSided);
478     out_FZ = dm_test_core(mf2_fz, bench_fz, altOneSided);
479
480     % Salvataggio statistica test e p-value
481     DMResults.(modName).AL_Stat = out_AL.Stat;
482     DMResults.(modName).AL_pval = out_AL.pValue;
483     DMResults.(modName).FZ_Stat = out_FZ.Stat;
484     DMResults.(modName).FZ_pval = out_FZ.pValue;
485 end
486
487 %% =====
488 %% FUNZIONI LOCALI PER I BACKTEST SU VaR ED ES
489 %% =====
490
491 %% ----- F1. Stima dei gradi di liberta della Student-t -----
492 function nuHat = estimate_nu_t_standardized(z, lb, ub)
493     z = z(isfinite(z)); % mantiene solo le oss. finite
494     nll = @(nu) nll_std_t(nu, z); % funzione obiettivo: negativa della logl.
495     opts = optimset('TolX', 1e-4, 'Display', 'off'); % impostaz. ottimizz.
496     nuHat = fminbnd(nll, lb, ub, opts); % stima di nu tramite min-logl.
497 end
498
499 function val = nll_std_t(nu, z) % si impone nu > 2 per garantire
500     if nu <= 2.0001 % l'esistenza della var.
501         val = 1e50; % penalizzazione per valori non ammissibili

```



```

502     return;
503 end
504 s = sqrt(nu/(nu-2));
505 lp = log(tpdf(z.*s, nu)) + log(s); %log-densita student-t
506                                     %standardizzata valutata
507                                     %sulle osservazioni z
508 if any(~isfinite(lp))
509     val = 1e50;
510 else
511     val = -sum(lp); % resituisce negativa della logl. campionaria
512 end
513 end
514
515 %% ----- F2. Test di Christoffersen: UC, IND, CC -----
516 function [LRuc,puc,LRind,pind,LRcc,pcc] = christoffersen_tests(hit, alpha)
517
518 T = numel(hit); % Numero totale di osservazioni
519 x = sum(hit); % Numero complessivo di violazioni
520
521 eps0 = 1e-12;
522 phat = min(max(x / T, eps0), 1-eps0); % Frequenza empirica di violazione,
523                                         % opportunamente troncata
524                                         % per stabilita numerica
525 % Test di Unconditional Coverage (UC)
526 % H0: la probabilita di violazione e uguale al livello teorico alpha
527 % H1: la probabilita di violazione e diversa da alpha
528
529 % Log-verosimiglianza sotto H0: probabilita di violazione fissata ad alpha
530 logL0 = (T-x)*log(1-alpha) + x*log(alpha);
531
532 % Log-verosimiglianza sotto H1: probabilita di violazione stimata dal
533     campione
534 logL1 = (T-x)*log(1-phat) + x*log(phat);
535
536 % Statistica LR del test UC e relativo p-value
537 LRuc = -2 * (logL0 - logL1);
538 puc = 1 - chi2cdf(LRuc, 1);
539
540 % Costruzione delle transizioni tra violazioni consecutive
541 % h0 contiene lo stato al tempo t-1, h1 lo stato al tempo t
542 h0 = hit(1:end-1);
543 h1 = hit(2:end);
544
545 % Conteggi delle transizioni della catena di Markov a due stati
546 n00 = sum(~h0 & ~h1); % n00: nessuna viol. seguita da nessuna viol.
547 n01 = sum(~h0 & h1); % n01: nessuna viol. seguita da viol.
548 n10 = sum(h0 & ~h1); % n10: viol. seguita da nessuna viol.
549 n11 = sum(h0 & h1); % n11: viol. seguita da viol.
550
551 % Probabilita di transizione stimate, con correzione numerica
552 pi01 = min(max(n01 / max(n00+n01, 1), eps0), 1-eps0);
553 pi11 = min(max(n11 / max(n10+n11, 1), eps0), 1-eps0);
554
555 % Probabilita di violazione sotto indipendenza
556 pi2 = min(max((n01+n11) / max(n00+n01+n10+n11, 1), eps0), 1-eps0);
557
558 %% Test di indipendenza (IND)

```

```

558 % H0: le violazioni sono indipendenti nel tempo
559 % H1: le violazioni presentano dipendenza seriale
560
561 % Log-verosimiglianza sotto H0: unica probabilita di transizione
562 logL_ind = (n00+n10)*log(1-pi2) + (n01+n11)*log(pi2);
563
564 % Log-verosimiglianza sotto H1: probabilita di transizione
565 % dipendenti dallo stato precedente
566 logL_dep = n00*log(1-pi01) + n01*log(pi01) + n10*log(1-pi11) + n11*log(
    pi11);
567
568 % Statistica LR del test di indipendenza e relativo p-value
569 LRind = -2 * (logL_ind - logL_dep);
570 pind = 1 - chi2cdf(LRind, 1);
571
572 %% Test di copertura condizionata (CC)
573 % Combina copertura incondizionata e indipendenza
574 LRcc = LRuc + LRind;
575 pcc = 1 - chi2cdf(LRcc, 2);
576 end
577
578 %% ----- F3. Test DQ per il VaR -----
579 function out = dq_test_core(y, v, alpha)
580 % Scarto di quantile: diff. tra violazione oss. del VaR e la prob.
581 % teorica di violazione alpha
582 lam = double(y <= v) - alpha; % (1-alpha) se c'e la viol., altrimenti (-
    alpha)
583 dep = lam(2:end); % variabile dip. della regressione
    ausiliaria
584 X = [ones(numel(dep),1), lam(1:end-1), v(2:end)]; %matrice regressori
585 out = hac_wald_test(dep, X); % wald test con varianza HAC per verificare
    % la significativita congiunta
586
587 end
588
589 %% ----- F4. Test DES per l'Expected Shortfall -----
590 function out = des_test_core(y, v, e, alpha)
591 % Scarto di ES: misura la coerenza tra perdite osservate in coda
592 % ed Expected Shortfall previsto; sotto corretta specificazione ha media
    nulla
593 lam = (double(y <= v) .* (y ./ e)) ./ alpha - 1;
594 dep = lam(2:end);
595 X = [ones(numel(dep),1), lam(1:end-1), e(2:end)];
596 out = hac_wald_test(dep, X);
597 end
598
599 %% ----- F5. Test di Wald con matrice HAC -----
600 function out = hac_wald_test(dep, X)
601 out = struct('Stat', NaN, 'pValue', NaN);
602 N = size(X,1); % Numero oss.
603 k = size(X,2); % Num. regressori
604 if N <= k + 5 || rank(X) < k % Test eseguito con campione ampio
605     return; % e matrice con rango pieno
606 end
607 b = X \ dep; % Stima OLS coeff.
608 u = dep - X*b; % Residui
609
610 % Scelta automatica numero di ritardi matrice HAC

```

```

611 L = max(0, min(floor(4 * (N / 100)^(2/9)), N-1));
612
613 % Matrice var-cov HAC Newey-West
614 V = newey_west_cov(X, u, L);
615 if rcond(V) > 1e-12
616     % Statistica di Wald per il test congiunto H0: b = 0
617     out.Stat = b' * (V \ b);
618     % p-value asintotico basato sulla distribuzione chi-quadrato
619     out.pValue = 1 - chi2cdf(out.Stat, k);
620 end
621 end
622
623 %% ----- F6. Matrice di covarianza HAC di Newey-West -----
624 function V = newey_west_cov(X, u, L)
625     [T, k] = size(X); % T = num. oss., K = num. regressori
626     XtXinv = pinv(X' * X);
627     S = zeros(k); % Inizializzazione matrice
628     for t = 1:T % Si tiene in consideraz. l'eterosch. dei residui
629         S = S + (u(t)^2) * (X(t,:) * X(t,:));
630     end
631     for ell = 1:L % Si tiene conto dell'autocov. seriale fino al lag L
632         w = 1 - ell / (L + 1); % Peso di Bartlett
633
634         % Autocovarianza campionaria al ritardo ell
635         G = zeros(k);
636         for t = ell+1:T
637             G = G + u(t) * u(t-ell) * (X(t,:) * X(t-ell,:));
638         end
639         S = S + w * (G + G'); % Aggiornamento simmetrico della matrice
640                                 centrale
641     end
642     V = XtXinv * S * XtXinv; % Formula matrice HAC
643 end
644
645 %% ----- F7. Joint scoring functions: AL e FZ0 -----
646 function [AL_t, FZ0_t] = joint_scores_al_fz0_core(y, VaR, ES, alpha)
647
648     n = numel(y);
649     AL_t = NaN(n,1); % Pre-allocazione
650     FZ0_t = NaN(n,1);
651
652     % Selezioni oss. valide (VaR e ES devono essere finiti)
653     valid = isfinite(y) & isfinite(VaR) & isfinite(ES) & ...
654             (ES < -1e-12) & (ES < VaR - 1e-12);
655
656     % Restrizione alle sole osservazioni ammissibili
657     yy = y(valid);
658     vv = VaR(valid);
659     ee = ES(valid);
660     ii = double(yy <= vv); % Indicatore di violazione del VaR
661
662     % Funzioni di perdita
663     AL_t(valid) = -log((1-alpha)./(-ee)) - ((yy - vv).*(alpha - ii))./(alpha
664         .* ee);
665     FZ0_t(valid) = -(ii.*(vv - yy))./(alpha .* ee) + (vv./ee) + log(-ee) - 1;
666 end
667

```

```

666 %% ----- F8. Skill score percentuale rispetto al benchmark -----
667 function s = skill_from_losses_pct(meanModel, meanBench)
668     if ~isfinite(meanModel) || ~isfinite(meanBench) || abs(meanBench) < 1e-12
669         s = NaN;
670         return;
671     end
672     s = 100 * (1 - meanModel / meanBench);
673 end
674 %% =====
675 %% FUNZIONE LOCALE PER IL TEST DI DIEBOLD-MARIANO
676 %% =====
677
678 function out = dm_test_core(x, y, alt)
679     out = struct('Stat', NaN, 'pValue', NaN, 'MeanDiff', NaN);
680     ok = isfinite(x) & isfinite(y);
681     d = x(ok) - y(ok);
682     T = numel(d);
683
684     if T < 20
685         return;
686     end
687
688     dbar = mean(d); % media campionaria del differenziale di loss
689     xc = d - dbar; % serie centrata del differenziale, per stimare
690                     % la long-run variance
691
692     % Lag HAC automatico di Newey-West
693     q = min(T-1, floor(4 * (T/100)^(2/9)));
694     % Long-run variance con kernel di Bartlett
695     lrv = (xc' * xc) / T;
696     for k = 1:q
697         lrv = lrv + 2 * (1 - k/(q+1)) * ((xc(1+k:end))' * xc(1:end-k)) / T;
698     end
699     if lrv > 1e-12 % test eseguito se la long-run variance e positiva
700         stat = dbar / sqrt(lrv / T); % Statistica del test DM
701
702         out.Stat = stat;
703         out.MeanDiff = dbar;
704
705         switch alt % Calcolo del p-value in base all'ipotesi alternativa
706             case 'less'
707                 out.pValue = normcdf(stat);
708             case 'greater'
709                 out.pValue = 1 - normcdf(stat);
710             case 'two-sided'
711                 out.pValue = 2 * (1 - normcdf(abs(stat)));
712         end
713     end
714 end

```

# Bibliografia

- Adrian, T., & Rosenberg, J. (2008). Stock returns and volatility: Pricing the short-run and long-run components of market risk. *The Journal of Finance*, 63(6), 2997–3030.
- Ahoniemi, K., & Lanne, M. (2010). Realized volatility and overnight returns. *Bank of Finland Research Discussion Paper*, No. 19.
- Amado, C., & Teräsvirta, T. (2008). Modelling conditional and unconditional heteroskedasticity with smoothly time-varying structure. *CREATES Research Paper*, No. 2008-8.
- Andersen, T. G., & Bollerslev, T. (1998). *Answering the skeptics: Yes, standard volatility models do provide accurate forecasts*. International Economic Review, 885–905.
- Andersen, T. G., Bollerslev, T., Christoffersen, P. F., & Diebold, F. X. (2006). Volatility and correlation forecasting. In G. Elliott, C. W. J. Granger, & A. Timmermann (Eds.), *Handbook of economic forecasting* (Vol. 1, pp. 777–878). Elsevier.
- Asgharian, H., Hou, A. J., & Javed, F. (2013). The importance of macroeconomic variables in forecasting stock return variance: A GARCH-MIDAS approach. *Journal of Forecasting*, 32, 600–612.
- Baker, S. R., Bloom, N., Davis, S. J., & Kost, K. J. (2019). Policy news and stock market volatility. *NBER Working Paper*, No. 25720.
- Baillie, R. T., Bollerslev, T., & Mikkelsen, H. O. (1996). Fractionally integrated generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 74(1), 3–30.
- Black, F. (1976). Studies of stock price volatility changes. In *Proceedings of the 1976 Meeting of the American Statistical Association, Business and Economic Statistics Section* (pp. 177–181). American Statistical Association.

- Black, F., & Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of Political Economy*, 81(3), 637–654.
- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Brownlees, C. T., & Engle, R. F. (2012). Volatility, correlation and tails for systemic risk measurement. *SSRN Working Paper*, No. 1611229.
- Christiansen, C., Schmeling, M., & Schrimpf, A. (2012). A comprehensive look at financial volatility prediction by economic variables. *Journal of Applied Econometrics*, 27(6), 956–977.
- Christoffersen, P. F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- Christoffersen, P. F., & Diebold, F. X. (2000). How relevant is volatility forecasting for financial risk management? *Review of Economics and Statistics*, 82(1), 12–22.
- Christoffersen, P., Jacobs, K., & Ornathanalai, C. (2012). Dynamic jump intensities and risk premiums: Evidence from S&P 500 returns and options. *Journal of Financial Economics*, 106(3), 447–472.
- Conrad, C., & Engle, R. F. (2025). Modelling volatility cycles: The MF2-GARCH model. *Journal of Applied Econometrics*, 40(4), 438–454.
- Conrad, C., & Schienle, M. (2020). Testing for an omitted multiplicative long-term component in GARCH models. *Journal of Business & Economic Statistics*, 38(2), 229–242.
- Conrad, C., Schoelkopf, J. T., & Tushteva, N. (2025). Long-term volatility shapes the stock market’s sensitivity to news. *Journal of Econometrics*, 106148.
- Cont, R. (2001). Empirical properties of asset returns: Stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- Cont, R. (2007). Volatility clustering in financial markets: Empirical facts and agent-based models. In *Long memory in economics* (pp. 289–309). Springer Berlin Heidelberg.

- Da, R., & Xiu, D. (2021). When moving-average models meet high-frequency data: Uniform inference on volatility. *Econometrica*, 89(6), 2787–2825.
- Ding, Z., & Granger, C. W. (1996). Modeling volatility persistence of speculative returns: A new approach. *Journal of Econometrics*, 73(1), 185–215.
- Dorion, C. (2016). Option valuation with macro-finance variables. *Journal of Financial and Quantitative Analysis*, 51(4), 1359–1389.
- Ederington, L. H., & Guan, W. (2010). Longer-term time-series volatility forecasts. *Journal of Financial and Quantitative Analysis*, 45, 1055–1076.
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50, 987–1007.
- Engle, R. F. (2001). GARCH 101: The use of ARCH/GARCH models in applied econometrics. *Journal of Economic Perspectives*, 15(4), 157–168.
- Engle, R. F. (2009). The risk that risk will change. *Journal of Investment Management*, 7(4), 24–28.
- Engle, R. F. (2009a). *Anticipating correlations: A new paradigm for risk management*. Princeton University Press.
- Engle, R. F., & Bollerslev, T. (1986). Modelling the persistence of conditional variances. *Econometric Reviews*, 5(1), 1–50.
- Engle, R. F., Ghysels, E., & Sohn, B. (2013). Stock market volatility and macroeconomic fundamentals. *Review of Economics and Statistics*, 95, 776–797.
- Engle, R. F., & Lee, G. G. (1999). A long-run and short-run component model of stock return volatility. In R. F. Engle & H. White (Eds.), *Cointegration, causality, and forecasting: A festschrift in honour of Clive W. J. Granger* (pp. 475–497). Oxford University Press.
- Engle, R. F., & Manganelli, S. (2004). CAViaR: Conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4), 367–381.

- Engle, R. F., & Ng, V. K. (1993). Measuring and testing the impact of news on volatility. *The Journal of Finance*, 48(5), 1749–1778.
- Engle, R. F., & Rangel, J. G. (2008). The spline-GARCH model for low-frequency volatility and its global macroeconomic causes. *Review of Financial Studies*, 21, 1187–1222.
- Fama, E. F. (1965). The behavior of stock-market prices. *The Journal of Business*, 38(1), 34–105.
- Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417.
- Figlewski, S. (1997). Forecasting volatility. *Financial Markets, Institutions & Instruments*, 6(1), 1–88.
- Figlewski, S. (2001). Reprinted from *Journal of Derivatives*, 6(4) (1999), 33–43. In *Quantitative analysis in financial markets* (Vol. 3, p. 296). World Scientific.
- Fissler, T., & Ziegel, J. F. (2016). Higher order elicibility and Osband’s principle. *The Annals of Statistics*, 44(4), 1680–1707.
- Fouque, J.-P., Papanicolaou, G., & Sircar, K. R. (2000). *Derivatives in financial markets with stochastic volatility*. Cambridge University Press.
- Fouque, J.-P., Papanicolaou, G., Sircar, K. R., & Sølna, K. (2003). Multi-scale stochastic volatility for equity, interest-rate, and credit-rate markets. *Communications on Pure and Applied Mathematics*, 56(11), 1543–1583.
- Francq, C., & Zakoïan, J.-M. (2007). Quasi-maximum likelihood in GARCH processes when some coefficients are equal to zero. *Stochastic Processes and their Applications*, 117, 1265–1284.
- Francq, C., Kandji, B. M., & Zakoïan, J. M. (2024). Inference on GARCH-MIDAS models without any small-order moment. *Econometric Theory*, 40(6), 1422–1455.
- Ghysels, E., Santa-Clara, P., & Valkanov, R. (2006). Predicting volatility: Getting the most out of return data sampled at different frequencies. *Journal of Econometrics*, 131, 59–95.



- Glosten, L. R., Jagannathan, R., & Runkle, D. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5), 1779–1801.
- Hansen, P. R., & Lunde, A. (2005). A forecast comparison of volatility models: Does anything beat a GARCH(1,1)? *Journal of Applied Econometrics*, 20(7), 873–889.
- Hassler, U. (2018). *Time series analysis with long memory in view*. John Wiley & Sons.
- Heston, S. L., & Nandi, S. (2000). A closed-form GARCH option valuation model. *The Review of Financial Studies*, 13(3), 585–625.
- Jordà, Ò. (2005). Estimation and inference of impulse responses by local projections. *American Economic Review*, 95(1), 161–182.
- Lamoureux, C. G., & Lastrapes, W. D. (1990). Persistence in variance, structural change, and the GARCH model. *Journal of Business & Economic Statistics*, 8(2), 225–234.
- Li, J., Phillips, P. C., Shi, S., & Yu, J. (2025). Weak identification of long memory with implications for volatility modeling. *The Review of Financial Studies*, 38(10), 3117–3148.
- Mandelbrot, B. (1963). The variation of certain speculative prices. *Journal of Business*, 36, 392–417.
- Newey, W. K., & West, K. D. (1987). Hypothesis testing with efficient method of moments estimation. *International Economic Review*, 28(3), 777–787.
- Pagan, A. (1996). The econometrics of financial markets. *Journal of Empirical Finance*, 3(1), 15–102.
- Pagan, A. R., & Schwert, G. W. (1990). Alternative models for conditional stock volatility. *Journal of Econometrics*, 45(1–2), 267–290.
- Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- Patton, A. J., Ziegel, J. F., & Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2), 388–413.

- Paye, B. S. (2012). Déjà vol: Predictive regressions for aggregate stock market volatility using macroeconomic variables. *Journal of Financial Economics*, 106(3), 527–546.
- Schwert, G. W. (1989). Why does stock market volatility change over time? *The Journal of Finance*, 44(5), 1115–1153.
- Taylor, J. W. (2019). Forecasting value at risk and expected shortfall using a semiparametric approach based on the asymmetric Laplace distribution. *Journal of Business & Economic Statistics*, 37(1), 121–133.
- Taylor, J. W. (2020). Forecast combinations for value at risk and expected shortfall. *International Journal of Forecasting*, 36(2), 428–441.
- Tse, Y. K. (1991). Stock return volatility in the Tokyo Stock Exchange. *Japan and the World Economy*, 3(3), 285–298.
- Wang, F., & Ghysels, E. (2015). Econometric analysis of volatility component models. *Econometric Theory*, 31, 362–393.
- Xiu, D. (2010). Quasi-maximum likelihood estimation of volatility with high frequency data. *Journal of Econometrics*, 159(1), 235–250.

## Sitografia

- Conrad, C. e Schoelkopf, J. T. (2025). *MF2-GARCH Toolbox for Matlab*. Matlab package, version 0.1.0. <https://github.com/juliustheodor/mf2garch.git>.
- Da and Xiu Risk Lab, <https://dachxiu.chicagobooth.edu/#risklab>.
- Federal Reserve Economic Data (FRED), Federal Reserve Bank of St. Louis, <https://fred.stlouisfed.org/>.
- Stock Market Jumps Data, <https://sites.google.com/view/stock-market-jumps/data>.
- Volatility Laboratory (V-Lab), New York University Stern School of Business, <https://vlab.stern.nyu.edu/>.